

Clasificación de estudiantes de Actuaría según sus preferencias de materias optativas mediante análisis de conglomerados

Índice

1. Objetivo	3
2. Introducción	3
3. Problemática	4
4. Técnicas estadísticas utilizadas	5
4.1. Análisis de conglomerados	5
4.2. Medidas de distancia	6
4.3. Método K-means	6
4.4. Determinación del número de conglomerados	8
4.4.1. Método del codo	8
4.4.2. Coeficiente de silueta	8
4.5. Aplicación del análisis de conglomerados al problema	9
5. Análisis descriptivo	10
5.1. Distribución del orden de preferencia	10
5.2. Estadísticos descriptivos del orden de preferencia	11
5.3. Número de preferencias registradas por estudiante	11
5.4. Frecuencia de elección de las materias	12
5.5. Materias con mayor frecuencia de elección	13
5.6. Materias con menor frecuencia de elección	14
6. Análisis utilizando la técnica	15
6.1. Preparación de los datos para el análisis de conglomerados	16
6.2. Construcción de la matriz de preferencias	16
6.3. Análisis de conglomerados	17
6.3.1. Análisis jerárquico	17
6.3.2. Caras de Chernoff	18
6.4. Determinación del número de conglomerados	19
6.4.1. Método del codo	20
6.4.2. Coeficiente de silueta	21
6.5. Análisis de la solución con $K = 4$	22
6.5.1. Conglomerado 1	22
6.5.2. Conglomerado 2	23
6.5.3. Conglomerado 3	23
6.5.4. Conglomerado 4	23
6.6. Análisis de la solución con $K = 5$	24

6.6.1. Conglomerado 1	24
6.6.2. Conglomerado 2	25
6.6.3. Conglomerado 3	25
6.6.4. Conglomerado 4	25
6.6.5. Conglomerado 5	26
6.7. Comparación entre las soluciones $K = 4$ y $K = 5$	26
6.8. Selección de la solución final	28
7. Anexos	28
7.1. Trabajo realizado sobre la base de datos	28
7.2. Código utilizado	32
8. Conclusiones	65

1. Objetivo

Por medio de la técnica de análisis de conglomerados, se busca agrupar de forma apropiada a los estudiantes de la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán de acuerdo con sus preferencias respecto a las materias optativas.

El propósito es identificar grupos de estudiantes que presenten patrones de elección similares, de manera que los integrantes de un mismo conglomerado compartan preferencias semejantes por determinadas materias. A partir de estos grupos se pretende identificar las materias que resulten representativas de las preferencias de cada conglomerado.

2. Introducción

La elección de materias optativas constituye una parte importante de la formación académica de los estudiantes, ya que permite seleccionar asignaturas de acuerdo con sus intereses y preferencias. Cuando una generación cuenta con diferentes alternativas de materias y cada estudiante establece un orden de preferencia, se genera información que puede ser utilizada para identificar patrones de elección.

En el presente trabajo se analiza una base de datos correspondiente a las preferencias de estudiantes de la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán respecto a diferentes materias optativas. Para cada estudiante se cuenta con información relacionada con las asignaturas de su interés y con el orden de preferencia asignado a cada una de ellas, donde los valores de la escala permiten establecer cuáles son las materias que presentan mayor o menor preferencia para cada estudiante.

El análisis busca aprovechar esta información para identificar grupos de estudiantes con características similares en sus preferencias. Para ello, se emplea la técnica estadística de análisis de conglomerados, la cual permite formar grupos de observaciones de acuerdo con el grado de similitud existente entre ellas.

El trabajo se estructura en diferentes etapas. En primer lugar, se presenta la problemática asociada con la elección de materias optativas y las características de la información disponible. Posteriormente, se describen las técnicas estadísticas utilizadas y se realiza un análisis descriptivo de la base de datos. Después, se aplica la técnica de análisis de conglomerados para identificar grupos de estudiantes con preferencias similares y se analizan las características de cada uno de los grupos obtenidos.

Finalmente, se presentan las conclusiones derivadas del análisis y se incluye un anexo en el que se documenta el proceso realizado para la revisión, depuración y transformación de la base de datos antes de aplicar la técnica estadística.

3. Problemática

En la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán, los estudiantes pueden manifestar sus preferencias respecto a las materias optativas que desean cursar. Para una generación determinada, se dispone de una base de datos construida a partir de las elecciones realizadas por los estudiantes.

La información corresponde a un registro realizado hace varios años, en un contexto en el que los mecanismos digitales para recopilar y organizar información no se encontraban tan estandarizados como en la actualidad. Debido a la forma en que fueron registradas las elecciones, la base presenta algunas inconsistencias que deben ser consideradas antes de realizar cualquier análisis estadístico. La información originalmente se encuentra organizada de manera que cada registro representa la selección de una materia por parte de un estudiante. Además de identificar al estudiante y la materia seleccionada, la base contiene una variable denominada “Orden de preferencia”, mediante la cual se establece la importancia relativa que el estudiante asignó a cada una de sus elecciones. La escala de preferencia utilizada permite distinguir entre las materias que presentan mayor y menor interés para cada estudiante. En particular, un valor de 5 representa la mayor preferencia dentro de las opciones seleccionadas por el estudiante, mientras que un valor de 1 representa una menor preferencia relativa.

Por ejemplo, si un estudiante selecciona las materias Análisis de Datos, Análisis Multivariado, Evaluación de Proyectos, Auditoría Actuarial y Contabilidad de Seguros, y asigna a Análisis Multivariado un orden de preferencia igual a 5, esta materia representa su principal elección dentro de las opciones registradas.

Debido a la forma en que fue recopilada la información, se presentan diferencias en la manera de capturar los nombres de las materias, errores de escritura, variaciones en el uso de mayúsculas, minúsculas y espacios, así como algunos registros que requieren ser revisados y relacionados con el catálogo de materias disponible. Estas situaciones pueden provocar que una misma asignatura aparezca registrada de diferentes maneras, aunque represente la misma materia.

Esta situación representa un aspecto importante del problema, ya que realizar directamente un análisis estadístico sobre una base que no ha sido revisada y depurada podría generar resultados incorrectos. Por ejemplo, si una misma materia aparece registrada con diferentes nombres, el análisis podría interpretarlas como asignaturas distintas, modificando las frecuencias y afectando la identificación de los patrones de preferencia.

Por lo anterior, antes de aplicar una técnica estadística es necesario realizar un proceso de revisión, depuración y organización de la información. Esto permitirá identificar registros inconsistentes, estandarizar las materias y estructurar los datos de manera que las preferencias de los estudiantes puedan ser comparadas adecuadamente.

Una vez que la información se encuentre depurada, surge la necesidad de identificar grupos de estudiantes que presenten patrones de preferencia similares. Algunos estudiantes pueden presentar

intereses similares y seleccionar las mismas materias en órdenes de preferencia semejantes, mientras que otros pueden presentar patrones de elección diferentes. Por lo tanto, identificar manualmente grupos de estudiantes con preferencias similares puede resultar complicado cuando se considera el conjunto completo de elecciones.

Esta situación plantea la necesidad de utilizar una herramienta estadística que permita identificar grupos relativamente homogéneos de estudiantes a partir de sus preferencias. El análisis de conglomerados resulta adecuado para este propósito, ya que permite agrupar observaciones de acuerdo con sus características de similitud.

Desde una perspectiva práctica, la formación de estos grupos puede contribuir a identificar conjuntos de estudiantes que presentan intereses académicos semejantes. Esto permitiría analizar cuáles son las materias que concentran las preferencias dentro de cada grupo y evitar considerar como representativas aquellas asignaturas cuya demanda sea demasiado reducida.

Por esta razón, se busca obtener una clasificación que permita formar como máximo cinco conglomerados y considerar, para cada uno de ellos, un número reducido de materias representativas. De esta manera, el resultado del análisis no solamente tendrá una interpretación estadística, sino que también podrá relacionarse con la organización de las preferencias de los estudiantes.

4. Técnicas estadísticas utilizadas

4.1. Análisis de conglomerados

El análisis de conglomerados, también conocido como análisis de *cluster*, es una técnica estadística multivariada cuyo objetivo es identificar grupos de individuos u objetos que presenten características similares entre sí.

A diferencia de las técnicas de clasificación en las que los grupos son definidos previamente, en el análisis de conglomerados los grupos se obtienen a partir de las características observadas en los datos. De esta manera, se busca formar conglomerados cuyos integrantes sean lo más similares posible entre sí y, al mismo tiempo, presenten diferencias respecto a los integrantes de otros conglomerados.

La finalidad del análisis de conglomerados es, por lo tanto, encontrar una estructura de agrupamiento dentro de un conjunto de datos. Para lograrlo, se comparan las características de las observaciones mediante alguna medida de similitud o distancia, de acuerdo con el método de agrupamiento utilizado.

En el presente trabajo, las observaciones corresponden a los estudiantes de la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán, mientras que las características utilizadas para establecer la similitud entre ellos corresponden a sus preferencias por las diferentes materias optativas.

De esta manera, se busca identificar grupos de estudiantes que presenten patrones de elección simi-

lares, de tal forma que los integrantes de un mismo conglomerado tengan preferencias semejantes y puedan ser diferenciados de aquellos estudiantes que presenten patrones de elección distintos.

4.2. Medidas de distancia

Para formar los conglomerados es necesario contar con una medida que permita determinar qué tan similares o diferentes son dos observaciones. En el contexto del presente trabajo, esta medida permitirá comparar a los estudiantes a partir de sus preferencias por las materias optativas.

Una medida de distancia asigna un valor numérico a la diferencia existente entre dos observaciones. Un valor pequeño indica que las observaciones presentan características similares, mientras que un valor grande indica que existe una mayor diferencia entre ellas.

Existen diferentes medidas de distancia que pueden utilizarse dependiendo de las características de los datos. Una de las más utilizadas para variables cuantitativas es la distancia euclidiana. Para dos observaciones representadas por los vectores

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})$$

y

$$\mathbf{x}_j = (x_{j1}, x_{j2}, \dots, x_{jp}),$$

la distancia euclidiana se define como

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{r=1}^p (x_{ir} - x_{jr})^2},$$

donde p representa el número de variables consideradas para realizar la comparación.

En el caso de esta práctica, cada estudiante será representado mediante sus preferencias por las diferentes materias optativas. Por lo tanto, la distancia entre dos estudiantes permitirá cuantificar qué tan similares son sus patrones de elección. Por ejemplo, dos estudiantes que asignen órdenes de preferencia semejantes a las mismas materias tendrán una distancia relativamente pequeña, mientras que aquellos que presenten preferencias diferentes tendrán una distancia mayor.

La elección de la medida de distancia es importante, ya que influye directamente en la formación de los conglomerados. Por esta razón, antes de aplicar la técnica se debe considerar la naturaleza de las variables y la forma en que se representan las preferencias de los estudiantes.

4.3. Método K-means

El método K-means es una técnica de agrupamiento no jerárquico que permite dividir un conjunto de observaciones en un número determinado de conglomerados. El objetivo del método es formar

grupos cuyos integrantes presenten características similares entre sí, de acuerdo con las variables utilizadas en el análisis.

La letra K representa el número de conglomerados que se desea formar. En este método, el número de grupos debe establecerse previamente y, posteriormente, cada observación es asignada al conglomerado cuyo centroide se encuentra más cercano.

El centroide de un conglomerado corresponde al vector formado por la media de cada una de las variables de las observaciones que pertenecen a dicho grupo. Por lo tanto, el centroide puede interpretarse como una representación del comportamiento promedio de los individuos que conforman el conglomerado.

De manera general, el procedimiento de K-means puede describirse mediante los siguientes pasos:

1. Seleccionar el número K de conglomerados que se desean formar.
2. Establecer inicialmente K centroides.
3. Calcular la distancia entre cada observación y cada uno de los centroides.
4. Asignar cada observación al conglomerado cuyo centroide se encuentre más cercano.
5. Actualizar los centroides calculando nuevamente la media de las observaciones asignadas a cada conglomerado.
6. Repetir los pasos anteriores hasta que las asignaciones de las observaciones se estabilicen o se cumpla el criterio de convergencia establecido.

El método busca minimizar la variabilidad interna de los conglomerados. Para ello, se considera la suma de las distancias cuadráticas entre cada observación y el centroide del conglomerado al que pertenece. La función objetivo puede expresarse como

$$\min \sum_{j=1}^K \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2,$$

donde C_j representa el conglomerado j , $\mathbf{x}_i$ representa una observación perteneciente a dicho conglomerado y $\boldsymbol{\mu}_j$ corresponde al centroide del conglomerado j .

En términos prácticos, el método busca que los estudiantes que pertenezcan a un mismo conglomerado tengan patrones de preferencias similares. Por ejemplo, si un grupo de estudiantes presenta preferencias elevadas por determinadas materias y patrones semejantes en el resto de sus elecciones, K-means tenderá a ubicarlos dentro del mismo conglomerado.

En el presente trabajo, el número de conglomerados estará limitado a un máximo de cinco, de acuerdo con el objetivo establecido. Sin embargo, esto no implica que necesariamente deban formarse cinco grupos. Será necesario evaluar diferentes valores de K y determinar cuál proporciona una agrupación adecuada tanto desde el punto de vista estadístico como desde la perspectiva práctica del problema.

4.4. Determinación del número de conglomerados

Una de las decisiones más importantes al utilizar el método K-means consiste en determinar el número de conglomerados que se deben formar. La elección de un valor inadecuado de K puede generar grupos demasiado generales o, por el contrario, una cantidad excesiva de grupos que dificulte su interpretación.

En el presente trabajo, el número de conglomerados estará restringido a un máximo de cinco, por lo que se considerarán diferentes alternativas dentro de este límite. Para apoyar la selección del número de grupos se utilizarán criterios estadísticos que permitan evaluar la calidad de las agrupaciones obtenidas.

4.4.1. Método del codo

El método del codo es una técnica utilizada para identificar un valor apropiado de K mediante el análisis de la variabilidad interna de los conglomerados. Para cada posible número de grupos se calcula la suma de cuadrados dentro de los conglomerados, conocida como *Within-Cluster Sum of Squares* (WCSS).

La medida puede expresarse como

$$WCSS = \sum_{j=1}^K \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2,$$

donde C_j representa el conglomerado j , $\mathbf{x}_i$ corresponde a una observación perteneciente al conglomerado y $\boldsymbol{\mu}_j$ representa su centroide.

A medida que aumenta el número de conglomerados, la variabilidad interna tiende a disminuir, debido a que las observaciones se distribuyen entre un mayor número de grupos. Sin embargo, después de cierto punto, agregar nuevos conglomerados produce una reducción cada vez menor en la variabilidad.

El método del codo consiste en identificar el punto en el que esta reducción deja de ser considerable. Este punto puede interpretarse como un equilibrio entre obtener grupos suficientemente homogéneos y evitar utilizar un número excesivo de conglomerados.

4.4.2. Coeficiente de silueta

Otro criterio utilizado para evaluar la calidad de una agrupación es el coeficiente de silueta. Esta medida permite evaluar qué tan adecuada es la asignación de una observación al conglomerado al que pertenece, considerando tanto su similitud con los elementos de su propio grupo como su separación respecto a otros grupos.

Para una observación i , el coeficiente de silueta se define como

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

donde $a(i)$ representa la distancia promedio entre la observación i y las demás observaciones pertenecientes a su mismo conglomerado, mientras que $b(i)$ corresponde a la menor distancia promedio entre la observación i y las observaciones de cualquier otro conglomerado.

El valor del coeficiente de silueta se encuentra entre -1 y 1 . Valores cercanos a 1 indican que la observación se encuentra bien integrada dentro de su propio conglomerado y separada de los demás grupos. Valores cercanos a 0 indican que la observación se encuentra en una posición intermedia entre dos conglomerados, mientras que valores negativos pueden indicar una asignación inadecuada. Para seleccionar el número de conglomerados se considerarán los resultados obtenidos mediante estos criterios, evaluando los valores posibles de K dentro del límite establecido. La decisión final no dependerá únicamente de un criterio numérico, sino que también se considerará la interpretación de los grupos obtenidos y su utilidad para el problema de las preferencias de los estudiantes.

4.5. Aplicación del análisis de conglomerados al problema

Para aplicar el análisis de conglomerados al problema planteado, se requiere transformar la información original de manera que las preferencias de cada estudiante puedan ser comparadas entre sí. En este sentido, cada estudiante será considerado como una observación, mientras que las diferentes materias optativas constituirán las variables mediante las cuales se describirá su patrón de preferencias.

La información correspondiente al orden de preferencia permitirá representar las elecciones realizadas por cada estudiante. De esta manera, será posible comparar a los individuos de acuerdo con las materias seleccionadas y con la importancia relativa que cada estudiante asignó a ellas.

A partir de esta representación se aplicará el método K-means para identificar grupos de estudiantes con patrones de preferencia similares. La formación de los conglomerados permitirá analizar las características particulares de cada grupo y determinar cuáles son las materias que presentan una mayor concentración de preferencias dentro de ellos.

Debido a que uno de los objetivos del análisis es obtener grupos que tengan una utilidad práctica, la interpretación de los conglomerados no se limitará únicamente a la asignación de los estudiantes. También se analizará la distribución de las preferencias dentro de cada grupo, con el propósito de identificar las materias que puedan considerarse representativas de cada conglomerado.

Asimismo, se considerará la restricción de formar como máximo cinco conglomerados y no más de cinco materias representativas por grupo. En caso de que una materia presente una cantidad muy reducida de estudiantes interesados dentro de un conglomerado, se evaluará su pertinencia como materia representativa, buscando que los resultados reflejen patrones de preferencia suficientemente respaldados por los integrantes de cada grupo.

De esta manera, la aplicación del análisis de conglomerados permitirá transformar la información individual de las preferencias en una clasificación de estudiantes con características similares, facilitando posteriormente la interpretación de los patrones de elección de materias optativas.

5. Análisis descriptivo

Una vez concluido el proceso de limpieza y homologación de la información, se realizó un análisis estadístico descriptivo de las preferencias registradas por los estudiantes. Para este análisis se utilizó la base de datos limpia, conservando los 609 registros correspondientes a los 124 estudiantes.

El análisis se enfocó en la distribución del orden de preferencia, el número de preferencias registradas por estudiante y la frecuencia de elección de las materias optativas.

5.1. Distribución del orden de preferencia

El orden de preferencia corresponde a la posición que cada estudiante asignó a una materia dentro de sus elecciones. Los valores posibles van del 1 al 5, donde el valor 5 representa la mayor preferencia y el valor 1 la menor preferencia relativa dentro de las opciones seleccionadas.

La distribución de los registros según el orden de preferencia se presenta en la Figura 1. Se observa que los cinco niveles presentan frecuencias relativamente similares. El primer nivel registra 118 elecciones, mientras que los niveles cuarto y quinto presentan la mayor frecuencia, con 124 registros cada uno.




Figura 1: Distribución del orden de preferencia

La distribución obtenida muestra que no existe una concentración marcada de los registros en alguno de los cinco niveles de preferencia. Las frecuencias aumentan ligeramente conforme se avanza del primer al quinto nivel, aunque las diferencias son relativamente pequeñas.

5.2. Estadísticos descriptivos del orden de preferencia

Para complementar el análisis de frecuencias, se calcularon medidas descriptivas para la variable correspondiente al orden de preferencia. Los resultados obtenidos se presentan en la Tabla 1.

Cuadro 1: Estadísticos descriptivos del orden de preferencia

Estadístico	Valor
Media	3.02
Mediana	3.00
Desviación estándar	1.41
Mínimo	1
Máximo	5

La media del orden de preferencia fue de 3.02, mientras que la mediana fue de 3.00. Esto indica que las elecciones se concentran alrededor del tercer nivel de preferencia. La desviación estándar de 1.41 refleja una dispersión moderada respecto a la media, mientras que los valores mínimo y máximo confirman que se utilizaron los cinco niveles de preferencia disponibles.

5.3. Número de preferencias registradas por estudiante

Además del orden asignado a cada elección, se analizó el número total de preferencias registradas por estudiante. De los 124 estudiantes considerados, 118 registraron las cinco preferencias disponibles, lo que representa el 95.2% del total.

Por otra parte, 3 estudiantes registraron cuatro preferencias, 2 estudiantes registraron dos preferencias y únicamente 1 estudiante registró tres preferencias.

La distribución del número de preferencias registradas por estudiante se presenta en la Figura 2.




Figura 2: Número de preferencias registradas por estudiante

Los resultados muestran que existe una alta uniformidad en el número de elecciones realizadas por los estudiantes, ya que el 95.2% de ellos registró las cinco preferencias. Esto permite considerar que la información disponible presenta una estructura suficientemente completa para analizar los patrones de elección.

5.4. Frecuencia de elección de las materias

Posteriormente, se calculó la frecuencia con la que cada materia fue seleccionada por los estudiantes. Para este análisis se utilizó el nombre de la materia homologado con base en el catálogo oficial, de manera que las diferentes formas de captura correspondientes a una misma asignatura fueran consideradas como una sola categoría.

De las 27 materias contempladas en el catálogo oficial, 26 presentan al menos una selección en la base de datos. La materia *Modelos Macroeconómicos* no registra ninguna elección, por lo que presenta una frecuencia de cero y no aparece entre las materias seleccionadas.

La Figura 3 muestra la frecuencia de elección de las 26 materias que registraron al menos una selección.




Figura 3: Frecuencia de elección de las materias

La materia con mayor frecuencia de elección fue *Modelos y Simulación*, con 85 selecciones, seguida de *Análisis de Regresión*, con 64. Posteriormente se encuentran *Evaluación de Proyectos* y *Derivados*, ambas con 54 selecciones, mientras que *Muestreo* registró 43 selecciones.

También destacan *Auditoría Actuarial*, con 37 selecciones, *Investigación de Operaciones II* y *Análisis Multivariado*, con 36 cada una, y *Estadística Bayesiana*, con 35 selecciones.

5.5. Materias con mayor frecuencia de elección

Con el propósito de identificar las materias que concentran el mayor número de elecciones, se seleccionaron las diez materias con mayor frecuencia.




Figura 4: Materias con mayor frecuencia de elección

Como se observa en la Figura 4, *Modelos y Simulación* presenta una frecuencia de 85 selecciones, siendo la materia con mayor número de elecciones. Le siguen *Análisis de Regresión*, con 64, y *Evaluación de Proyectos* y *Derivados*, con 54 selecciones cada una.

Dentro de este grupo también se encuentran *Muestreo*, *Auditoría Actuarial*, *Investigación de Operaciones II*, *Análisis Multivariado*, *Estadística Bayesiana* y *Serie de Tiempo*.

5.6. Materias con menor frecuencia de elección

De manera complementaria, se identificaron las diez materias con menor frecuencia de elección entre las 26 materias que registraron al menos una selección.




Figura 5: Materias con menor frecuencia de elección

Las materias con menor frecuencia fueron *Modelos Microeconómicos*, con una selección; *Legislación de Seguros* y *Estadística de Seguros*, con dos selecciones cada una; *Seguros de Personas*, *Procesos Estocásticos II* y *Análisis Económico*, con tres selecciones cada una; *Contabilidad de Seguros*, con cinco selecciones; y *Fianzas*, con seis selecciones.

Asimismo, *Presupuesto de capital* y *Matemáticas Actariales Aplicadas* registraron diez selecciones cada una.

En términos generales, el análisis descriptivo evidencia una distribución heterogénea en la frecuencia de elección de las materias. Mientras algunas asignaturas concentran un número elevado de selecciones, otras presentan una participación considerablemente menor. Estas diferencias permiten identificar patrones iniciales en las preferencias de los estudiantes, los cuales serán estudiados posteriormente mediante la técnica de análisis de conglomerados.

6. Análisis utilizando la técnica

Una vez concluido el análisis descriptivo, se procedió a aplicar la técnica de análisis de conglomerados con el propósito de identificar grupos de estudiantes que presentaran patrones de preferencia similares respecto a las materias optativas de la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán.

Para este análisis se utilizó el método *k-means*, debido a que permite dividir un conjunto de observaciones en un número determinado de conglomerados, de manera que los individuos pertenecientes a un mismo grupo presenten características similares entre sí y, al mismo tiempo, sean diferentes de los individuos pertenecientes a otros grupos.

En este caso, cada estudiante constituye una observación y sus preferencias por las materias optativas representan las características a partir de las cuales se determinará la similitud entre estudiantes. De esta manera, el objetivo del procedimiento es identificar grupos de estudiantes con patrones de elección semejantes, los cuales puedan ser interpretados posteriormente de acuerdo con las materias que presentan mayor preferencia dentro de cada conglomerado.

6.1. Preparación de los datos para el análisis de conglomerados

La base de datos original se encuentra estructurada de forma que cada registro representa una elección realizada por un estudiante. Por tanto, un mismo estudiante puede aparecer en varios registros, correspondientes a las diferentes materias que seleccionó.

Para aplicar el método *k-means*, fue necesario transformar la información a una estructura en la que cada fila representara a un estudiante y cada columna correspondiera a una materia. De esta forma, se construyó una matriz de preferencias de dimensiones estudiante por materia.

En esta matriz, los valores registrados representan el orden de preferencia asignado por cada estudiante a las materias que seleccionó. Las materias que no fueron seleccionadas por un estudiante se identifican de manera diferenciada, con el propósito de conservar la información sobre el patrón completo de elecciones de cada individuo.

La transformación de la información permite comparar a los estudiantes considerando simultáneamente el conjunto de materias y sus respectivos niveles de preferencia, en lugar de analizar cada elección de manera individual.

6.2. Construcción de la matriz de preferencias

A partir de la base limpia, se utilizó la variable “Nombre_Materia_Limpio” para identificar las materias y la variable “Orden de preferencia” para representar el nivel de preferencia asignado por cada estudiante.

La información se transformó a una matriz en la que cada fila corresponde a un estudiante y cada columna representa una de las materias que presentó al menos una selección en la base de datos. Para las materias seleccionadas por un estudiante se conservó el valor correspondiente a su orden de preferencia, utilizando la escala de 1 a 5.

En los casos en que un estudiante no seleccionó una determinada materia, se asignó el valor de 0. De esta manera, el valor de cero representa la ausencia de elección de la materia, mientras que los valores de 1 a 5 representan los distintos niveles de preferencia registrados por el estudiante.

Esta transformación permite representar en una sola estructura el patrón completo de preferencias de cada estudiante y facilita la comparación entre individuos mediante medidas de distancia. La matriz resultante constituye la información de entrada para la aplicación del método *k-means*.

6.3. Análisis de conglomerados

El análisis de conglomerados se realizó con el objetivo de identificar grupos de estudiantes que presentaran patrones de preferencia similares respecto a las materias optativas de la Licenciatura en Actuaría de la FES Acatlán. La base de datos está conformada por 124 estudiantes y 26 materias optativas.

Para cada estudiante se dispone del orden de preferencia asignado a cada materia. En esta escala, un valor mayor representa una mayor preferencia por cursar dicha materia, mientras que un valor de cero indica que la materia no fue seleccionada dentro de sus preferencias.

A partir de esta información, el análisis busca agrupar a los estudiantes de acuerdo con la similitud de sus preferencias, de tal manera que aquellos que presenten patrones similares queden integrados en un mismo conglomerado. La finalidad es identificar perfiles de estudiantes que permitan posteriormente proponer una organización de las materias optativas de acuerdo con las preferencias observadas en cada grupo.

Para realizar la agrupación se empleó el algoritmo *k-means*, utilizando como variables las preferencias registradas para las diferentes materias optativas. La selección del número de conglomerados se realizó posteriormente mediante criterios estadísticos y considerando las restricciones establecidas para la conformación de los grupos.

6.3.1. Análisis jerárquico

Como herramienta complementaria al análisis de conglomerados, se construyó un dendrograma mediante un procedimiento de agrupamiento jerárquico. Esta representación permite observar cómo se van formando grupos de estudiantes a partir de sus similitudes y diferencias en los patrones de preferencia.

La altura a la que se unen las ramas representa la distancia entre los grupos que se están fusionando. Por lo tanto, las observaciones que se unen a distancias pequeñas presentan patrones de preferencia más similares.




Figura 6: Dendrograma del análisis jerárquico.

Como se observa en la Figura 6, existen diferentes niveles de similitud entre los estudiantes, observándose agrupaciones que se forman a diferentes distancias. El dendrograma permite obtener una visión general de la estructura de los datos y sirve como apoyo para interpretar los patrones de agrupamiento encontrados posteriormente mediante K-means.

6.3.2. Caras de Chernoff

Como complemento a la representación jerárquica, se utilizaron caras de Chernoff para representar visualmente las características de las materias optativas de acuerdo con sus patrones de preferencia. Cada cara representa una materia y sus diferentes características faciales se encuentran asociadas con los valores registrados para los distintos lugares de preferencia. De esta manera, materias con patrones de preferencia similares presentan representaciones visuales semejantes, mientras que diferencias en sus patrones producen cambios en los rasgos de las caras.




Figura 7: Caras de Chernoff de las materias optativas según el lugar de preferencia.

La representación permite identificar visualmente diferencias entre las materias de acuerdo con la distribución de sus preferencias. Por ejemplo, algunas materias presentan características faciales más diferenciadas, mientras que otras muestran representaciones similares, lo cual sugiere patrones de elección semejantes.

6.4. Determinación del número de conglomerados

Para determinar un número adecuado de conglomerados se evaluaron diferentes soluciones mediante el algoritmo *k-means*. Debido a que se estableció como condición no generar más de cinco grupos, se consideraron soluciones entre $K = 2$ y $K = 5$ conglomerados.

La selección del número de conglomerados se realizó considerando dos criterios complementarios. En primer lugar, se utilizó el método del codo, mediante la suma de cuadrados intra-conglomerado (*Within-Cluster Sum of Squares*, WSS), con el propósito de observar la reducción de la variabilidad interna al incrementar el número de grupos. En segundo lugar, se calculó el coeficiente de silueta promedio, el cual permite evaluar qué tan adecuadamente se encuentra cada estudiante asignado a su conglomerado en relación con los demás grupos.

A partir de ambos criterios se analizaron las soluciones obtenidas para $K = 2$, $K = 3$, $K = 4$ y $K = 5$, prestando especial atención a las alternativas de cuatro y cinco conglomerados. Estas dos soluciones serán analizadas y comparadas posteriormente para determinar cuál resulta más adecuada para los objetivos del estudio.

6.4.1. Método del codo

La suma de cuadrados intra-conglomerado (*Within-Cluster Sum of Squares*, WSS) obtenida para las diferentes soluciones se presenta en la Tabla 2.

Cuadro 2: Suma de cuadrados intra-conglomerado para diferentes valores de K .

Número de conglomerados (K)	WSS
2	3795.855
3	3425.821
4	3134.357
5	2909.235

La Figura 8 muestra el comportamiento de la WSS conforme aumenta el número de conglomerados.




Figura 8: Método del codo para determinar el número de conglomerados.

Como se observa, la WSS disminuye conforme se incrementa el número de conglomerados, lo cual indica que la variabilidad interna de los grupos se reduce al aumentar su número. Sin embargo, la disminución de la WSS por sí sola no permite determinar de manera concluyente cuál es el número adecuado de conglomerados. Por esta razón, este criterio se complementó con el coeficiente de silueta promedio.

6.4.2. Coeficiente de silueta

Como segundo criterio para evaluar las soluciones de agrupamiento se calculó el coeficiente de silueta promedio para cada valor de K . Los resultados obtenidos se presentan en la Tabla 3.

Cuadro 3: Coeficiente de silueta promedio para diferentes valores de K .

Número de conglomerados (K)	Silueta promedio
2	0.1652
3	0.1403
4	0.1527
5	0.1488

La Figura 9 presenta gráficamente los valores obtenidos.




Figura 9: Coeficiente de silueta para diferentes números de conglomerados.

El coeficiente de silueta presenta su valor máximo para la solución de $K = 2$, con un valor de 0.1652. Sin embargo, esta solución concentra a los 124 estudiantes en únicamente dos grupos, lo cual proporciona una segmentación demasiado general para el objetivo del estudio.

Por otra parte, las soluciones de $K = 4$ y $K = 5$ presentan coeficientes de silueta de 0.1527 y 0.1488, respectivamente. Ambos valores son cercanos entre sí y permiten una segmentación más detallada de los estudiantes, sin superar la restricción establecida de cinco conglomerados.

Por lo anterior, las soluciones de $K = 4$ y $K = 5$ se consideran como las principales alternativas para el análisis posterior. Ambas serán analizadas de manera detallada, considerando el tamaño de los conglomerados, las materias con mayor frecuencia de selección y la interpretación de los perfiles obtenidos, antes de seleccionar la solución final.

6.5. Análisis de la solución con $K = 4$

La solución con cuatro conglomerados distribuye a los 124 estudiantes de la siguiente manera:

Cuadro 4: Distribución de estudiantes para $K = 4$.

Conglomerado	Estudiantes	Porcentaje
1	36	29.0 %
2	27	21.8 %
3	28	22.6 %
4	33	26.6 %
Total	124	100 %

La distribución muestra que los cuatro conglomerados presentan tamaños relativamente equilibrados. El conglomerado de menor tamaño está conformado por 27 estudiantes, mientras que el de mayor tamaño cuenta con 36 estudiantes.

Para caracterizar cada conglomerado se identificaron las materias con mayor número de estudiantes que las seleccionaron dentro de cada grupo. De acuerdo con el criterio establecido para el análisis, únicamente se consideraron como relevantes aquellas materias que fueron seleccionadas por al menos cinco estudiantes dentro del conglomerado. Para cada grupo se presentan las cinco materias con mayor frecuencia de selección.

6.5.1. Conglomerado 1

El primer conglomerado está integrado por 36 estudiantes. Las materias con mayor frecuencia de selección se presentan en la Tabla 5.

Cuadro 5: Principales materias del conglomerado 1 para $K = 4$.

Materia	Estudiantes	Porcentaje
Análisis de Regresión	36	100.0 %
Modelos y Simulación	34	94.4 %
Investigación de Operaciones II	21	58.3 %
Muestreo	16	44.4 %
Evaluación de Proyectos	14	38.9 %

Se observa una marcada preferencia por las materias de *Análisis de Regresión* y *Modelos y Simulación*, seleccionadas por la totalidad y el 94.4 % de los integrantes del conglomerado, respectivamente. También presentan una presencia importante *Investigación de Operaciones II* y *Muestreo*. En conjunto, estas preferencias caracterizan al grupo por una orientación hacia materias de análisis estadístico, modelación y métodos cuantitativos.

6.5.2. Conglomerado 2

El segundo conglomerado está conformado por 27 estudiantes. Sus principales materias se muestran en la Tabla 6.

Cuadro 6: Principales materias del conglomerado 2 para $K = 4$.

Materia	Estudiantes	Porcentaje
Estadística Bayesiana	27	100.0 %
Modelos y Simulación	21	77.8 %
Muestreo	18	66.7 %
Análisis de Regresión	17	63.0 %
Análisis Multivariado	9	33.3 %

El principal rasgo de este conglomerado es la preferencia por *Estadística Bayesiana*, seleccionada por la totalidad de sus integrantes. A esta materia le siguen *Modelos y Simulación*, *Muestreo* y *Análisis de Regresión*. El perfil del grupo muestra, por tanto, una orientación hacia materias relacionadas con la estadística y el análisis de datos.

6.5.3. Conglomerado 3

El tercer conglomerado está integrado por 28 estudiantes. Las materias con mayor frecuencia de selección se presentan en la Tabla 7.

Cuadro 7: Principales materias del conglomerado 3 para $K = 4$.

Materia	Estudiantes	Porcentaje
Auditoría Actuarial	18	64.3 %
Modelos y Simulación	14	50.0 %
Planeación Financiera	14	50.0 %
Evaluación de Proyectos	13	46.4 %
Análisis de Estados Financieros	9	32.1 %

Este conglomerado presenta una mayor presencia de *Auditoría Actuarial*, seleccionada por el 64.3 % de sus integrantes. También destacan *Planeación Financiera* y *Evaluación de Proyectos*, además de *Modelos y Simulación*. En conjunto, las preferencias observadas permiten identificar un perfil con mayor orientación hacia materias relacionadas con auditoría, finanzas y evaluación de proyectos.

6.5.4. Conglomerado 4

El cuarto conglomerado está conformado por 33 estudiantes. Sus principales materias se presentan en la Tabla 8.

Cuadro 8: Principales materias del conglomerado 4 para $K = 4$.

Materia	Estudiantes	Porcentaje
Derivados	33	100.0 %
Evaluación de Proyectos	23	69.7 %
Modelos y Simulación	16	48.5 %
Auditoría Actuarial	12	36.4 %
Análisis Multivariado	10	30.3 %

Este conglomerado presenta una preferencia particularmente marcada por *Derivados*, materia seleccionada por la totalidad de sus integrantes. También destaca *Evaluación de Proyectos*, con una selección del 69.7 % de los estudiantes. Las demás materias relevantes presentan frecuencias menores, aunque *Modelos y Simulación* mantiene una presencia importante dentro del grupo.

6.6. Análisis de la solución con $K = 5$

La solución con cinco conglomerados distribuye a los 124 estudiantes de la siguiente manera:

Cuadro 9: Distribución de estudiantes para $K = 5$.

Conglomerado	Estudiantes	Porcentaje
1	26	21.0 %
2	27	21.8 %
3	27	21.8 %
4	20	16.1 %
5	24	19.4 %
Total	124	100 %

La distribución muestra que los cinco conglomerados presentan tamaños relativamente equilibrados, con un mínimo de 20 y un máximo de 27 estudiantes.

Para interpretar los grupos se identificaron las materias con mayor número de estudiantes dentro de cada conglomerado. Se consideraron como materias relevantes aquellas seleccionadas por al menos cinco estudiantes.

6.6.1. Conglomerado 1

El primer conglomerado está integrado por 26 estudiantes. Sus principales materias son:

Cuadro 10: Principales materias del conglomerado 1 para $K = 5$.

Materia	Estudiantes	Porcentaje
Auditoría Actuarial	17	65.4 %
Planeación financiera	14	53.8 %
Modelos y simulación	13	50.0 %
Evaluación de Proyectos	12	46.2 %
Análisis de estados financieros	8	30.8 %

Este conglomerado presenta una mayor preferencia por Auditoría Actuarial, seleccionada por el 65.4 % de sus integrantes. También destacan Planeación financiera, Modelos y simulación y Evaluación de Proyectos, por lo que el grupo presenta un perfil relacionado principalmente con auditoría, finanzas y evaluación de proyectos.

6.6.2. Conglomerado 2

El segundo conglomerado está conformado por 27 estudiantes:

Cuadro 11: Principales materias del conglomerado 2 para $K = 5$.

Materia	Estudiantes	Porcentaje
Análisis de Regresión	27	100.0 %
Modelos y simulación	27	100.0 %
Análisis Multivariado	11	40.7 %
Muestreo	11	40.7 %
Investigación de Operaciones II	9	33.3 %

El principal rasgo de este grupo es la preferencia por Análisis de Regresión y Modelos y simulación, materias seleccionadas por la totalidad de sus integrantes. También destacan Análisis Multivariado, Muestreo e Investigación de Operaciones II, lo que permite identificar un perfil orientado principalmente hacia materias estadísticas y de modelación.

6.6.3. Conglomerado 3

El tercer conglomerado está integrado por 27 estudiantes:

Cuadro 12: Principales materias del conglomerado 3 para $K = 5$.

Materia	Estudiantes	Porcentaje
Derivados	27	100.0 %
Evaluación de Proyectos	19	70.4 %
Modelos y simulación	14	51.9 %
Auditoría Actuarial	12	44.4 %
Análisis Multivariado	10	37.0 %

Este conglomerado presenta una preferencia particularmente marcada por Derivados, materia seleccionada por la totalidad de sus integrantes. También destaca Evaluación de Proyectos, con una selección del 70.4 % de los estudiantes, seguida de Modelos y simulación y Auditoría Actuarial.

6.6.4. Conglomerado 4

El cuarto conglomerado está conformado por 20 estudiantes:

Cuadro 13: Principales materias del conglomerado 4 para $K = 5$.

Materia	Estudiantes	Porcentaje
Investigación de Operaciones II	20	100.0 %
Análisis de Regresión	13	65.0 %
Modelos y simulación	13	65.0 %
Evaluación de Proyectos	11	55.0 %
Muestreo	8	40.0 %

Este conglomerado presenta una preferencia particularmente marcada por Investigación de Operaciones II, materia seleccionada por la totalidad de sus integrantes. Asimismo, destacan Análisis de Regresión y Modelos y simulación, ambas con una selección del 65.0 %, lo que muestra un perfil orientado hacia materias de métodos cuantitativos, estadística y modelación.

6.6.5. Conglomerado 5

El quinto conglomerado está integrado por 24 estudiantes:

Cuadro 14: Principales materias del conglomerado 5 para $K = 5$.

Materia	Estudiantes	Porcentaje
Estadística Bayesiana	24	100.0 %
Modelos y simulación	18	75.0 %
Muestreo	16	66.7 %
Análisis de Regresión	14	58.3 %
Análisis Multivariado	9	37.5 %

Este conglomerado presenta un perfil principalmente estadístico, encabezado por Estadística Bayesiana, seleccionada por la totalidad de sus integrantes. También destacan Modelos y simulación y Muestreo, con 75.0 % y 66.7 % de selección, respectivamente, además de Análisis de Regresión y Análisis Multivariado.

6.7. Comparación entre las soluciones $K = 4$ y $K = 5$

Una vez analizadas ambas alternativas, se realizó una comparación considerando el tamaño de los conglomerados, el coeficiente de silueta y la correspondencia entre las asignaciones obtenidas en ambas soluciones.

Cuadro 15: Comparación de las soluciones $K = 4$ y $K = 5$.

Criterio	$K = 4$	$K = 5$
Número de conglomerados	4	5
Silueta promedio	0.1527	0.1488
Tamaño mínimo	27	20
Tamaño máximo	36	27
Número total de estudiantes	124	124

La solución con $K = 4$ presenta un coeficiente de silueta promedio de 0.1527, ligeramente superior al obtenido para $K = 5$, cuyo valor fue de 0.1488. Por lo tanto, el incremento de cuatro a cinco conglomerados no representa una mejora en términos de la separación y cohesión de los grupos, de acuerdo con este criterio.

En cuanto al tamaño de los conglomerados, ambas soluciones presentan grupos de dimensiones relativamente equilibradas. Para $K = 4$, el tamaño de los conglomerados varía entre 27 y 36 estudiantes, mientras que para $K = 5$ varía entre 20 y 27 estudiantes. Aunque la solución con cinco conglomerados permite una segmentación ligeramente más detallada, también genera un grupo adicional sin producir una mejora en el coeficiente de silueta.

Para analizar la correspondencia entre ambas soluciones se construyó una tabla de transición, en la que cada celda representa el número de estudiantes que pertenecían a un determinado conglomerado de $K = 4$ y que fueron asignados a un conglomerado específico de $K = 5$.

Cuadro 16: Tabla de transición de las asignaciones entre $K = 4$ y $K = 5$.

$K = 4 \backslash K = 5$	1	2	3	4	5
1	0	24	0	12	0
2	0	3	0	0	24
3	26	0	0	2	0
4	0	0	27	6	0

La tabla muestra una correspondencia importante entre las dos soluciones. El conglomerado 1 de $K = 4$, integrado por 36 estudiantes, se divide entre los conglomerados 2 y 4 de $K = 5$, con 24 y 12 estudiantes, respectivamente. De manera similar, el conglomerado 2 de $K = 4$ se distribuye principalmente entre los conglomerados 5 y 2 de $K = 5$, con 24 y 3 estudiantes, respectivamente. Por otra parte, el conglomerado 3 de $K = 4$ presenta una alta correspondencia con el conglomerado 1 de $K = 5$, ya que 26 de sus 28 integrantes permanecen agrupados, mientras que únicamente 2 son asignados al conglomerado 4. Asimismo, 27 de los 33 estudiantes que integraban el conglomerado 4 de $K = 4$ pasan al conglomerado 3 de $K = 5$, mientras que los 6 restantes se incorporan al conglomerado 4.

Estos resultados indican que la solución con $K = 5$ no genera cinco perfiles completamente independientes de los obtenidos con $K = 4$. En cambio, la nueva solución conserva una parte importante de la estructura de cuatro conglomerados y realiza subdivisiones y reasignaciones entre algunos de ellos.

Considerando conjuntamente el coeficiente de silueta, el tamaño de los grupos y la correspondencia entre las asignaciones, la solución con $K = 4$ presenta un mejor equilibrio entre la diferenciación de los perfiles y la simplicidad de la segmentación. Por lo tanto, se selecciona $K = 4$ como la solución final para caracterizar los perfiles de preferencia de los estudiantes.

6.8. Selección de la solución final

Considerando conjuntamente los resultados obtenidos, se selecciona la solución de $K = 4$ **conglomerados** como la alternativa final para el análisis.

Esta decisión se fundamenta en los siguientes aspectos:

- Cumple con la restricción establecida de no generar más de cinco grupos.
- Los cuatro conglomerados presentan tamaños relativamente equilibrados, con entre 27 y 36 estudiantes.
- El coeficiente de silueta promedio es ligeramente superior al obtenido con cinco conglomerados (0.1527 frente a 0.1488), por lo que incrementar el número de grupos no representa una mejora en este criterio.
- Los cuatro conglomerados presentan perfiles de preferencias diferenciados, lo que permite interpretar de manera clara los principales intereses de los estudiantes.
- La solución de $K = 5$ conserva una parte importante de la estructura obtenida con $K = 4$, pero introduce subdivisiones y reasignaciones entre algunos grupos sin generar una mejora en la calidad del agrupamiento.

Por lo tanto, para la propuesta final de organización de las materias optativas se utilizará la solución de cuatro conglomerados. Esta solución permite identificar cuatro perfiles de estudiantes con patrones de preferencia diferenciados y proporciona un nivel de segmentación suficientemente detallado, sin generar una fragmentación innecesaria de la población.

7. Anexos

7.1. Trabajo realizado sobre la base de datos

La base de datos utilizada para el análisis contiene las preferencias de los estudiantes respecto a las materias optativas de la Licenciatura en Actuaría de la Facultad de Estudios Superiores Acatlán. Debido a que la información fue recopilada originalmente mediante un proceso de captura que no contaba con herramientas digitales estandarizadas, se identificaron algunas inconsistencias en los nombres de las materias y en las claves registradas. Por esta razón, antes de realizar el análisis estadístico fue necesario llevar a cabo un proceso de revisión y depuración de la información.

Como primer paso, se importó la hoja denominada “Base completa de eleccion” del archivo de Excel. La base original contiene cuatro variables: identificador del estudiante, orden de preferencia, clave de la materia y nombre de la materia.

La exploración inicial permitió determinar que la base contiene un total de 609 registros correspondientes a 124 estudiantes. Cada registro representa una elección realizada por un estudiante y contiene el orden de preferencia asignado a dicha materia.

También se revisó la estructura de las variables, los primeros y últimos registros y un resumen general de la información, con el propósito de identificar posibles valores faltantes o inconsistencias que pudieran afectar el análisis posterior.

El archivo de Excel contiene una segunda hoja denominada “materias”, la cual fue utilizada como catálogo de referencia. Esta hoja contiene dos columnas: el nombre oficial de la materia y su clave correspondiente. Debido a la estructura original de la hoja, la primera fila corresponde directamente a una materia y no a los encabezados de las columnas.

Después de seleccionar las dos columnas relevantes y retirar del catálogo los registros que no contenían información, se identificaron 27 materias dentro del catálogo oficial. Este catálogo se tomó como referencia para homologar los nombres de las materias presentes en la base de elecciones. Posteriormente, se compararon las claves registradas en la base de elecciones con las claves disponibles en el catálogo oficial. Esta revisión permitió identificar algunas diferencias entre ambas fuentes.

En particular, se encontraron claves presentes en la base de elecciones que no aparecen en el catálogo oficial. Entre ellas se identificaron las claves 2511, 2613 y 2612. Asimismo, se detectó un registro sin clave correspondiente al estudiante 102.

Debido a estas diferencias, no se consideró conveniente utilizar exclusivamente la clave como criterio para identificar las materias. Esta decisión fue consistente con la revisión realizada sobre la información y con la indicación de utilizar el nombre de la materia como referencia en aquellos casos donde la clave no coincidiera con el catálogo.

Además de comparar las claves, se revisaron los nombres registrados en la base. Se encontraron diversas formas de captura para una misma materia, incluyendo diferencias en mayúsculas y minúsculas, errores de escritura, abreviaciones y caracteres especiales.

Por ejemplo, una misma materia podía aparecer registrada de diferentes maneras, aun cuando correspondiera a la misma asignatura del catálogo oficial. Este comportamiento se observó particularmente en materias como Análisis Multivariado, Análisis de Regresión, Investigación de Operaciones II y Modelos y Simulación.

Para identificar estas situaciones se agruparon los registros por clave y se contabilizó el número de nombres diferentes asociados a cada una. Posteriormente, se revisaron de manera detallada los registros correspondientes a las claves que presentaban un mayor número de inconsistencias.

A partir de la revisión anterior, se creó una variable denominada “Nombre_Materia_Limpio”, destinada a almacenar el nombre homologado de cada materia.

Para realizar la homologación se tomó como referencia el nombre oficial contenido en el catálogo. De esta manera, cuando el nombre registrado por un estudiante presentaba diferencias de escritura, pero permitía identificar claramente la materia correspondiente, se sustituyó por el nombre oficial

del catálogo.

Este procedimiento permitió evitar que una misma materia fuera considerada como varias asignaturas diferentes durante el análisis estadístico.

También se normalizaron algunas diferencias relacionadas con mayúsculas, minúsculas, espacios y caracteres especiales, con el propósito de facilitar la comparación entre los nombres capturados y los nombres oficiales.

Una vez realizada la homologación, se efectuó una revisión final para identificar registros que todavía no contaran con un nombre de materia homologado.

Durante esta revisión se identificaron algunos registros que requerían una revisión específica. En particular, se detectaron inconsistencias en los nombres de las materias correspondientes al estudiante 67, donde se registraron elecciones de *Economía Matemática II* y *Análisis Económico*. Asimismo, se identificó un registro correspondiente al estudiante 70 cuya materia presentaba un problema de codificación de caracteres en el nombre de *Economía Matemática II*.

Estos casos fueron revisados individualmente y se asignó a cada registro el nombre de la materia que correspondía de acuerdo con el catálogo oficial. De esta manera, se evitó que una misma asignatura fuera considerada como una categoría diferente debido a errores de captura o codificación.

Después de realizar las correcciones correspondientes, no se encontraron registros sin homologar. Por lo tanto, los 609 registros de la base cuentan con un nombre de materia limpio para ser utilizado en el análisis.

Como resultado del proceso de limpieza, se conservaron los 609 registros originales correspondientes a los 124 estudiantes. La información de las materias se trabajó utilizando el nombre homologado con base en el catálogo oficial, en lugar de depender exclusivamente de las claves registradas originalmente.

El catálogo oficial contiene 27 materias; sin embargo, en la base de elecciones se identificaron 26 materias con al menos una selección. La diferencia corresponde a la materia *Modelos Macroeconómicos*, la cual forma parte del catálogo oficial, pero no presentó registros de elección en la información analizada.

Por lo tanto, las 26 materias que presentaron al menos una selección constituyeron la base para el análisis descriptivo y posteriormente para la aplicación de la técnica de análisis de conglomerados mediante el método *k-means*.

Este proceso permitió reducir el efecto de los errores de captura y de las diferencias de escritura presentes en la información original, de manera que las observaciones correspondientes a una misma materia fueran consideradas como una sola categoría durante las etapas posteriores del análisis.

Una vez concluido el proceso de limpieza y homologación de la base de datos, se realizó una transformación de la información con el propósito de obtener una estructura adecuada para la aplicación del análisis de conglomerados.

Para ello, se reorganizó la información de manera que cada fila representara a un estudiante y cada columna correspondiera a una materia optativa. De esta forma, se construyó una matriz

de preferencias en la que cada estudiante quedó representado mediante el conjunto de valores correspondientes al orden de preferencia de las materias seleccionadas.

Las materias que no fueron seleccionadas por un estudiante se representaron mediante un valor de cero, mientras que las materias seleccionadas conservaron el valor correspondiente a su orden de preferencia. Esta transformación permitió comparar a los estudiantes considerando simultáneamente sus preferencias por las diferentes materias optativas.

Con la matriz de preferencias preparada, se aplicó el algoritmo de agrupamiento *k-means*. Esta técnica permite dividir las observaciones en un número determinado de conglomerados, de manera que los estudiantes pertenecientes a un mismo grupo presenten patrones de preferencia similares. Para cada estudiante se utilizaron como variables de agrupamiento los valores correspondientes a las materias optativas. El algoritmo asignó cada estudiante al conglomerado cuyo centroide se encontraba más próximo de acuerdo con la distancia utilizada por el procedimiento.

Debido a que el resultado del algoritmo puede depender de la selección inicial de los centroides, se utilizaron múltiples inicializaciones para reducir el efecto de una selección inicial desfavorable. Asimismo, se fijó una semilla aleatoria con el propósito de garantizar que el procedimiento fuera reproducible.

Una vez aplicado el procedimiento de agrupamiento, se evaluaron diferentes cantidades de conglomerados con el propósito de determinar una estructura adecuada para los datos.

De acuerdo con las condiciones establecidas para el análisis, se consideró un máximo de cinco grupos. Por esta razón, se evaluaron soluciones con diferentes valores de K dentro de este límite. Para comparar las distintas soluciones se utilizaron dos criterios. El primero fue el método del codo, basado en la suma de cuadrados intra-conglomerado (*Within-Cluster Sum of Squares*, WSS), el cual permite observar cómo disminuye la variabilidad interna de los grupos al incrementar el número de conglomerados.

El segundo criterio fue el coeficiente de silueta promedio, utilizado para evaluar conjuntamente la cohesión de las observaciones dentro de cada conglomerado y su separación respecto de los demás grupos.

La utilización conjunta de ambos criterios permitió comparar las diferentes alternativas de agrupamiento y seleccionar aquellas que resultaran más adecuadas para continuar con el análisis.

A partir de los criterios anteriores, se realizó una comparación entre las soluciones consideradas como alternativas para el análisis final.

Además de los criterios estadísticos, se revisó la distribución de los estudiantes entre los conglomerados y las características de las materias seleccionadas dentro de cada grupo. Esta revisión permitió evaluar si los grupos obtenidos eran suficientemente grandes y si presentaban perfiles de preferencia que pudieran interpretarse de manera adecuada.

También se consideró la restricción establecida para la conformación de los grupos, de acuerdo con la cual no debía generarse un número de conglomerados superior a cinco y las materias consideradas para la organización final debían presentar una demanda suficiente entre los estudiantes.

Una vez obtenida la asignación de los estudiantes a los conglomerados, se procedió a caracterizar cada grupo a partir de sus preferencias por las materias optativas.

Para ello, se contabilizó la frecuencia con la que cada materia fue seleccionada por los estudiantes pertenecientes a cada conglomerado. Estas frecuencias permitieron identificar las materias con mayor presencia dentro de cada grupo.

Posteriormente, se calcularon los porcentajes correspondientes respecto al número total de estudiantes de cada conglomerado. Con esta información fue posible establecer un perfil de preferencias para cada grupo y utilizarlo como base para la propuesta de organización de las materias optativas. Finalmente, se compararon las soluciones de agrupamiento consideradas y se seleccionó aquella que proporcionara un equilibrio adecuado entre la calidad estadística del agrupamiento, el tamaño de los grupos y la interpretación de los perfiles de preferencias.

La solución seleccionada fue posteriormente utilizada como base para la propuesta de organización de las materias optativas presentada en el análisis.

7.2. Código utilizado

```
1 # PRACTICA 01 - ELECCION DE MATERIAS OPTATIVAS
2 # ANALISIS DESCRIPTIVO
3
4 # 1. PAQUETES
5
6 library(readxl)
7 library(dplyr)
8 library(tidyr)
9 library(ggplot2)
10 library(stringi)
11
12 # 2. IMPORTAR LA BASE
13
14 ruta <- "C:/Users/Garc a/Downloads/practica01elecciondeoptativasGrupo30.xlsx"
15
16 base <- read_excel(
17   ruta,
18   sheet = "Base completa de eleccion"
19 )
20
21 # 3. EXPLORACION GENERAL
22
23 # Dimensiones de la base
24 dim(base)
25
26 # Nombres de las variables
27 names(base)
28
29 # Estructura de la base
30 str(base)
31
32 # Primeros registros
33 head(base)
34
```

```
35 # Ultimos registros
36 tail(base)
37
38 # Resumen general
39 summary(base)
40
41 # 4. NUMERO DE ESTUDIANTES
42
43 n_individuos <- n_distinct(base$Individuo)
44 n_individuos
45
46 # 5. NUMERO DE REGISTROS
47
48 n_registros <- nrow(base)
49 n_registros
50
51
52 # 6. IMPORTACION Y REVISION DEL CATALOGO DE MATERIAS
53
54 # La hoja "materias" contiene el catalogo de referencia,
55 # donde se establece la relacion entre el nombre de la
56 # materia y su clave.
57
58 materias <- read_excel(
59   ruta,
60   sheet = "materias",
61   col_names = FALSE)
62
63 # Seleccion de las columnas del catalogo
64
65 # Las dos primeras columnas contienen el nombre de la materia y su clave. La hoja no cuenta con
66 # encabezados, por lo que la primera fila corresponde a una materia.
67
68 catalogo <- materias %>%
69   select(
70     Nombre_Oficial = 1,
71     Clave = 2
72   ) %>%
73   filter(
74     !is.na(Nombre_Oficial),
75     !is.na(Clave)
76   ) %>%
77   mutate(
78     Clave = as.character(Clave)
79   )
80
81 # Convertir la clave de la base a texto para garantizar
82 # que ambas fuentes tengan el mismo tipo de dato.
83
84 base <- base %>%
85   mutate(
86     Clave = as.character(Clave))
87
88 # Revisar el catalogo
89
90 # Numero de materias del catalogo
```

```
91 n_materias_catalogo <- nrow(catalogo)
92
93 n_materias_catalogo
94
95 # Mostrar el catalogo completo
96 catalogo
97
98 # 7. COMPARACION DE CLAVES ENTRE LA BASE Y EL CATALOGO
99
100 # Obtener las claves utilizadas en la base de elecciones
101 claves_base <- base %>%
102   distinct(Clave) %>%
103   filter(!is.na(Clave))
104
105 # Obtener las claves disponibles en el catalogo
106 claves_catalogo <- catalogo %>%
107   distinct(Clave) %>%
108   filter(!is.na(Clave))
109
110 # Claves de la base que no aparecen en el catalogo
111
112 claves_no_catalogo <- claves_base %>%
113   anti_join(
114     claves_catalogo,
115     by = "Clave")
116
117 claves_no_catalogo
118
119 # Claves del catalogo que no aparecen en la base
120
121 claves_no_utilizadas <- claves_catalogo %>%
122   anti_join(
123     claves_base,
124     by = "Clave")
125
126 claves_no_utilizadas
127
128
129 # 8. REVISION DE CLAVES FALTANTES
130
131 # Identificar registros de la base que no tienen clave
132
133 registros_sin_clave <- base %>%
134   filter(is.na(Clave))
135
136 registros_sin_clave
137
138
139
140 # 9. REVISION DE NOMBRES ASOCIADOS A CADA CLAVE
141
142 nombres_por_clave <- base %>%
143   group_by(Clave) %>%
144   summarise(
145     Numero_nombres = n_distinct('Nombre de la Materia'),
146     Nombres_registrados = paste(
147       unique('Nombre de la Materia'),
```

```

148     collapse = " | "
149   ),
150   Frecuencia = n(),
151   .groups = "drop"
152 ) %>%
153   arrange(desc(Numero_nombres))
154
155 nombres_por_clave
156
157 # Claves con diferentes nombres registrados
158
159 nombres_inconsistentes <- nombres_por_clave %>%
160   filter(Numero_nombres > 1)
161
162 nombres_inconsistentes
163
164
165 # 10. REVISION DETALLADA DE LAS INCONSISTENCIAS
166
167 # Identificar las claves que presentan mas de un nombre
168 # registrado en la base.
169
170 claves_problematicas <- nombres_inconsistentes %>%
171   arrange(desc(Numero_nombres)) %>%
172   pull(Clave)
173
174 claves_problematicas
175
176
177 # Registros asociados a las claves problematicas
178
179 registros_problematicos <- base %>%
180   filter(
181     Clave %in% claves_problematicas
182   ) %>%
183   select(
184     Individuo,
185     'Orden de preferencia',
186     Clave,
187     'Nombre de la Materia'
188   ) %>%
189   arrange(
190     Clave,
191     Individuo,
192     desc('Orden de preferencia')
193   )
194
195 registros_problematicos
196
197
198 # Revision de las claves con mayor numero de nombres
199
200 claves_mayor_inconsistencia <- nombres_inconsistentes %>%
201   arrange(desc(Numero_nombres)) %>%
202   slice_head(n = 5) %>%
203   select(
204     Clave,

```

```

205     Numero_nombres,
206     Frecuencia)
207
208 claves_mayor_inconsistencia
209
210
211 # Nombres registrados para las claves mas problematicas
212
213 base %>%
214   filter(
215     Clave %in% claves_mayor_inconsistencia$Clave
216   ) %>%
217   select(
218     Clave,
219     'Nombre de la Materia'
220   ) %>%
221   distinct() %>%
222   arrange(
223     Clave,
224     'Nombre de la Materia')
225
226
227
228 # Revision de claves que no aparecen en el catalogo
229
230 base %>%
231   filter(
232     Clave %in% claves_no_catalogo$Clave
233   ) %>%
234   select(
235     Individuo,
236     'Orden de preferencia',
237     Clave,
238     'Nombre de la Materia'
239   ) %>%
240   arrange(
241     Clave,
242     Individuo
243   )
244
245 # Busqueda de Econometria en el catalogo
246
247 catalogo %>%
248   filter(
249     grepl(
250       "econom",
251       Nombre_Oficial,
252       ignore.case = TRUE))
253
254
255 # 11. COMPARACION CON EL NOMBRE OFICIAL
256
257 # Incorporar temporalmente el nombre oficial de la materia a partir de la clave registrada en la
    base. Esta etapa es solamente de diagnostico y no modifica la base original.
258
259 revision_materias <- base %>%
260   left_join(

```

```
261     catalogo %>%
262     select(
263       Clave,
264       Nombre_Oficial
265     ),
266     by = "Clave"
267   )
268
269
270 # Normalizacion temporal de los nombres
271
272 # Se eliminan temporalmente diferencias de mayusculas, acentos, signos de puntuacion y espacios
273 # para determinar si dos nombres representan esencialmente el mismo texto.
274
275 normalizar_nombre <- function(x) {
276   x %>%
277     stri_trans_general("Latin-ASCII") %>%
278     tolower() %>%
279     gsub("[^a-z0-9 ]", " ", .) %>%
280     gsub("[0-9 ]+", " ", .) %>%
281     gsub("\\s+", " ", .) %>%
282     trimws()
283 }
284
285 # Aplicar la normalizacion temporal
286
287 revision_materias <- revision_materias %>%
288   mutate(
289     Nombre_Capturado_Normalizado =
290       normalizar_nombre(Nombre de la Materia'),
291     Nombre_Oficial_Normalizado =
292       normalizar_nombre(Nombre_Oficial)
293   )
294
295 # Comparacion entre nombre capturado y nombre oficial
296
297 revision_materias <- revision_materias %>%
298   mutate(
299     Coincidencia_Nombre =
300       Nombre_Capturado_Normalizado ==
301       Nombre_Oficial_Normalizado)
302
303 # Revisar el resultado
304
305 revision_materias
306
307
308 # 12. IDENTIFICACION DE INCONSISTENCIAS
309
310 # Mostrar los registros en los que el nombre capturado no coincide con el nombre oficial asociado
311 # a la clave.
312
313 inconsistencias_nombre <- revision_materias %>%
314   filter(
315     !is.na(Nombre_Oficial),
316     !Coincidencia_Nombre
```

```
316   ) %>%
317   select(
318     Individuo,
319     'Orden de preferencia',
320     Clave,
321     'Nombre de la Materia',
322     Nombre_Oficial
323   ) %>%
324   arrange(
325     Clave,
326     Individuo)
327
328 inconsistencias_nombre
329
330
331 # 13. RESUMEN DE INCONSISTENCIAS POR CLAVE
332
333 resumen_inconsistencias <- inconsistencias_nombre %>%
334   group_by(
335     Clave,
336     Nombre_Oficial
337   ) %>%
338   summarise(
339     Numero_registros = n(),
340     Nombres_capturados = paste(
341       unique('Nombre de la Materia'),
342       collapse = " | "
343     ),
344     .groups = "drop"
345   ) %>%
346   arrange(
347     Clave,
348     desc(Numero_registros))
349
350 resumen_inconsistencias
351
352
353 # 14. FRECUENCIA DE NOMBRES POR CLAVE
354
355 # Contabilizar cuantas veces aparece cada nombre de materia
356 # dentro de cada clave.
357
358 frecuencia_nombre_clave <- base %>%
359   filter(
360     !is.na(Clave),
361     !is.na('Nombre de la Materia')
362   ) %>%
363   count(
364     Clave,
365     'Nombre de la Materia',
366     sort = TRUE,
367     name = "Frecuencia")
368
369 # Revisar los nombres registrados para cada clave
370 # junto con su frecuencia.
371
372 frecuencia_nombre_clave
```

```
373
374
375 # Frecuencia de nombres en claves inconsistentes
376
377 frecuencia_nombre_clave_problematicas <- frecuencia_nombre_clave %>%
378   filter(
379     Clave %in% nombres_inconsistentes$Clave
380   ) %>%
381   arrange(
382     Clave,
383     desc(Frecuencia))
384
385 frecuencia_nombre_clave_problematicas
386
387
388 # Nombres mas frecuentes por clave
389
390 nombre_mas_frecuente <- frecuencia_nombre_clave_problematicas %>%
391   group_by(Clave) %>%
392   slice_max(
393     Frecuencia,
394     n = 3,
395     with_ties = TRUE
396   ) %>%
397   ungroup()
398
399 nombre_mas_frecuente
400
401
402 # 15. CONSOLIDACION TEMPORAL DE VARIANTES DE NOMBRE
403
404 # Agrupar las diferentes formas de escritura de una misma
405 # materia utilizando el nombre normalizado.
406
407 frecuencia_nombre_normalizado <- base %>%
408   filter(
409     !is.na(Clave),
410     !is.na('Nombre de la Materia')
411   ) %>%
412   mutate(
413     Nombre_Normalizado =
414       normalizar_nombre('Nombre de la Materia')
415   ) %>%
416   count(
417     Clave,
418     Nombre_Normalizado,
419     sort = TRUE,
420     name = "Frecuencia")
421
422 # Revisar las variantes normalizadas
423
424 frecuencia_nombre_normalizado
425
426
427 # Principales nombres normalizados por clave
428
429 nombre_normalizado_principal <- frecuencia_nombre_normalizado %>%
```



```
430   group_by(Clave) %>%
431   slice_max(
432     Frecuencia,
433     n = 3,
434     with_ties = TRUE
435   ) %>%
436   ungroup()
437
438 nombre_normalizado_principal
439
440
441 # 16. COMPARACION DEL NOMBRE NORMALIZADO CON EL CATALOGO
442
443 # Comparar el nombre normalizado capturado con el nombre normalizado oficial del catalogo.
444
445 revision_normalizada <- revision_materias %>%
446   mutate(
447     Coincidencia_Normalizada =
448       Nombre_Capturado_Normalizado ==
449       Nombre_Oficial_Normalizado)
450
451 # Resumen de coincidencias
452
453 table(
454   revision_normalizada$Coincidencia_Normalizada,
455   useNA = "ifany"
456 )
457
458
459 # 17. ANALISIS DE LOS REGISTROS QUE NO COINCIDEN
460
461 # Identificar los registros que no coinciden con el nombre
462 # oficial despues de la normalizacion.
463
464 registros_no_coincidentes <- revision_normalizada %>%
465   filter(
466     Coincidencia_Normalizada == FALSE
467   ) %>%
468   select(
469     Individuo,
470     'Orden de preferencia',
471     Clave,
472     'Nombre de la Materia',
473     Nombre_Oficial
474   ) %>%
475   arrange(
476     Clave,
477     Individuo
478   )
479
480 registros_no_coincidentes
481
482
483
484 # Frecuencia de inconsistencias por clave
485
486 frecuencia_no_coincidentes <- registros_no_coincidentes %>%
```

```
487   count(
488     Clave,
489     'Nombre de la Materia',
490     Nombre_Oficial,
491     sort = TRUE,
492     name = "Frecuencia"
493   )
494
495 frecuencia_no_coincidentes
496
497
498 # Numero de inconsistencias por clave
499
500 resumen_no_coincidentes <- registros_no_coincidentes %>%
501   count(
502     Clave,
503     sort = TRUE,
504     name = "Numero_inconsistencias"
505   )
506
507 resumen_no_coincidentes
508
509
510
511 # 18. HOMOLOGACION DE LOS NOMBRES DE LAS MATERIAS
512
513 # La homologacion se realiza tomando como referencia el
514 # nombre oficial de las materias incluido en el catalogo. El nombre de la materia es la referencia
    principal para identificar y estandarizar cada asignatura, de acuerdo con la revision
    realizada de la base de datos.
515
516
517 # Crear la variable con el nombre homologado
518
519 base_limpia <- revision_materias %>%
520   mutate(
521     Nombre_Materia_Limpio = Nombre_Oficial)
522
523 # Revisar los primeros registros
524 head(base_limpia)
525
526 # Registros sin nombre oficial en el catalogo
527
528 registros_sin_nombre_oficial <- base_limpia %>%
529   filter(
530     is.na(Nombre_Materia_Limpio)
531   ) %>%
532   select(
533     Individuo,
534     'Orden de preferencia',
535     Clave,
536     'Nombre de la Materia')
537
538 registros_sin_nombre_oficial
539
540
541 # 19. HOMOLOGACION DE MATERIAS SIN CLAVE EN EL CATALOGO
```

```

542
543 # Para los registros cuya clave no permite obtener un nombre oficial, se utiliza el nombre de la
    materia registrado en la base como referencia para identificar la asignatura.
544
545
546 # Normalizar los nombres del catalogo
547
548 catalogo_normalizado <- catalogo %>%
549   mutate(
550     Nombre_Oficial_Normalizado =
551       normalizar_nombre(Nombre_Oficial))
552
553 # Buscar el nombre oficial a partir del nombre capturado
554
555 base_limpia <- base_limpia %>%
556   left_join(
557     catalogo_normalizado %>%
558       select(
559         Nombre_Oficial_Normalizado,
560         Nombre_Oficial
561       ),
562     by = c(
563       "Nombre_Capturado_Normalizado" =
564       "Nombre_Oficial_Normalizado"
565     ),
566     suffix = c("", "_por_nombre"))
567
568
569 # Seleccionar el nombre definitivo de la materia
570
571 # Si la clave permitio identificar la materia, se conserva el nombre oficial obtenido mediante la
    clave. Si la clave no permitio identificarla, se utiliza el nombre oficial obtenido mediante
    el nombre capturado.
572
573 base_limpia <- base_limpia %>%
574   mutate(
575     Nombre_Materia_Limpio = coalesce(
576       Nombre_Materia_Limpio,
577       Nombre_Oficial_por_nombre
578     ))
579
580 # Revisar los registros que aun no pudieron homologarse
581
582 registros_sin_homologar <- base_limpia %>%
583   filter(
584     is.na(Nombre_Materia_Limpio)
585   ) %>%
586   select(
587     Individuo,
588     'Orden de preferencia',
589     Clave,
590     'Nombre de la Materia')
591
592 registros_sin_homologar
593
594
595 # 20. CORRECCION DE LOS ULTIMOS REGISTROS SIN HOMOLOGAR

```

```

596
597 # Los registros restantes presentan errores de captura en el nombre de la materia. Debido a que el
    nombre permite identificar la asignatura, se homologan tomando como referencia el catalogo
    oficial.
598
599
600 # Correccion final de Economia Matematica II y Econometria
601
602 base_limpia <- base_limpia %>%
603   mutate(
604     Nombre_Materia_Limpio = case_when(
605
606       # Homologar cualquier variante de Economia Matematica II
607       normalizar_nombre(Nombre_Materia_Limpio) ==
608         "economia matematica ii" ~
609         "Econom a Matem tica II",
610
611       # Homologar Econometria
612       normalizar_nombre(Nombre_Materia_Limpio) ==
613         "econometria" ~
614         "An lisis Econom trico",
615
616       # Mantener los demas nombres ya homologados
617       TRUE ~ Nombre_Materia_Limpio
618     )
619   )
620
621
622 # Verificar nuevamente los registros sin homologar
623
624 registros_sin_homologar <- base_limpia %>%
625   filter(
626     is.na(Nombre_Materia_Limpio)
627   ) %>%
628   select(
629     Individuo,
630     'Orden de preferencia',
631     Clave,
632     'Nombre de la Materia'
633   )
634
635 registros_sin_homologar
636
637
638 # Correccion de Analisis Econometrico
639
640 base_limpia <- base_limpia %>%
641   mutate(
642     Nombre_Materia_Limpio = case_when(
643
644       normalizar_nombre('Nombre de la Materia') ==
645         "analisis econometrico" ~
646         "An lisis Econom trico",
647
648       TRUE ~ Nombre_Materia_Limpio
649     ))
650

```

```
651 # Verificar duplicados por estudiante y materia
652
653 duplicados_materia <- base_limpia %>%
654   count(
655     Individuo,
656     Nombre_Materia_Limpio,
657     name = "Frecuencia"
658   ) %>%
659   filter(Frecuencia > 1)
660
661 duplicados_materia
662
663
664
665 # 21. REVISION FINAL DE LA BASE LIMPIA
666
667 # Revisar la estructura de la base limpia
668 str(base_limpia)
669
670 # Revisar las primeras observaciones
671 head(base_limpia)
672
673 # Numero de estudiantes
674 n_distinct(base_limpia$Individuo)
675
676 # Numero de registros
677 nrow(base_limpia)
678
679 # Numero de materias oficiales
680 n_distinct(base_limpia$Nombre_Materia_Limpio)
681
682 # Materias utilizadas y su frecuencia
683 frecuencia_materias <- base_limpia %>%
684   count(
685     Nombre_Materia_Limpio,
686     sort = TRUE,
687     name = "Frecuencia"
688   )
689
690 frecuencia_materias
691
692
693 # 22. ANALISIS DESCRIPTIVO DE LA BASE LIMPIA
694
695
696 # Distribucion del orden de preferencia
697
698 frecuencia_preferencia_limpia <- base_limpia %>%
699   count(
700     'Orden de preferencia',
701     name = "Frecuencia"
702   ) %>%
703   arrange('Orden de preferencia')
704
705 frecuencia_preferencia_limpia
706
707
```

```
708 # Porcentaje de cada nivel de preferencia
709
710 frecuencia_preferencia_limpia <- frecuencia_preferencia_limpia %>%
711   mutate(
712     Porcentaje = Frecuencia / sum(Frecuencia) * 100)
713
714 frecuencia_preferencia_limpia
715
716
717 # Estadísticos del orden de preferencia
718
719 estadisticos_preferencia_limpia <- base_limpia %>%
720   summarise(
721     Media = mean(
722       'Orden de preferencia',
723       na.rm = TRUE
724     ),
725     Mediana = median(
726       'Orden de preferencia',
727       na.rm = TRUE
728     ),
729     Desviacion_Estandar = sd(
730       'Orden de preferencia',
731       na.rm = TRUE
732     ),
733     Minimo = min(
734       'Orden de preferencia',
735       na.rm = TRUE
736     ),
737     Maximo = max(
738       'Orden de preferencia',
739       na.rm = TRUE))
740
741 estadisticos_preferencia_limpia
742
743
744 # Numero de preferencias por estudiante
745
746 preferencias_por_estudiante_limpia <- base_limpia %>%
747   count(
748     Individuo,
749     name = "Numero_preferencias")
750
751 preferencias_por_estudiante_limpia
752
753
754 # Frecuencia de estudiantes segun numero de preferencias
755
756 frecuencia_preferencias_limpia <- preferencias_por_estudiante_limpia %>%
757   count(
758     Numero_preferencias,
759     name = "Frecuencia"
760   ) %>%
761   arrange(Numero_preferencias)
762
763 frecuencia_preferencias_limpia
764
```

```
765
766 # Porcentaje de estudiantes
767
768 frecuencia_preferencias_limpia <- frecuencia_preferencias_limpia %>%
769   mutate(
770     Porcentaje = Frecuencia / sum(Frecuencia) * 100
771   )
772
773 frecuencia_preferencias_limpia
774
775
776 # Frecuencia de solicitud de las materias
777
778 frecuencia_materias_limpia <- base_limpia %>%
779   count(
780     Nombre_Materia_Limpio,
781     sort = TRUE,
782     name = "Frecuencia"
783   )
784
785 frecuencia_materias_limpia
786
787
788 # Materias mas solicitadas
789
790 materias_mas_solicitadas <- frecuencia_materias_limpia %>%
791   slice_head(n = 10)
792
793 materias_mas_solicitadas
794
795
796 # Materias menos solicitadas
797
798 materias_menos_solicitadas <- frecuencia_materias_limpia %>%
799   slice_tail(n = 10)
800
801 materias_menos_solicitadas
802
803
804
805 # 15. GRAFICAS DEL ANALISIS DESCRIPTIVO
806
807 # Distribucion del orden de preferencia
808
809 grafica_preferencia <- ggplot(
810   frecuencia_preferencia_limpia,
811   aes(
812     x = factor('Orden de preferencia'),
813     y = Frecuencia
814   )
815 ) +
816   geom_col(
817     width = 0.65
818   ) +
819   geom_text(
820     aes(label = Frecuencia),
821     vjust = -0.4,
```

```

822   size = 4
823 ) +
824 scale_y_continuous(
825   expand = expansion(mult = c(0, 0.08))
826 ) +
827 labs(
828   title = "Distribuci n del orden de preferencia",
829   subtitle = "Frecuencia de registros por nivel de preferencia",
830   x = "Orden de preferencia",
831   y = "N mero de registros"
832 ) +
833 theme_minimal(base_size = 12) +
834 theme(
835   plot.title = element_text(
836     face = "bold",
837     size = 15,
838     hjust = 0.5
839   ),
840   plot.subtitle = element_text(
841     size = 11,
842     hjust = 0.5
843   ),
844   axis.title = element_text(
845     face = "bold"
846   ),
847   panel.grid.major.x = element_blank(),
848   panel.grid.minor = element_blank()
849 )
850
851 grafica_preferencia
852
853
854 # Numero de preferencias registradas por estudiante
855
856 grafica_preferencias_estudiante <- ggplot(
857   frecuencia_preferencias_limpia,
858   aes(
859     x = factor(Numero_preferencias),
860     y = Frecuencia
861   )
862 ) +
863   geom_col(
864     width = 0.65
865   ) +
866   geom_text(
867     aes(label = paste0(
868       Frecuencia,
869       " (",
870       round(Porcentaje, 1),
871       "%)"
872     )),
873     vjust = -0.4,
874     size = 4
875   ) +
876   scale_y_continuous(
877     expand = expansion(mult = c(0, 0.12))
878   ) +

```



```

879 labs(
880   title = "N mero de preferencias registradas por estudiante",
881   subtitle = "Distribuci n de estudiantes seg n el n mero de elecciones realizadas",
882   x = "N mero de preferencias",
883   y = "N mero de estudiantes"
884 ) +
885 theme_minimal(base_size = 12) +
886 theme(
887   plot.title = element_text(
888     face = "bold",
889     size = 15,
890     hjust = 0.5
891   ),
892   plot.subtitle = element_text(
893     size = 11,
894     hjust = 0.5
895   ),
896   axis.title = element_text(
897     face = "bold"
898   ),
899   panel.grid.major.x = element_blank(),
900   panel.grid.minor = element_blank()
901 )
902
903 grafica_preferencias_estudiante
904
905
906 # Materias mas solicitadas
907
908 grafica_materias_mas <- ggplot(
909   materias_mas_solicitadas,
910   aes(
911     x = reorder(Nombre_Materia_Limpio, Frecuencia),
912     y = Frecuencia
913   )
914 ) +
915   geom_col(
916     width = 0.7
917   ) +
918   geom_text(
919     aes(label = Frecuencia),
920     hjust = -0.25,
921     size = 3.8
922   ) +
923   coord_flip() +
924   scale_y_continuous(
925     expand = expansion(mult = c(0, 0.10))
926   ) +
927   labs(
928     title = "Materias con mayor frecuencia de elecci n",
929     subtitle = "Diez materias con mayor n mero de selecciones",
930     x = NULL,
931     y = "N mero de selecciones"
932   ) +
933   theme_minimal(base_size = 12) +
934   theme(
935     plot.title = element_text(

```

```

936     face = "bold",
937     size = 15,
938     hjust = 0.5
939   ),
940   plot.subtitle = element_text(
941     size = 11,
942     hjust = 0.5
943   ),
944   axis.title.y = element_blank(),
945   axis.title.x = element_text(
946     face = "bold"
947   ),
948   panel.grid.major.y = element_blank(),
949   panel.grid.minor = element_blank()
950 )
951
952 grafica_materias_mas
953
954
955
956
957
958 # Materias menos solicitadas
959
960 grafica_materias_menos <- ggplot(
961   materias_menos_solicitadas,
962   aes(
963     x = reorder(Nombre_Materia_Limpio, Frecuencia),
964     y = Frecuencia
965   )
966 ) +
967   geom_col(
968     width = 0.7
969   ) +
970   geom_text(
971     aes(label = Frecuencia),
972     hjust = -0.25,
973     size = 3.8
974   ) +
975   coord_flip() +
976   scale_y_continuous(
977     expand = expansion(mult = c(0, 0.15))
978   ) +
979   labs(
980     title = "Materias con menor frecuencia de elecc i n",
981     subtitle = "Diez materias con menor n mero de selecciones",
982     x = NULL,
983     y = "N mero de selecciones"
984   ) +
985   theme_minimal(base_size = 12) +
986   theme(
987     plot.title = element_text(
988       face = "bold",
989       size = 15,
990       hjust = 0.5
991     ),
992     plot.subtitle = element_text(

```

```
993     size = 11,
994     hjust = 0.5
995   ),
996   axis.title.x = element_text(
997     face = "bold"
998   ),
999   panel.grid.major.y = element_blank(),
1000  panel.grid.minor = element_blank()
1001 )
1002
1003 grafica_materias_menos
1004
1005
1006
1007 # Frecuencia de las 27 materias
1008
1009 materias_ordenadas <- frecuencia_materias_limpia %>%
1010   arrange(Frecuencia) %>%
1011   mutate(
1012     Nombre_Materia_Limpio = factor(
1013       Nombre_Materia_Limpio,
1014       levels = Nombre_Materia_Limpio
1015     )
1016   )
1017
1018
1019 grafica_27_materias <- ggplot(
1020   materias_ordenadas,
1021   aes(
1022     x = Nombre_Materia_Limpio,
1023     y = Frecuencia
1024   )
1025 ) +
1026   geom_col(
1027     width = 0.7
1028   ) +
1029   geom_text(
1030     aes(label = Frecuencia),
1031     hjust = -0.25,
1032     size = 3.2
1033   ) +
1034   coord_flip() +
1035   scale_y_continuous(
1036     expand = expansion(mult = c(0, 0.08))
1037   ) +
1038   labs(
1039     title = "Frecuencia de elecci n de las materias",
1040     subtitle = "N mero de selecciones registradas para cada materia",
1041     x = NULL,
1042     y = "N mero de selecciones"
1043   ) +
1044   theme_minimal(base_size = 11) +
1045   theme(
1046     plot.title = element_text(
1047       face = "bold",
1048       size = 15,
1049       hjust = 0.5
```

```
1050     ),
1051     plot.subtitle = element_text(
1052       size = 11,
1053       hjust = 0.5
1054     ),
1055     axis.text.y = element_text(
1056       size = 9
1057     ),
1058     axis.title.x = element_text(
1059       face = "bold"
1060     ),
1061     panel.grid.major.y = element_blank(),
1062     panel.grid.minor = element_blank()
1063   )
1064
1065   grafica_27_materias
1066
1067
1068   # 16. EXPORTACION DE GRAFICAS
1069
1070   ggsave(
1071     "distribucion_preferencia.png",
1072     grafica_preferencia,
1073     width = 8,
1074     height = 5.5,
1075     dpi = 300
1076   )
1077
1078   ggsave(
1079     "preferencias_por_estudiante.png",
1080     grafica_preferencias_estudiante,
1081     width = 8,
1082     height = 5.5,
1083     dpi = 300
1084   )
1085
1086   ggsave(
1087     "materias_mas_solicitadas.png",
1088     grafica_materias_mas,
1089     width = 9,
1090     height = 6,
1091     dpi = 300
1092   )
1093
1094   ggsave(
1095     "materias_menos_solicitadas.png",
1096     grafica_materias_menos,
1097     width = 9,
1098     height = 6,
1099     dpi = 300
1100   )
1101
1102   ggsave(
1103     "frecuencia_27_materias.png",
1104     grafica_27_materias,
1105     width = 10,
1106     height = 9,
```

```

1107   dpi = 300
1108 )
1109
1110
1111
1112 # 21. ANALISIS DE CONGLOMERADOS
1113
1114 # CORRECCION FINAL DEL REGISTRO DUPLICADO
1115
1116 # El estudiante 67 aparece dos veces con la misma materia homologada. Se corrige utilizando el
1117   nombre original de la materia como referencia.
1118
1119 base_limpia <- base_limpia %>%
1120   mutate(
1121     Nombre_Materia_Limpio = case_when(
1122       Individuo == 67 &
1123         normalizar_nombre('Nombre de la Materia') ==
1124           "análisis econométrico" ~
1125           "Análisis Económico",
1126       TRUE ~ Nombre_Materia_Limpio
1127     ))
1128
1129
1130 # VERIFICAR DUPLICADOS
1131
1132 duplicados_materia <- base_limpia %>%
1133   count(
1134     Individuo,
1135     Nombre_Materia_Limpio,
1136     name = "Frecuencia"
1137   ) %>%
1138   filter(Frecuencia > 1)
1139
1140 duplicados_materia
1141
1142
1143 # CONSTRUCCION DE LA MATRIZ DE PREFERENCIAS
1144
1145 matriz_preferencias <- base_limpia %>%
1146   select(
1147     Individuo,
1148     Nombre_Materia_Limpio,
1149     'Orden de preferencia'
1150   ) %>%
1151   pivot_wider(
1152     names_from = Nombre_Materia_Limpio,
1153     values_from = 'Orden de preferencia',
1154     values_fill = 0)
1155
1156 # Revisar dimensiones
1157 dim(matriz_preferencias)
1158
1159 # Revisar matriz
1160 matriz_preferencias
1161
1162 # PREPARACION DE LOS DATOS PARA K-MEANS

```

```
1163
1164 datos_kmeans <- matriz_preferencias %>%
1165   select(-Individuo)
1166
1167 # Estructura
1168 str(datos_kmeans)
1169
1170 # Dimensiones
1171 dim(datos_kmeans)
1172
1173 # Valores faltantes
1174 sum(is.na(datos_kmeans))
1175
1176
1177 # DENDROGRAMA Y CARAS DE CHERNOFF
1178
1179 # DENDROGRAMA DEL ANALISIS JERARQUICO
1180
1181 # Distancia euclidiana
1182 distancias <- dist(
1183   datos_kmeans,
1184   method = "euclidean")
1185
1186 # Agrupamiento jerarquico con liga promedio
1187 hc <- hclust(
1188   distancias,
1189   method = "average")
1190
1191 plot(
1192   hc,
1193   labels = 1:124,
1194   hang = -1,
1195   cex = 0.55,
1196   main = "Dendrograma del analisis jerarquico",
1197   xlab = "Estudiantes",
1198   ylab = "Distancia")
1199
1200
1201
1202 # ANALISIS DE CONGLOMERADOS JERARQUICO
1203
1204 # Calcular matriz de distancias
1205
1206 distancias_hc <- dist(
1207   datos_kmeans,
1208   method = "euclidean")
1209
1210
1211 # Aplicar agrupamiento jerarquico: Metodo de enlace promedio (average)
1212
1213 hc <- hclust(
1214   distancias_hc,
1215   method = "average")
1216
1217 # Mostrar el dendrograma
1218
1219 plot(
```

```
1220 hc,
1221 labels = matriz_preferencias$Individuo,
1222 hang = 0.1,
1223 cex = 0.55,
1224 main = "Dendrograma del análisis jerárquico",
1225 xlab = "Estudiantes",
1226 ylab = "Distancia")
1227
1228
1229 # Guardar el dendrograma como imagen PNG
1230
1231 png(
1232   filename = "C:/Users/García/Downloads/dendrograma.png",
1233   width = 1700,
1234   height = 900,
1235   res = 150)
1236
1237 plot(
1238   hc,
1239   labels = matriz_preferencias$Individuo,
1240   hang = 0.1,
1241   cex = 0.55,
1242   main = "Dendrograma del análisis jerárquico",
1243   xlab = "Estudiantes",
1244   ylab = "Distancia")
1245
1246 dev.off()
1247
1248
1249
1250 # CARAS DE CHERNOFF
1251
1252 # Instalar y cargar paquete
1253 if (!require(aplpack)) {
1254   install.packages("aplpack")
1255   library(aplpack)
1256 } else {
1257   library(aplpack)
1258 }
1259
1260
1261 # PREPARAR LA MATRIZ DE MATERIAS
1262
1263 # Eliminar la columna "Individuo"
1264 # Esta columna no corresponde a una materia
1265
1266 datos_materias <- matriz_preferencias[
1267   ,
1268   !colnames(matriz_preferencias) %in% "Individuo",
1269   drop = FALSE
1270 ]
1271
1272
1273 # Revisar dimensiones
1274
1275 print(dim(datos_materias))
1276
```

```
1277
1278 # CONTAR LAS PREFERENCIAS POR MATERIA
1279
1280 preferencias_caras <- sapply(1:5, function(p) {
1281
1282   apply(datos_materias, 2, function(x) {
1283     sum(x == p, na.rm = TRUE)
1284   })
1285 })
1286
1287
1288 # Convertir a matriz
1289
1290 preferencias_caras <- as.matrix(preferencias_caras)
1291
1292
1293 # NOMBRAR LAS VARIABLES
1294
1295 colnames(preferencias_caras) <- c(
1296   "Primer lugar",
1297   "Segundo lugar",
1298   "Tercer lugar",
1299   "Cuarto lugar",
1300   "Quinto lugar"
1301 )
1302
1303
1304 # Los nombres de las materias seran los nombres de las filas
1305
1306 rownames(preferencias_caras) <- colnames(datos_materias)
1307
1308
1309 # REVISAR LOS RESULTADOS
1310
1311 print(preferencias_caras)
1312
1313
1314 # CONVERTIR A DATA FRAME
1315
1316 datos_caras <- as.data.frame(preferencias_caras)
1317
1318 # Nombres de las materias
1319
1320 nombres_materias <- rownames(preferencias_caras)
1321
1322
1323 # Revisar numero de materias
1324 cat("\n===== \n")
1325 cat("N MERO DE MATERIAS\n")
1326 cat("===== \n")
1327
1328 cat("Materias utilizadas:",
1329     nrow(datos_caras), "\n")
1330
1331
1332 # 6. GENERAR LAS CARAS DE CHERNOFF
1333
```



```
1334 faces(  
1335   datos_caras,  
1336   face.type = 1,  
1337   nrow.plot = 5,  
1338   ncol.plot = 6,  
1339   scale = TRUE,  
1340   byrow = FALSE,  
1341   main = "Caras de Chernoff - Popularidad de las materias por lugar de preferencia",  
1342   labels = nombres_materias,  
1343   print.info = FALSE,  
1344   cex = 0.7  
1345 )  
1346  
1347  
1348 # 7. GUARDAR LA GRAFICA EN PNG  
1349  
1350 png(  
1351   filename = "caras_chernoff_materias.png",  
1352   width = 1800,  
1353   height = 1400,  
1354   res = 180)  
1355  
1356  
1357 faces(  
1358   datos_caras,  
1359   face.type = 1,  
1360   nrow.plot = 5,  
1361   ncol.plot = 6,  
1362   scale = TRUE,  
1363   byrow = FALSE,  
1364   main = "Caras de Chernoff - Popularidad de las materias por lugar de preferencia",  
1365   labels = nombres_materias,  
1366   print.info = FALSE,  
1367   cex = 0.7)  
1368  
1369  
1370 dev.off()  
1371  
1372  
1373 # ANALISIS DE CONGLOMERADOS K-MEANS  
1374  
1375 # METODO DEL CODO  
1376  
1377 set.seed(123)  
1378  
1379 wss <- numeric(4)  
1380  
1381 for (k in 2:5) {  
1382  
1383   modelo <- kmeans(  
1384     datos_kmeans,  
1385     centers = k,  
1386     nstart = 100)  
1387  
1388   wss[k - 1] <- modelo$tot.withinss  
1389 }  
1390
```

```
1391 resultados_codo <- data.frame(  
1392   Numero_Conglomerados = 2:5,  
1393   WSS = wss)  
1394  
1395 resultados_codo  
1396  
1397 # Grafica del codo  
1398  
1399 grafica_codo <- ggplot(  
1400   resultados_codo,  
1401   aes(  
1402     x = Numero_Conglomerados,  
1403     y = WSS  
1404   )  
1405 ) +  
1406   geom_line() +  
1407   geom_point(size = 3) +  
1408   scale_x_continuous(  
1409     breaks = 2:5  
1410   ) +  
1411   labs(  
1412     title = "M todo del codo para determinar el n mero de conglomerados",  
1413     x = "N mero de conglomerados (k)",  
1414     y = "Suma de cuadrados intra-conglomerado (WSS)"  
1415   ) +  
1416   theme_minimal(base_size = 12) +  
1417   theme(  
1418     plot.title = element_text(  
1419       face = "bold",  
1420       size = 15,  
1421       hjust = 0.5  
1422     )  
1423   )  
1424  
1425 grafica_codo  
1426  
1427  
1428 # MODELOS K-MEANS DEFINITIVOS  
1429  
1430 # Se generan una sola vez los modelos para K = 2, 3, 4 y 5. Todos los analisis posteriores  
1431   utilizaran estos mismos modelos.  
1432  
1433 set.seed(123)  
1434  
1435 modelos_kmeans <- list()  
1436  
1437 for (k in 2:5) {  
1438   modelos_kmeans[[paste0("k", k)]] <- kmeans(  
1439     datos_kmeans,  
1440     centers = k,  
1441     nstart = 100  
1442   )  
1443 }  
1444  
1445  
1446 # TAMANO DE LOS CONGLOMERADOS
```

```

1447
1448 comparar_tamamos <- function(k) {
1449
1450     modelo <- modelos_kmeans[[paste0("k", k)]]
1451
1452     tabla <- as.data.frame(
1453         table(modelo$cluster)
1454     )
1455
1456     names(tabla) <- c(
1457         "Conglomerado",
1458         "Estudiantes"
1459     )
1460
1461     tabla %>%
1462         mutate(
1463             Conglomerado = as.integer(
1464                 as.character(Conglomerado)
1465             ),
1466             Estudiantes = as.integer(
1467                 Estudiantes
1468             ),
1469             Porcentaje = round(
1470                 Estudiantes / sum(Estudiantes) * 100,
1471                 1
1472             ),
1473             K = k
1474         )
1475 }
1476
1477 tamanos_k4 <- comparar_tamamos(4)
1478 tamanos_k5 <- comparar_tamamos(5)
1479
1480 cat("\n===== \n")
1481 cat("TAMA OS DE LOS CONGLOMERADOS - K = 4 \n")
1482 cat("===== \n")
1483
1484 print(tamanos_k4)
1485
1486 cat("\n===== \n")
1487 cat("TAMA OS DE LOS CONGLOMERADOS - K = 5 \n")
1488 cat("===== \n")
1489
1490 print(tamanos_k5)
1491
1492
1493 # COEFICIENTE DE SILUETA
1494
1495 library(cluster)
1496
1497 distancias <- dist(datos_kmeans)
1498
1499 sil_k4 <- silhouette(
1500     modelos_kmeans$k4$cluster,
1501     distancias)
1502
1503 sil_k5 <- silhouette(

```

```

1504   modelos_kmeans$k5$cluster,
1505   distancias)
1506
1507 promedio_sil_k4 <- mean(
1508   sil_k4[, 3])
1509
1510 promedio_sil_k5 <- mean(
1511   sil_k5[, 3])
1512
1513 comparacion_silueta <- data.frame(
1514   Conglomerados = c(4, 5),
1515   Silhouette_Promedio = c(
1516     promedio_sil_k4,
1517     promedio_sil_k5))
1518
1519
1520 cat("\n===== \n")
1521 cat("COMPARACION DEL COEFICIENTE DE SILUETA \n")
1522 cat("===== \n")
1523
1524 print(comparacion_silueta)
1525
1526
1527 # Grafica de silueta
1528
1529 resultados_silueta <- data.frame(
1530   Numero_Conglomerados = 2:5,
1531   Silhouette_Promedio = NA)
1532
1533
1534 for (k in 2:5) {
1535
1536   modelo <- modelos_kmeans[[paste0("k", k)]]
1537
1538   sil <- silhouette(
1539     modelo$cluster,
1540     distancias
1541   )
1542
1543   resultados_silueta$Silhouette_Promedio[
1544     resultados_silueta$Numero_Conglomerados == k
1545   ] <- mean(sil[, 3])
1546 }
1547
1548
1549 resultados_silueta
1550
1551
1552 grafica_silueta <- ggplot(
1553   resultados_silueta,
1554   aes(
1555     x = Numero_Conglomerados,
1556     y = Silhouette_Promedio
1557   )
1558 ) +
1559   geom_line() +
1560   geom_point(size = 3) +

```

```

1561   scale_x_continuous(
1562     breaks = 2:5
1563   ) +
1564   labs(
1565     title = "Coeficiente de silueta para diferentes n meros de conglomerados",
1566     x = "N mero de conglomerados (k)",
1567     y = "Coeficiente de silueta promedio"
1568   ) +
1569   theme_minimal(base_size = 12) +
1570   theme(
1571     plot.title = element_text(
1572       face = "bold",
1573       size = 15,
1574       hjust = 0.5
1575     )
1576   )
1577
1578 grafica_silueta
1579
1580
1581 # MATERIAS RELEVANTES POR CONGLOMERADO
1582
1583 # Criterios establecidos por el profesor:
1584 #
1585 # 1. No mas de 5 conglomerados.
1586 # 2. No mas de 5 materias por conglomerado.
1587 # 3. Una materia se considera relevante unicamente
1588 #     si fue seleccionada por al menos 5 estudiantes
1589 #     dentro del conglomerado.
1590
1591
1592 obtener_materias_relevantes <- function(k) {
1593
1594   modelo <- modelos_kmeans[[paste0("k", k)]]
1595
1596   # Crear base con estudiante y conglomerado
1597
1598   datos <- matriz_preferencias %>%
1599     select(Individuo) %>%
1600     mutate(
1601       Conglomerado = modelo$cluster
1602     ) %>%
1603     bind_cols(datos_kmeans)
1604
1605   # Convertir a formato largo
1606
1607   datos_largos <- datos %>%
1608     pivot_longer(
1609       cols = all_of(colnames(datos_kmeans)),
1610       names_to = "Nombre_Materia_Limpio",
1611       values_to = "Preferencia"
1612     )
1613
1614   # Tamano de cada conglomerado
1615
1616   tamanos <- datos %>%
1617     count(

```

```
1618     Conglomerado ,
1619     name = "Total_Estudiantes"
1620 )
1621
1622
1623 # Numero de estudiantes que seleccionaron cada materia
1624
1625 materias <- datos_largos %>%
1626   filter(
1627     Preferencia > 0
1628   ) %>%
1629   group_by(
1630     Conglomerado ,
1631     Nombre_Materia_Limpio
1632   ) %>%
1633   summarise(
1634     Estudiantes = n_distinct(Individuo),
1635     .groups = "drop"
1636   ) %>%
1637   left_join(
1638     tamanos ,
1639     by = "Conglomerado"
1640   ) %>%
1641   mutate(
1642     Porcentaje = round(
1643       Estudiantes / Total_Estudiantes * 100,
1644       1))
1645
1646 # Aplicar criterios del profesor
1647
1648 materias_relevantes <- materias %>%
1649
1650   # Al menos 5 estudiantes solicitaron la materia
1651   filter(
1652     Estudiantes >= 5
1653   ) %>%
1654
1655   # Ordenar las materias por numero de estudiantes
1656   group_by(
1657     Conglomerado
1658   ) %>%
1659   arrange(
1660     desc(Estudiantes),
1661     desc(Porcentaje),
1662     .by_group = TRUE
1663   ) %>%
1664
1665   # Maximo 5 materias por conglomerado
1666   slice_head(
1667     n = 5
1668   ) %>%
1669
1670   ungroup() %>%
1671
1672   mutate(
1673     K = k
1674   ) %>%
```

```

1675
1676     select(
1677         K,
1678         Conglomerado,
1679         Nombre_Materia_Limpio,
1680         Estudiantes,
1681         Porcentaje
1682     )
1683
1684
1685     return(materias_relevantes)
1686 }
1687
1688
1689 # RESULTADOS PARA K = 4
1690
1691 materias_k4 <- obtener_materias_relevantes(4)
1692
1693
1694 cat("\n===== \n")
1695 cat("MATERIAS RELEVANTES - K = 4\n")
1696 cat("===== \n")
1697
1698 print(
1699     materias_k4,
1700     n = 100
1701 )
1702
1703 # RESULTADOS PARA K = 5
1704
1705 materias_k5 <- obtener_materias_relevantes(5)
1706
1707 cat("\n===== \n")
1708 cat("MATERIAS RELEVANTES - K = 5\n")
1709 cat("===== \n")
1710
1711 print(
1712     materias_k5,
1713     n = 100
1714 )
1715
1716 # COMPARACION DE MATERIAS K = 4 VS K = 5
1717
1718 comparacion_materias <- bind_rows(
1719     materias_k4,
1720     materias_k5
1721 ) %>%
1722     arrange(
1723         K,
1724         Conglomerado,
1725         desc(Estudiantes)
1726     )
1727
1728
1729 cat("\n===== \n")
1730 cat("COMPARACION DE MATERIAS K = 4 VS K = 5\n")
1731 cat("===== \n")

```

```

1732
1733 print(
1734     comparacion_materias,
1735     n = 100)
1736
1737 # CENTROIDES DEL MODELO K = 4
1738
1739 centroides_k4 <- as.data.frame(
1740     modelos_kmeans$k4$centers)
1741
1742 cat("\n=====\n")
1743 cat("CENTROIDES - K = 4\n")
1744 cat("=====\n")
1745
1746 print(centroides_k4)
1747
1748
1749 # CENTROIDES DEL MODELO K = 5
1750
1751 centroides_k5 <- as.data.frame(
1752     modelos_kmeans$k5$centers)
1753
1754
1755 cat("\n=====\n")
1756 cat("CENTROIDES - K = 5\n")
1757 cat("=====\n")
1758
1759 print(centroides_k5)
1760
1761
1762 # MATERIAS CON MAYOR PREFERENCIA PROMEDIO
1763
1764 for (k in 4:5) {
1765
1766     modelo <- modelos_kmeans[[paste0("k", k)]]
1767
1768     cat("\n=====\n")
1769     cat("CENTROIDES - K =", k, "\n")
1770     cat("=====\n")
1771
1772     for (grupo in 1:k) {
1773
1774         tabla_centroide <- data.frame(
1775             Materia = names(
1776                 modelo$centers[grupo, ]
1777             ),
1778             Preferencia_Promedio =
1779                 as.numeric(
1780                     modelo$centers[grupo, ]
1781                 )
1782         ) %>%
1783         arrange(
1784             desc(Preferencia_Promedio)
1785         )
1786
1787         cat("\n-----\n")
1788         cat("CONGLOMERADO", grupo, "\n")

```



```

1789     cat("-----\n")
1790
1791     print(
1792         head(
1793             tabla_centroide,
1794             10
1795         )
1796     )
1797 }
1798 }
1799
1800 # TABLA DE TRANSICION K = 4 VS K = 5
1801
1802 asignaciones_comparacion <- matriz_preferencias %>%
1803     select(
1804         Individuo
1805     ) %>%
1806     mutate(
1807         K4 = modelos_kmeans$k4$cluster,
1808         K5 = modelos_kmeans$k5$cluster)
1809
1810
1811 tabla_transicion <- table(
1812     asignaciones_comparacion$K4,
1813     asignaciones_comparacion$K5)
1814
1815
1816 cat("\n=====\n")
1817 cat("TABLA DE TRANSICION K = 4 VS K = 5\n")
1818 cat("=====\n")
1819
1820 print(
1821     tabla_transicion
1822 )
1823
1824
1825 cat(
1826     "\nTotal de estudiantes:",
1827     sum(tabla_transicion),
1828     "\n"
1829 )
1830
1831 # RESUMEN FINAL K = 4 VS K = 5
1832
1833 cat("\n=====\n")
1834 cat("RESUMEN FINAL K = 4 VS K = 5\n")
1835 cat("=====\n")
1836
1837 cat("\n-----\n")
1838 cat("TAMA OS K = 4\n")
1839 cat("-----\n")
1840
1841 print(tamamos_k4)
1842
1843 cat("\n-----\n")
1844 cat("TAMA OS K = 5\n")
1845 cat("-----\n")

```

```
1846
1847 print(tamamos_k5)
1848
1849 cat("\n-----\n")
1850 cat("COEFICIENTE DE SILUETA\n")
1851 cat("-----\n")
1852
1853 print(comparacion_silueta)
1854
1855 cat("\n-----\n")
1856 cat("MATERIAS RELEVANTES K = 4\n")
1857 cat("-----\n")
1858
1859 print(materias_k4,n = 100)
1860
1861 cat("\n-----\n")
1862 cat("MATERIAS RELEVANTES K = 5\n")
1863 cat("-----\n")
1864
1865 print(materias_k5,n = 100)
1866
1867 cat("\n=====\n")
1868 cat("FIN DEL ANALISIS DE CONGLOMERADOS\n")
1869 cat("=====\n")
```

8. Conclusiones

El análisis realizado permitió identificar patrones de preferencia de los estudiantes respecto a las materias optativas de la Licenciatura en Actuaría. A partir del proceso de limpieza y homologación de la información, se obtuvo una base consistente que permitió realizar el análisis estadístico sobre las preferencias de los 124 estudiantes.

Mediante el análisis de conglomerados utilizando el método *k-means*, se evaluaron diferentes alternativas de agrupación y se compararon las soluciones con $K = 4$ y $K = 5$. Considerando el método del codo, el coeficiente de silueta, el tamaño de los grupos y la interpretación de los perfiles obtenidos, se seleccionó la solución de cuatro conglomerados.

Los resultados permitieron identificar cuatro perfiles diferenciados de preferencias, cada uno con características particulares respecto a las materias optativas. Estos perfiles proporcionan información útil para comprender los intereses de los estudiantes y pueden servir como referencia para apoyar la organización y planeación de la oferta de materias optativas.

En conclusión, el análisis de conglomerados permitió transformar la información individual de preferencias en grupos con características similares, facilitando su interpretación y proporcionando una base estadística para la toma de decisiones relacionadas con la organización de las materias optativas.

Referencias

- [1] IBM. (2026). *¿Qué es el clustering?* IBM Think. Disponible en: <https://www.ibm.com/mx-es/think/topics/clustering>
- [2] Kavlakoglu, E., & Winland, V. (2026). *¿Qué es la agrupación en clústeres k-means?* IBM Think. Disponible en: <https://www.ibm.com/mx-es/think/topics/k-means-clustering>
- [3] IBM. (2026). *Análisis de clústeres de K-medias*. IBM SPSS Statistics Documentation. Disponible en: <https://www.ibm.com/docs/es/spss-statistics/32.0.0?topic=edition-k-means-cluster-analysis>
- [4] Wicklin, R. (2023). *What is the silhouette statistic in cluster analysis?* The DO Loop, SAS. Disponible en: <https://blogs.sas.com/content/iml/2023/05/15/silhouette-statistic-cluster.html>

Elaborado por:
Noé Antonio García Martínez

