

Análisis de Componentes Principales aplicado a indicadores de riesgo reproductivo y materno

28 de agosto de 2026

Índice

1	Objetivo	2
2	Introducción	2
3	Problemática	3
4	Técnicas estadísticas utilizadas	5
4.1	Análisis de Componentes Principales	5
4.2	Matriz de varianzas y covarianzas	8
4.3	Matriz de correlaciones	10
4.4	Eigenvalores y eigenvectores	12
4.5	Componentes Principales	14
4.6	Varianza explicada y selección de componentes	17
4.7	Cargas o <i>loadings</i>	19
4.8	Aplicación del Análisis de Componentes Principales al problema	21
5	Análisis descriptivo	22
5.1	Análisis descriptivo de los indicadores	23
5.2	Matriz de varianzas y covarianzas	26
5.3	Matriz de correlaciones	27
5.4	Selección de la matriz para el Análisis de Componentes Principales	29
6	Análisis utilizando la técnica	29
6.1	Eigenvalores y eigenvectores	29
6.2	Primeras tres Componentes Principales	31
6.3	Gráficas de las Componentes Principales	31
6.4	Varianza explicada por las Componentes Principales	34
6.5	Selección del número de Componentes Principales	36
6.6	Interpretación de las Componentes Principales	36
6.6.1	Interpretación de la primera Componente Principal	37
6.6.2	Interpretación de la segunda Componente Principal	38
6.7	Correlación de la primera Componente Principal con la calificación de riesgo	39
6.8	Relación entre las variables originales y la calificación de riesgo	40
7	Conclusiones	42
8	Anexos	45
8.1	Trabajo realizado sobre la base de datos	45
8.2	Código utilizado	47

1. Objetivo

Aplicar la técnica de Análisis de Componentes Principales (ACP) a la base de datos de riesgo materno, utilizando las variables $v1$ a $v10$ y excluyendo la variable $v11$, correspondiente a la calificación de riesgo, con el propósito de reducir la dimensionalidad de la información e identificar las principales fuentes de variabilidad entre los países analizados.

Para ello, se calcularán las matrices de varianzas y covarianzas y de correlaciones, así como los eigenvalores y eigenvectores correspondientes. Posteriormente, se construirán e interpretarán las componentes principales seleccionadas, analizando la proporción de varianza explicada y las cargas asociadas a cada componente. Finalmente, se analizará la relación entre las componentes principales y la calificación de riesgo, así como la asociación de las variables originales con dicha calificación.

2. Introducción

El Análisis de Componentes Principales (ACP) es una técnica estadística multivariada que permite transformar un conjunto de variables originales en un nuevo conjunto de variables denominadas componentes principales. Estas componentes son combinaciones lineales de las variables originales y se construyen de manera que la primera componente explique la mayor cantidad posible de variabilidad de los datos, mientras que las componentes posteriores explican progresivamente la variabilidad restante.

Una de las principales aplicaciones del ACP es la reducción de dimensionalidad, ya que permite representar la información contenida en un conjunto de variables mediante un número menor de componentes, procurando conservar una proporción importante de la variabilidad original. Además, esta técnica permite estudiar la estructura de variabilidad de los datos, identificar las variables que presentan una mayor contribución en la construcción de cada componente y analizar las relaciones existentes entre los indicadores considerados.

En la presente práctica se utiliza una base de datos que contiene información de diferentes países mediante indicadores relacionados con la salud reproductiva y materna. Entre las variables consideradas se encuentran los nacimientos en mujeres de 15 a 19 años, el uso de anticoncepción, las políticas de aborto, la presencia de anemia durante el embarazo, la atención prenatal, la asistencia de los partos por personal capacitado, el nivel de VIH/SIDA en las mujeres, la infertilidad, el promedio de nacimientos por mujer y las muertes maternas por cada 100,000 nacimientos.

Debido a que estos indicadores pueden presentar diferentes escalas de medición y relaciones entre sí, el Análisis de Componentes Principales permite estudiar conjuntamente la información y resumir la estructura de variabilidad observada mediante un número reducido de componentes.

Para el desarrollo del análisis se utilizarán las variables $v1$ a $v10$, mientras que la variable $v11$, correspondiente a la calificación de riesgo, será excluida de la construcción de las componentes principales. Posteriormente, esta variable será utilizada para analizar su relación con las componentes

obtenidas y con las variables originales incluidas en el análisis.

3. Problemática

La salud materna constituye un tema de gran importancia debido a que el embarazo y el parto pueden estar acompañados por diferentes factores que afectan las condiciones de salud de las mujeres. La mortalidad materna representa uno de los indicadores utilizados para evaluar las condiciones de atención y salud relacionadas con el embarazo, ya que permite identificar diferencias importantes entre las poblaciones de distintos países.

Los problemas relacionados con la salud materna no dependen de un solo factor. Existen diferentes condiciones sociales, demográficas, reproductivas y relacionadas con los servicios de salud que pueden estar asociadas con las condiciones y el desenlace de un embarazo. Entre estos factores pueden encontrarse la edad en la que ocurre el embarazo, el acceso a métodos anticonceptivos, las condiciones de salud de las mujeres durante el embarazo y la disponibilidad de atención médica antes y durante el parto.

Uno de los aspectos considerados en la información disponible es el embarazo durante la adolescencia. Los nacimientos entre mujeres de 15 a 19 años constituyen uno de los indicadores incluidos en la base de datos, debido a que permiten observar diferencias en los patrones reproductivos de los países. Este indicador se analiza junto con el promedio de nacimientos por mujer, incorporando diferentes dimensiones relacionadas con la fecundidad.

El acceso y la utilización de métodos anticonceptivos constituyen otro de los aspectos incluidos en la información disponible. El porcentaje de mujeres que utilizan anticoncepción permite caracterizar las diferencias existentes entre los países respecto a las prácticas de prevención del embarazo. De manera complementaria, la base considera las políticas de aborto mediante la variable $v3$, cuya información se encuentra codificada de acuerdo con las condiciones establecidas en la base de datos. Además de los factores relacionados con la fecundidad y la planificación familiar, existen condiciones que pueden afectar la salud de las mujeres durante el embarazo. Entre ellas se encuentra la presencia de anemia en mujeres embarazadas, representada mediante la variable $v4$. Este indicador permite incorporar al análisis una condición relacionada con el estado de salud de las mujeres durante el embarazo.

La atención recibida durante el embarazo y el parto también constituye una parte importante de la información disponible. La variable $v5$ representa el porcentaje de mujeres que reciben atención prenatal, mientras que $v6$ corresponde al porcentaje de partos asistidos por personal capacitado. Estos indicadores permiten considerar las diferencias existentes entre los países respecto al acceso a servicios de atención relacionados con el embarazo y el parto.

La base también incorpora otros indicadores relacionados con las condiciones de salud de las mujeres. La variable $v7$ corresponde al nivel de VIH/SIDA en las mujeres, mientras que $v8$ representa el porcentaje de infertilidad. De esta manera, la información disponible reúne indicadores

de diferentes características que permiten estudiar las diferencias entre los países desde distintas perspectivas.

Finalmente, la variable v_{10} representa las muertes maternas por cada 100,000 nacimientos. Este indicador constituye una de las variables de mayor interés dentro del análisis, debido a que permite observar diferencias entre los países en cuanto a la mortalidad materna. La base también contiene la variable v_{11} , denominada “calificación de riesgo”, la cual proporciona un indicador adicional que posteriormente puede relacionarse con las variables originales y con las componentes principales obtenidas.

Una característica importante de la información disponible es que los indicadores se encuentran expresados en diferentes escalas y unidades. Algunas variables corresponden a porcentajes, otras a tasas, promedios o valores codificados. Por ejemplo, mientras que algunas variables toman valores dentro de una escala cercana a 0–100, la variable relacionada con las muertes maternas puede presentar valores considerablemente mayores. Esta diferencia en las escalas debe ser considerada antes de realizar un análisis estadístico multivariado.

Asimismo, varios de los indicadores pueden presentar relaciones entre sí. Por ejemplo, los indicadores relacionados con la atención prenatal y la asistencia de los partos pueden estar asociados, al igual que las variables relacionadas con la fecundidad y el uso de anticonceptivos. Esto implica que parte de la información contenida en las variables puede ser redundante y que analizar cada indicador de manera independiente puede dificultar la identificación de los principales patrones existentes en los datos.

Por otra parte, antes de realizar el análisis estadístico fue necesario revisar la calidad de la información disponible. La base contiene 118 observaciones correspondientes a diferentes países y presenta algunos valores faltantes. En particular, se identificaron cuatro valores faltantes: dos correspondientes a la variable v_5 y dos a la variable v_6 . Con el propósito de conservar las observaciones disponibles, estos valores fueron tratados mediante un proceso de imputación utilizando la mediana de la variable correspondiente.

Una vez revisada y preparada la información, surge la necesidad de identificar cuáles son las principales dimensiones que explican la variabilidad existente entre los países. Considerar simultáneamente los diez indicadores utilizados puede dificultar la interpretación de los patrones generales, especialmente debido a las relaciones existentes entre las variables y a las diferencias en sus escalas de medición.

Por lo anterior, se plantea la necesidad de utilizar una técnica estadística que permita sintetizar la información contenida en los diferentes indicadores sin perder una proporción importante de la variabilidad presente en los datos. El Análisis de Componentes Principales resulta adecuado para este propósito, ya que permite construir nuevas variables a partir de combinaciones lineales de los indicadores originales y ordenar dichas componentes de acuerdo con la cantidad de variabilidad que explican.

De esta manera, el análisis permitirá identificar las principales dimensiones que diferencian a los

países respecto a los indicadores de salud reproductiva y materna. Además, mediante el análisis de las cargas de las componentes será posible determinar qué variables presentan una mayor contribución a las principales dimensiones obtenidas y, posteriormente, estudiar la relación de dichas componentes con la calificación de riesgo incluida en la base de datos.

4. Técnicas estadísticas utilizadas

4.1. Análisis de Componentes Principales

El Análisis de Componentes Principales (ACP) es una técnica estadística multivariada utilizada para analizar conjuntos de datos en los que se dispone de varias variables cuantitativas que pueden presentar relaciones entre sí. Su principal objetivo es transformar las variables originales en un nuevo conjunto de variables denominadas componentes principales, buscando concentrar la mayor cantidad posible de información en un número reducido de dimensiones.

Las componentes principales se construyen como combinaciones lineales de las variables originales. La primera componente principal se obtiene de manera que explique la mayor proporción posible de la variabilidad total de los datos. La segunda componente se construye de manera que explique la mayor cantidad posible de la variabilidad restante y, además, sea ortogonal a la primera componente. Este procedimiento continúa hasta obtener el número total de componentes correspondiente al número de variables originales.

Sea un vector aleatorio de p variables definido como

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix},$$

con matriz de varianzas y covarianzas Σ . Una componente principal puede expresarse como una combinación lineal de las variables originales:

$$Y_j = a_j^T X,$$

donde a_j es un vector de coeficientes definido por

$$a_j = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{pj} \end{pmatrix}.$$

De manera explícita, la primera componente principal puede escribirse como

$$CP_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p.$$

El objetivo de la primera componente es encontrar una combinación lineal que maximice la varianza. Por lo tanto, considerando que

$$CP_1 = a_1^T X,$$

su varianza está dada por

$$\text{Var}(CP_1) = \text{Var}(a_1^T X).$$

Utilizando las propiedades de la matriz de varianzas y covarianzas, se obtiene

$$\text{Var}(CP_1) = a_1^T \Sigma a_1.$$

Para evitar que la varianza pueda incrementarse únicamente aumentando arbitrariamente la magnitud de los coeficientes, se establece la restricción

$$a_1^T a_1 = 1.$$

De esta manera, la construcción de la primera componente principal puede plantearse como el siguiente problema de optimización:

$$\max_{a_1} \{a_1^T \Sigma a_1\}$$

sujeto a

$$a_1^T a_1 = 1.$$

Para resolver este problema se utiliza el método de multiplicadores de Lagrange. Se define la función

$$L(a_1, \lambda) = a_1^T \Sigma a_1 - \lambda(a_1^T a_1 - 1).$$

Al derivar respecto al vector a_1 e igualar a cero se obtiene

$$\frac{\partial L}{\partial a_1} = 2\Sigma a_1 - 2\lambda a_1 = 0.$$

Por lo tanto,

$$\Sigma a_1 = \lambda a_1,$$

o equivalentemente,

$$(\Sigma - \lambda I)a_1 = 0,$$

donde I representa la matriz identidad.

Esta expresión corresponde al problema de eigenvalores y eigenvectores de la matriz Σ . Para que exista una solución no trivial para a_1 , se debe cumplir que

$$\det(\Sigma - \lambda I) = 0.$$

Las soluciones $\lambda_1, \lambda_2, \dots, \lambda_p$ corresponden a los eigenvalores de la matriz Σ , mientras que los vectores $a_1, a_2, \dots, a_p$ asociados corresponden a sus respectivos eigenvectores.

Los eigenvalores se ordenan de manera decreciente:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

La primera Componente Principal se obtiene utilizando el eigenvector asociado con el mayor eigenvalor λ_1 . Esto se debe a que dicho eigenvalor representa la máxima varianza que puede obtenerse mediante una combinación lineal de las variables bajo la restricción establecida.

En consecuencia,

$$\text{Var}(CP_1) = a_1^T \Sigma a_1 = \lambda_1.$$

Por lo tanto, la primera componente concentra la mayor cantidad posible de variabilidad de las variables originales.

Para construir la segunda componente principal se busca una nueva combinación lineal

$$CP_2 = a_2^T X,$$

que maximice la varianza restante, pero que además sea incorrelacionada con la primera componente. Esta condición puede expresarse como

$$\text{Cov}(CP_1, CP_2) = 0.$$

La condición de incorrelación se relaciona con la ortogonalidad de los eigenvectores, de modo que

$$a_1^T a_2 = 0.$$

La segunda componente se obtiene entonces mediante el eigenvector correspondiente al segundo mayor eigenvalor λ_2 , cumpliéndose que

$$\text{Var}(CP_2) = \lambda_2.$$

El procedimiento continúa de manera análoga para las componentes posteriores. Así, la k -ésima Componente Principal puede expresarse como

$$CP_k = a_k^T X$$

y su varianza corresponde al eigenvalor asociado:

$$\text{Var}(CP_k) = \lambda_k.$$

De esta manera, las Componentes Principales forman un nuevo sistema de variables que no están correlacionadas entre sí y se encuentran ordenadas de acuerdo con la cantidad de variabilidad que explican. Las primeras componentes suelen ser las de mayor interés, ya que permiten representar una parte importante de la información original utilizando un número menor de dimensiones.

En el presente trabajo, el ACP se utilizará para analizar conjuntamente los indicadores relacionados con la salud reproductiva y materna de los países incluidos en la base de datos. El análisis permitirá identificar las principales dimensiones que explican las diferencias observadas entre los países y determinar qué variables presentan una mayor contribución en dichas dimensiones.

4.2. Matriz de varianzas y covarianzas

Para realizar un Análisis de Componentes Principales es necesario considerar la variabilidad existente entre las variables y la relación conjunta entre ellas. Esta información puede representarse mediante la matriz de varianzas y covarianzas, denotada por S .

Si se cuenta con p variables cuantitativas $X_1, X_2, \dots, X_p$, la matriz de varianzas y covarianzas puede expresarse como

$$S = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{pmatrix}.$$

Los elementos de la diagonal principal corresponden a las varianzas de cada variable, mientras que los elementos fuera de la diagonal corresponden a las covarianzas entre pares de variables. Por lo tanto,

$$s_{jj} = \text{Var}(X_j)$$

representa la varianza de la variable X_j , mientras que

$$s_{jk} = \text{Cov}(X_j, X_k)$$

representa la covarianza entre las variables X_j y X_k .

Para una muestra de n observaciones, la varianza muestral de la variable X_j se calcula mediante

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

donde x_{ij} representa el valor de la variable X_j para la observación i y $\bar{x}_j$ corresponde a la media muestral de dicha variable.

De manera análoga, la covarianza muestral entre dos variables X_j y X_k se calcula como

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

La covarianza permite identificar la dirección en la que dos variables tienden a variar conjuntamente. Una covarianza positiva indica que, en términos generales, valores superiores de una variable tienden a asociarse con valores superiores de la otra. En cambio, una covarianza negativa indica que valores superiores de una variable tienden a asociarse con valores inferiores de la otra.

En términos matriciales, la matriz de varianzas y covarianzas puede escribirse como

$$S = \frac{1}{n-1} (X - \bar{X})(X - \bar{X})^T,$$

donde X representa la matriz de observaciones y $\bar{X}$ contiene las medias de las variables.

Una propiedad importante de esta matriz es que es simétrica, debido a que

$$s_{jk} = s_{kj}.$$

Por lo tanto,

$$S = S^T.$$

Esta propiedad resulta relevante para el Análisis de Componentes Principales, ya que permite obtener eigenvalores reales y eigenvectores ortogonales asociados con la matriz utilizada para construir las componentes.

La varianza de una combinación lineal también puede expresarse mediante la matriz de varianzas y covarianzas. Si una combinación lineal está definida como

$$Y = a^T X,$$

entonces su varianza está dada por

$$\text{Var}(Y) = a^T S a.$$

Esta expresión es fundamental para el ACP, ya que la primera componente principal se obtiene precisamente buscando el vector de coeficientes a que maximiza esta varianza bajo una restricción de normalización.

Sin embargo, la magnitud de las covarianzas depende de las unidades de medición de las variables involucradas. Por esta razón, cuando las variables presentan escalas o unidades considerablemente diferentes, una variable con una mayor variabilidad puede tener una influencia desproporcionada sobre el resultado del Análisis de Componentes Principales.

Por ejemplo, si una variable presenta valores numéricos de una magnitud mucho mayor que otra, su varianza puede ser considerablemente superior. En consecuencia, al utilizar directamente la matriz S , dicha variable puede dominar la construcción de las primeras componentes, aun cuando su relación con las demás variables no sea necesariamente más importante.

Por lo anterior, antes de aplicar el ACP es necesario analizar las varianzas de las variables y determinar si presentan órdenes de magnitud comparables. Cuando las escalas son diferentes, puede resultar más adecuado utilizar la matriz de correlaciones R , la cual equivale a realizar el análisis sobre variables estandarizadas.

4.3. Matriz de correlaciones

Cuando las variables originales presentan diferentes unidades de medida o escalas de variabilidad, una alternativa para realizar el Análisis de Componentes Principales consiste en utilizar la matriz de correlaciones, denotada por R . Esta matriz permite analizar la relación lineal existente entre las variables sin que la magnitud de sus unidades influya directamente en la construcción de las componentes.

Para un conjunto de p variables, la matriz de correlaciones se expresa como

$$R = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}.$$

Cada elemento r_{jk} representa el coeficiente de correlación entre las variables X_j y X_k . Los elementos de la diagonal principal son iguales a uno, debido a que cada variable presenta correlación perfecta consigo misma.

El coeficiente de correlación de Pearson entre dos variables X_j y X_k se define como

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}},$$

donde s_{jk} representa la covarianza entre las variables, mientras que s_{jj} y s_{kk} corresponden a sus respectivas varianzas.

El coeficiente de correlación toma valores dentro del intervalo

$$-1 \leq r_{jk} \leq 1.$$

Un valor cercano a 1 indica una relación lineal positiva fuerte, mientras que un valor cercano a -1 indica una relación lineal negativa fuerte. Por otro lado, valores cercanos a cero indican una relación lineal débil entre las variables.

Una característica importante de la matriz de correlaciones es que permite eliminar el efecto de las diferencias de escala entre las variables. Esto se debe a que el coeficiente de correlación se obtiene estandarizando la covarianza mediante las desviaciones estándar de las variables involucradas.

La estandarización de una variable X_j se obtiene mediante

$$Z_j = \frac{X_j - \bar{X}_j}{s_j},$$

donde $\bar{X}_j$ representa la media de la variable y s_j su desviación estándar. Después de la estandarización, cada variable presenta media cero y varianza uno:

$$E(Z_j) = 0$$

y

$$\text{Var}(Z_j) = 1.$$

Si las variables estandarizadas se organizan en un vector

$$Z = \begin{pmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_p \end{pmatrix},$$

su matriz de varianzas y covarianzas corresponde precisamente a la matriz de correlaciones R :

$$\text{Cov}(Z) = R.$$

Por lo tanto, realizar un Análisis de Componentes Principales utilizando la matriz de correlaciones es equivalente a realizar el análisis sobre las variables previamente estandarizadas.

Esta transformación resulta particularmente importante cuando las variables originales presentan diferentes unidades de medición o cuando sus varianzas presentan órdenes de magnitud considerablemente distintos. De esta manera, cada variable tiene una participación comparable en el análisis y se evita que las variables con mayor variabilidad dominen la construcción de las componentes principales.

Además, la matriz de correlaciones permite identificar previamente relaciones lineales importantes entre las variables. Cuando existen correlaciones elevadas entre diferentes indicadores, significa que parte de la información contenida en ellos puede estar relacionada, lo que justifica la aplicación de una técnica de reducción de dimensionalidad como el Análisis de Componentes Principales.

4.4. Eigenvalores y eigenvectores

Una vez definida la matriz que será utilizada para realizar el Análisis de Componentes Principales, el siguiente paso consiste en obtener sus eigenvalores y eigenvectores. Estos elementos son fundamentales para la construcción de las Componentes Principales, ya que determinan tanto la dirección de cada componente como la cantidad de variabilidad que esta explica.

Sea A una matriz cuadrada de dimensión $p \times p$. Un escalar λ es un eigenvalor de A si existe un vector no nulo a que satisface

$$Aa = \lambda a.$$

El vector a se denomina eigenvector asociado al eigenvalor λ . Reordenando la expresión anterior se obtiene

$$Aa - \lambda a = 0,$$

y, utilizando la matriz identidad I , puede escribirse como

$$(A - \lambda I)a = 0.$$

Para que exista una solución no trivial, es necesario que la matriz $(A - \lambda I)$ sea singular. Por lo tanto, los eigenvalores se obtienen resolviendo la ecuación característica

$$\det(A - \lambda I) = 0.$$

Al resolver esta ecuación se obtienen los p eigenvalores de la matriz, los cuales pueden ordenarse de manera decreciente como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

Para cada eigenvalor λ_j se obtiene su eigenvector asociado resolviendo el sistema

$$(A - \lambda_j I)a_j = 0.$$

En el caso del Análisis de Componentes Principales, la matriz A corresponde a la matriz de varianzas y covarianzas S o a la matriz de correlaciones R , dependiendo de cuál haya sido seleccionada

para realizar el análisis.

Si se utiliza la matriz de varianzas y covarianzas, el problema se expresa como

$$Sa_j = \lambda_j a_j.$$

Cuando se utiliza la matriz de correlaciones, se tiene

$$Ra_j = \lambda_j a_j.$$

Los eigenvalores obtenidos representan la varianza asociada con cada una de las Componentes Principales. Por esta razón, el eigenvalor más grande corresponde a la primera componente, el segundo eigenvalor más grande a la segunda componente y así sucesivamente.

De esta manera,

$$\text{Var}(CP_j) = \lambda_j.$$

Los eigenvectores, por su parte, contienen los coeficientes que determinan la combinación lineal utilizada para construir cada componente. Si a_j representa el eigenvector asociado con λ_j , entonces

$$CP_j = a_j^T X.$$

Por ejemplo, para la primera componente,

$$CP_1 = a_1^T X,$$

y si existen p variables,

$$CP_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p.$$

Una propiedad importante de las matrices de varianzas y covarianzas y de las matrices de correlaciones es que son matrices simétricas. En consecuencia, sus eigenvalores son reales y sus eigenvectores asociados pueden elegirse ortogonales entre sí.

Si a_i y a_j son eigenvectores correspondientes a diferentes eigenvalores, entonces

$$a_i^T a_j = 0, \quad i \neq j.$$

Esta propiedad es importante para el ACP, ya que garantiza que las Componentes Principales obtenidas sean incorrelacionadas entre sí.

Además, los eigenvectores se normalizan de manera que

$$a_j^T a_j = 1.$$

Por lo tanto, los eigenvectores utilizados para construir las componentes tienen norma unitaria y son ortogonales entre sí.

En términos del problema de optimización presentado anteriormente, la primera Componente Principal se obtiene a partir del eigenvector correspondiente al mayor eigenvalor. La segunda componente se obtiene mediante el eigenvector asociado con el segundo mayor eigenvalor, manteniendo la condición de ortogonalidad con respecto a la primera componente. El procedimiento continúa de manera análoga para las componentes posteriores.

En consecuencia, la descomposición espectral de la matriz utilizada en el ACP puede expresarse, de manera general, como

$$A = P\Lambda P^T,$$

donde P es la matriz formada por los eigenvectores y Λ es una matriz diagonal cuyos elementos corresponden a los eigenvalores:

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

Esta representación permite expresar la estructura de variabilidad de las variables originales mediante las direcciones principales determinadas por los eigenvectores y las cantidades de variabilidad asociadas con ellas mediante los eigenvalores.

4.5. Componentes Principales

Una vez obtenidos los eigenvalores y eigenvectores de la matriz utilizada en el análisis, es posible construir las Componentes Principales como combinaciones lineales de las variables originales. Cada componente representa una nueva variable construida a partir de los coeficientes contenidos en el eigenvector correspondiente.

Sea X el vector de variables originales y sea a_k el eigenvector asociado con el eigenvalor λ_k . La k -ésima Componente Principal se define como

$$CP_k = a_k^T X.$$

Si el vector de variables está compuesto por p variables,

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix},$$

y el eigenvector correspondiente es

$$a_k = \begin{pmatrix} a_{1k} \\ a_{2k} \\ \vdots \\ a_{pk} \end{pmatrix},$$

entonces la componente puede expresarse como

$$CP_k = a_{1k}X_1 + a_{2k}X_2 + \cdots + a_{pk}X_p.$$

Por lo tanto, los elementos del eigenvector determinan los coeficientes que acompañan a cada variable en la construcción de la componente.

Para la primera Componente Principal se utiliza el eigenvector asociado con el mayor eigenvalor, por lo que

$$CP_1 = a_1^T X.$$

Su varianza corresponde al primer eigenvalor:

$$\text{Var}(CP_1) = \lambda_1.$$

De manera análoga, la segunda Componente Principal se obtiene mediante

$$CP_2 = a_2^T X,$$

y su varianza está dada por

$$\text{Var}(CP_2) = \lambda_2.$$

El mismo procedimiento se aplica para las componentes posteriores.

Una característica fundamental de las Componentes Principales es que son incorrelacionadas entre sí. Para dos componentes diferentes, se cumple que

$$\text{Cov}(CP_i, CP_j) = 0, \quad i \neq j.$$

Esto puede demostrarse considerando que

$$CP_i = a_i^T X$$

y

$$CP_j = a_j^T X.$$

Por lo tanto,

$$\text{Cov}(CP_i, CP_j) = a_i^T \Sigma a_j.$$

Como los eigenvectores asociados con diferentes eigenvalores son ortogonales y satisfacen

$$a_i^T a_j = 0, \quad i \neq j,$$

se obtiene

$$\text{Cov}(CP_i, CP_j) = 0.$$

De esta manera, las Componentes Principales permiten transformar un conjunto de variables que pueden presentar correlaciones entre sí en un nuevo conjunto de variables que no presentan correlación lineal.

Si las variables se encuentran estandarizadas y se utiliza la matriz de correlaciones R , la construcción de las componentes se realiza de manera equivalente, sustituyendo Σ por R :

$$CP_k = a_k^T Z,$$

donde Z representa el vector de variables estandarizadas.

En este caso, la varianza de cada componente continúa estando determinada por su eigenvalor:

$$\text{Var}(CP_k) = a_k^T R a_k = \lambda_k.$$

Una propiedad importante del ACP es que la suma de las varianzas de todas las Componentes Principales es igual a la suma de las varianzas de las variables originales. Si se consideran p variables, entonces

$$\sum_{k=1}^p \text{Var}(CP_k) = \sum_{k=1}^p \lambda_k.$$

Cuando se trabaja con variables estandarizadas, cada variable presenta varianza igual a uno y, por lo tanto,

$$\sum_{k=1}^p \lambda_k = p.$$

Esta propiedad permite utilizar los eigenvalores para determinar qué proporción de la variabilidad total es representada por cada componente.

En términos matriciales, las componentes pueden obtenerse mediante la transformación

$$Y = XP,$$

donde P es una matriz cuyas columnas corresponden a los eigenvectores de la matriz utilizada en el ACP. De esta forma, cada columna de Y corresponde a una Componente Principal.

Si se conservan únicamente las primeras q componentes, donde $q < p$, se obtiene una representación de menor dimensión de los datos:

$$Y_q = XP_q,$$

donde P_q contiene únicamente los eigenvectores asociados con las primeras q componentes.

La reducción de dimensionalidad se justifica cuando las primeras componentes concentran una proporción elevada de la variabilidad total. Por esta razón, además de obtener las componentes, es necesario analizar la varianza explicada por cada una y su proporción acumulada.

4.6. Varianza explicada y selección de componentes

Una de las principales características del Análisis de Componentes Principales es que las componentes se ordenan de acuerdo con la cantidad de variabilidad que explican. Esta característica permite determinar si es posible representar adecuadamente la información original utilizando un número menor de componentes.

La varianza asociada con cada Componente Principal está representada por su eigenvalor correspondiente. Por lo tanto, la varianza de la k -ésima componente es

$$\text{Var}(CP_k) = \lambda_k.$$

La varianza total de las variables consideradas en el análisis corresponde a la suma de todos los eigenvalores:

$$\text{Var}_{\text{total}} = \sum_{k=1}^p \lambda_k.$$

Cuando el ACP se realiza a partir de la matriz de correlaciones y se utilizan variables estandarizadas, cada variable tiene varianza igual a uno. Por lo tanto, si se consideran p variables, la varianza total es igual a

$$\text{Var}_{\text{total}} = p.$$

La proporción de varianza explicada por cada componente se obtiene mediante

$$\text{PVE}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j},$$

y puede expresarse como porcentaje mediante

$$\text{PVE}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j} \times 100.$$

Además de analizar la varianza explicada individualmente, es posible calcular la proporción acumulada de varianza explicada por las primeras k componentes mediante

$$\text{PVE}_{\text{acumulada},k} = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \times 100.$$

Este porcentaje permite evaluar qué tan bien se puede representar la información original utilizando únicamente las primeras componentes. Mientras mayor sea la proporción acumulada, mayor será la cantidad de variabilidad original conservada en la representación reducida.

Para determinar el número de componentes que se conservarán pueden utilizarse diferentes criterios. Uno de los criterios empleados en este análisis es el **criterio de Kaiser**, el cual establece que deben conservarse aquellas componentes cuyos eigenvalores sean mayores que uno cuando el Análisis de Componentes Principales se realiza utilizando la matriz de correlaciones.

La lógica de este criterio se basa en que, al trabajar con variables estandarizadas, cada variable original aporta una varianza igual a uno. Por lo tanto, una componente cuyo eigenvalor sea mayor que uno explica una cantidad de varianza superior a la que aporta individualmente una variable estandarizada.

Matemáticamente, el criterio de Kaiser puede expresarse como

$$\lambda_k > 1.$$

De esta manera, una componente será considerada relevante bajo este criterio cuando su eigenvalor sea estrictamente mayor que uno. Las componentes cuyos eigenvalores sean menores o iguales a uno no se conservarán, debido a que explican una cantidad de variabilidad igual o inferior a la correspondiente a una variable original estandarizada.

Otro criterio consiste en analizar la gráfica de los eigenvalores, conocida como gráfica de sedimentación o *scree plot*. En esta representación se muestran los eigenvalores en orden descendente y se busca identificar el punto a partir del cual la reducción de los eigenvalores se vuelve menos pronunciada. Las componentes ubicadas antes de este punto suelen considerarse las de mayor importancia para representar la estructura de los datos.

La gráfica de sedimentación puede representarse mediante los pares

$$(k, \lambda_k), \quad k = 1, 2, \dots, p,$$

donde el eje horizontal representa el número de componente y el eje vertical representa su eigenvalor correspondiente. El cambio en la pendiente de la curva permite identificar visualmente el número de componentes que concentran una proporción importante de la variabilidad.

La selección final del número de componentes no debe depender exclusivamente de un único criterio. También debe considerarse la proporción acumulada de varianza explicada y la posibilidad de interpretar las componentes seleccionadas de acuerdo con las variables que presentan mayor contribución.

En el presente trabajo, el criterio de Kaiser, el gráfico de sedimentación y la proporción acumulada de varianza explicada serán utilizados conjuntamente para determinar cuántas Componentes Principales permiten representar adecuadamente la variabilidad de los indicadores de salud reproductiva y materna, procurando reducir la dimensionalidad de la información sin perder una cantidad importante de variabilidad.

4.7. Cargas o *loadings*

Las cargas de las Componentes Principales permiten analizar la contribución de cada variable original en la construcción de las nuevas componentes. Estas cargas están relacionadas con los coeficientes de los eigenvectores utilizados para obtener las componentes principales y permiten interpretar las dimensiones obtenidas mediante el ACP.

Sea a_k el eigenvector asociado con el eigenvalor λ_k . La k -ésima Componente Principal puede expresarse como

$$CP_k = a_k^T X.$$

Por lo tanto, los elementos del eigenvector corresponden a los coeficientes utilizados en la combinación lineal de las variables originales. Si

$$a_k = \begin{pmatrix} a_{1k} \\ a_{2k} \\ \vdots \\ a_{pk} \end{pmatrix},$$

entonces

$$CP_k = a_{1k}X_1 + a_{2k}X_2 + \cdots + a_{pk}X_p.$$

En este sentido, el valor de cada coeficiente permite conocer la dirección en la que cada variable participa en la construcción de la componente. Sin embargo, para interpretar las cargas resulta conveniente considerar no solamente el signo, sino también su magnitud.

Cuando el ACP se realiza utilizando la matriz de correlaciones, las variables se encuentran estandarizadas. En este caso, las cargas pueden obtenerse a partir de los eigenvectores y los eigenvalores mediante

$$l_{jk} = \sqrt{\lambda_k} a_{jk},$$

donde l_{jk} representa la carga de la variable X_j sobre la Componente Principal CP_k , λ_k es el eigenvalor asociado con la componente y a_{jk} es el elemento correspondiente del eigenvector.

En forma matricial, si A representa la matriz de eigenvectores y Λ la matriz diagonal de eigenvalores, la matriz de cargas puede expresarse como

$$L = A\Lambda^{1/2}.$$

De esta manera, cada elemento de la matriz L representa la relación entre una variable original y una determinada Componente Principal.

El signo de una carga indica la dirección de la relación entre la variable y la componente. Una carga positiva indica que valores superiores de la variable contribuyen en la misma dirección que valores superiores de la componente, mientras que una carga negativa indica una relación en dirección opuesta.

Por otra parte, la magnitud absoluta de la carga permite evaluar la importancia de la variable en la construcción de una componente. Valores absolutos elevados indican una mayor asociación de la variable con la componente, mientras que valores cercanos a cero indican una contribución relativamente pequeña.

Por ejemplo, si una variable presenta una carga de

$$l_{jk} = 0.90,$$

su relación con la componente es positiva y de magnitud elevada. En cambio, una carga de

$$l_{jk} = -0.90$$

indica una relación de magnitud igualmente elevada, pero en dirección opuesta.

Las cargas también permiten identificar las variables que caracterizan principalmente a cada componente. Si varias variables presentan cargas positivas elevadas dentro de una misma componente, estas variables contribuyen conjuntamente en la misma dirección. De manera análoga, si otras variables presentan cargas negativas elevadas, contribuyen en dirección contraria.

Es importante señalar que el signo de una Componente Principal no posee un significado absoluto. Si se cambia simultáneamente el signo del eigenvector y de la componente, se obtiene una representación estadísticamente equivalente. Por esta razón, la interpretación debe centrarse principalmente en la magnitud de las cargas y en el patrón conjunto de relaciones entre las variables.

Además, las cargas pueden relacionarse con la correlación entre las variables originales estandarizadas y las Componentes Principales. En particular, para variables estandarizadas, la carga l_{jk} puede interpretarse como la correlación entre la variable X_j y la Componente Principal CP_k :

$$l_{jk} = \text{Cor}(X_j, CP_k).$$

Esta propiedad facilita la interpretación de las componentes, ya que permite identificar cuáles de las variables originales presentan una mayor relación con cada dimensión obtenida mediante el ACP.

4.8. Aplicación del Análisis de Componentes Principales al problema

Para aplicar el Análisis de Componentes Principales al problema planteado, pueden considerarse los indicadores $v1$ a $v10$ disponibles en la base de datos. Cada país será considerado como una observación y las diferentes variables representarán las características mediante las cuales se describen las condiciones relacionadas con la salud reproductiva y materna.

Antes de realizar el análisis, es necesario revisar las características de las variables y determinar la matriz adecuada para la construcción de las componentes principales. En particular, se comparan las varianzas y covarianzas de las variables mediante la matriz S y sus correlaciones mediante la matriz R . Esta comparación permite establecer si las diferencias en las escalas de medición hacen conveniente trabajar con variables estandarizadas.

Una vez seleccionada la matriz correspondiente, se obtienen los eigenvalores y eigenvectores necesarios para construir las componentes principales. Posteriormente, se analiza la proporción de varianza explicada por cada componente y la varianza acumulada, con el propósito de determinar un número reducido de componentes que permita representar una parte importante de la información original.

La interpretación de las componentes seleccionadas se realiza mediante el análisis de sus cargas.

En particular, se identifican las variables que presentan los pesos de mayor magnitud y se analiza el sentido de su relación con cada componente. Esto permite establecer qué características de los indicadores de salud reproductiva y materna están asociadas con las principales dimensiones obtenidas.

Asimismo, se utilizan las puntuaciones de las componentes principales para representar gráficamente a los países en espacios de menor dimensión. Las gráficas de $CP1$ contra $CP2$ y de $CP2$ contra $CP3$ permiten observar la distribución de las observaciones e identificar posibles patrones, agrupamientos o puntos que presenten un comportamiento diferente al resto de los países.

Finalmente, la variable $v11$, correspondiente a la calificación de riesgo, se utiliza únicamente después de construir las componentes principales. Se calcula su correlación con la primera componente con el propósito de analizar qué tan relacionada se encuentra la dimensión principal obtenida mediante el ACP con el índice de riesgo original.

De esta manera, el Análisis de Componentes Principales permite sintetizar la información contenida en los diferentes indicadores y facilita la identificación de las principales dimensiones asociadas con las condiciones de salud reproductiva y materna de los países analizados.

5. Análisis descriptivo

La base de datos utilizada para el análisis contiene información correspondiente a 118 países y está conformada por doce variables. La primera variable corresponde al nombre del país, mientras que las siguientes once variables, identificadas como $v1$ a $v11$, contienen los indicadores utilizados para caracterizar diferentes aspectos relacionados con la salud reproductiva y materna.

Para el desarrollo del Análisis de Componentes Principales se consideran las variables $v1$ a $v10$. La variable $v11$, correspondiente a la “calificación de riesgo”, no se incorpora en la construcción de los componentes principales, ya que será utilizada posteriormente para analizar su relación con las componentes obtenidas.

Las variables consideradas para el ACP son las siguientes:

Cuadro 1: Indicadores utilizados en el Análisis de Componentes Principales

Variable	Descripción
$v1$	Nacimientos anuales por 100 mujeres de 15 a 19 años
$v2$	Porcentaje de mujeres que usan anticoncepción
$v3$	Políticas de aborto
$v4$	Porcentaje de embarazadas con anemia
$v5$	Porcentaje de mujeres que reciben atención prenatal
$v6$	Porcentaje de partos asistidos por personal capacitado
$v7$	Nivel de VIH/SIDA en las mujeres
$v8$	Porcentaje de infertilidad en las mujeres
$v9$	Promedio de nacimientos por mujer
$v10$	Muertes maternas por 100,000 nacimientos

Antes de realizar el análisis multivariado se revisó la estructura de la base y se verificó la existencia de valores faltantes. Se identificaron cuatro valores faltantes en las variables utilizadas para el ACP: dos correspondieron a la variable $v5$ y dos a la variable $v6$.

Los valores faltantes se presentaron en las observaciones correspondientes a Suiza y Laos para la variable $v5$, mientras que para la variable $v6$ se encontraron en las observaciones correspondientes a Congo y Zaire.

Debido a que la eliminación de estas observaciones implicaría reducir el número de países disponibles para el análisis, se decidió conservar las 118 observaciones y realizar un tratamiento de los valores faltantes mediante imputación por la mediana de cada variable.

La mediana obtenida para la variable $v5$ fue de 79.50, mientras que para la variable $v6$ fue de 71.50. Por lo tanto, los valores faltantes de $v5$ fueron sustituidos por 79.50 y los valores faltantes de $v6$ por 71.50.

Después de realizar la imputación, se verificó nuevamente la presencia de valores faltantes. El resultado mostró que ninguna de las diez variables utilizadas en el ACP presentó valores faltantes, por lo que se conservaron las 118 observaciones para las etapas posteriores del análisis.

5.1. Análisis descriptivo de los indicadores

Con el propósito de conocer las principales características de las variables que serán utilizadas en el Análisis de Componentes Principales, se realizó inicialmente un análisis descriptivo de los diez indicadores seleccionados. Para ello, se consideraron medidas de tendencia central y dispersión, así como representaciones gráficas que permitieran comparar el comportamiento de las variables.

Debido a que los indicadores presentan diferentes escalas de medición, la comparación directa de sus valores debe realizarse con precaución. Por esta razón, además de analizar sus valores originales, se utilizó una representación estandarizada para facilitar la comparación de sus distribuciones.

La Figura 1 presenta el valor promedio de cada uno de los indicadores considerados en el análisis.




Figura 1: Nivel promedio de los indicadores analizados.

Se observa que los indicadores presentan niveles promedio considerablemente diferentes. El valor medio más elevado corresponde a *Muertes maternas*, con un promedio de 289.60, seguido por *Atención prenatal*, con 72.66, y *Partos asistidos*, con 67.60. En contraste, *Nivel de VIH/SIDA* presenta el menor valor promedio, con 1.40.

Sin embargo, las diferencias observadas entre las medias no deben interpretarse directamente como diferencias en importancia dentro del análisis multivariado, debido a que cada indicador se encuentra expresado en una escala distinta.

Para complementar el análisis de tendencia central, se examinó la dispersión de cada variable mediante su desviación estándar. Los resultados se muestran en la Figura 2.




Figura 2: Dispersión de los indicadores mediante su desviación estándar.

La gráfica permite observar diferencias importantes en la variabilidad de los indicadores. La mayor dispersión corresponde a *Muertes maternas*, cuya desviación estándar es de 323.50, mientras que *Nivel de VIH/SIDA* presenta una desviación estándar de apenas 0.69. También se observan diferencias importantes entre variables como *Partos asistidos*, con una desviación estándar de 30.05, y *Uso de anticoncepción*, con 27.14.

Estas diferencias muestran que las variables no presentan una variabilidad comparable en sus escalas originales. Por ello, resulta conveniente considerar la estandarización de los indicadores al momento de aplicar el Análisis de Componentes Principales, evitando que las variables con mayor variabilidad absoluta dominen la construcción de las componentes.

Finalmente, se analizaron las distribuciones de las variables después de su estandarización. Esta representación permite comparar los indicadores en una escala común, independientemente de sus unidades y magnitudes originales.




Figura 3: Distribución estandarizada de los indicadores.

A partir de los diagramas de caja se observa que las distribuciones presentan diferentes grados de dispersión y asimetría. También se identifican algunas observaciones alejadas del comportamiento central, particularmente en variables como *Muertes maternas* e *Infertilidad*. Estas observaciones no fueron eliminadas, ya que representan países que forman parte de la población analizada y constituyen información relevante para el análisis.

En conjunto, el análisis descriptivo muestra que los diez indicadores presentan comportamientos y escalas considerablemente diferentes. Esta heterogeneidad constituye un elemento importante para

la aplicación del Análisis de Componentes Principales y motiva el uso de variables estandarizadas para evitar que las diferencias de escala determinen de manera artificial la importancia de los indicadores.

5.2. Matriz de varianzas y covarianzas

Como primer paso del análisis se calculó la matriz de varianzas y covarianzas S utilizando las diez variables consideradas en el Análisis de Componentes Principales. La matriz obtenida fue:

$$S = \begin{pmatrix} 41.6226 & -130.8667 & 5.2551 & 62.0868 & -97.1004 & -122.6844 & 2.4024 & 11.1857 & 10.3400 & 1468.0278 \\ -130.8667 & 736.8490 & -22.8012 & -319.3043 & 446.7699 & 619.4498 & -3.3515 & -38.5289 & -51.4926 & -6344.7472 \\ 5.2551 & -22.8012 & 2.2147 & 13.1551 & -16.5800 & -24.5679 & 0.2944 & 0.6865 & 1.8571 & 224.5482 \\ 62.0868 & -319.3043 & 13.1551 & 326.3918 & -252.4851 & -352.8455 & 4.9737 & 14.1989 & 24.2976 & 3651.0320 \\ -97.1004 & 446.7699 & -16.5800 & -252.4851 & 699.0080 & 616.7356 & -1.9493 & -10.2325 & -33.9015 & -5733.7911 \\ -122.6844 & 619.4498 & -24.5679 & -352.8455 & 616.7356 & 902.9041 & -8.0195 & -27.7208 & -47.5437 & -7218.5379 \\ 2.4024 & -3.3515 & 0.2944 & 4.9737 & -1.9493 & -8.0195 & 0.4810 & 1.5670 & 0.7437 & 99.2473 \\ 11.1857 & -38.5289 & 0.6865 & 14.1989 & -10.2325 & -27.7208 & 1.5670 & 12.6754 & 2.6246 & 455.5453 \\ 10.3400 & -51.4926 & 1.8571 & 24.2976 & -33.9015 & -47.5437 & 0.7437 & 2.6246 & 4.0518 & 459.6908 \\ 1468.0278 & -6344.7472 & 224.5482 & 3651.0320 & -5733.7911 & -7218.5379 & 99.2473 & 455.5453 & 459.6908 & 104712.9781 \end{pmatrix}$$

Los elementos de la diagonal principal corresponden a las varianzas de cada una de las variables. Estas fueron:

Cuadro 2: Varianzas de las variables utilizadas en el ACP

Variable	Varianza
$v1$	41.6226
$v2$	736.8490
$v3$	2.2147
$v4$	326.3918
$v5$	699.0080
$v6$	902.9041
$v7$	0.4810
$v8$	12.6754
$v9$	4.0518
$v10$	104712.9781

A partir de estos resultados se observa que las varianzas no son del mismo orden de magnitud. Existe una diferencia considerable entre las variables con menor y mayor variabilidad. Por ejemplo, la variable $v7$ presenta una varianza de aproximadamente 0.4810, mientras que la variable $v10$ presenta una varianza de aproximadamente 104712.9781.

Esta diferencia muestra que las variables se encuentran medidas en escalas y órdenes de magnitud diferentes. En particular, la variable $v10$ presenta una variabilidad considerablemente mayor

que el resto de las variables, por lo que si se utilizara directamente la matriz S para construir los componentes principales, esta variable podría tener una influencia desproporcionada en los resultados.

Por lo tanto, a partir del análisis de las varianzas se considera más apropiado utilizar posteriormente la matriz de correlaciones R , ya que esta permite trabajar con las variables estandarizadas y evita que las diferencias en escala determinen de manera dominante la construcción de los componentes principales.

5.3. Matriz de correlaciones

Debido a que las variables presentan diferentes órdenes de magnitud, se calculó la matriz de correlaciones R con el propósito de analizar la relación lineal existente entre los indicadores sin que sus diferentes escalas de medición influyeran directamente en el análisis.

La matriz de correlaciones obtenida fue:

$$R = \begin{pmatrix} 1.0000 & -0.7473 & 0.5473 & 0.5327 & -0.5693 & -0.6329 & 0.5369 & 0.4870 & 0.7962 & 0.7032 \\ -0.7473 & 1.0000 & -0.5644 & -0.6511 & 0.6225 & 0.7594 & -0.4967 & -0.3987 & -0.9424 & -0.7223 \\ 0.5473 & -0.5644 & 1.0000 & 0.4893 & -0.4214 & -0.5490 & 0.2852 & 0.1296 & 0.6200 & 0.4663 \\ 0.5327 & -0.6511 & 0.4893 & 1.0000 & -0.5286 & -0.6500 & 0.3969 & 0.2208 & 0.6681 & 0.6245 \\ -0.5693 & 0.6225 & -0.4214 & -0.5286 & 1.0000 & 0.7763 & -0.1063 & -0.1087 & -0.6370 & -0.6702 \\ -0.6329 & 0.7594 & -0.5490 & -0.6500 & 0.7763 & 1.0000 & -0.3848 & -0.2591 & -0.7860 & -0.7424 \\ 0.5369 & -0.4967 & 0.2852 & 0.3969 & -0.1063 & -0.3848 & 1.0000 & 0.6346 & 0.5327 & 0.4422 \\ 0.4870 & -0.3987 & 0.1296 & 0.2208 & -0.1087 & -0.2591 & 0.6346 & 1.0000 & 0.3662 & 0.3954 \\ 0.7962 & -0.9424 & 0.6200 & 0.6681 & -0.6370 & -0.7860 & 0.5327 & 0.3662 & 1.0000 & 0.7057 \\ 0.7032 & -0.7223 & 0.4663 & 0.6245 & -0.6702 & -0.7424 & 0.4422 & 0.3954 & 0.7057 & 1.0000 \end{pmatrix}$$

A partir de la matriz anterior se identificaron diferentes correlaciones de magnitud elevada. Para fines de interpretación en este análisis, se consideraron como correlaciones de magnitud alta aquellas cuyo valor absoluto fue igual o superior a 0.70.

Entre las relaciones más importantes se encuentra la correlación entre $v2$ y $v9$, cuyo valor fue

$$r_{v2,v9} = -0.9424.$$

Esta es la correlación de mayor magnitud encontrada en la matriz. El signo negativo indica una relación inversa entre ambas variables: los países que presentan mayores valores en $v2$, correspondiente al porcentaje de mujeres que utilizan anticoncepción, tienden a presentar menores valores en $v9$, correspondiente al promedio de nacimientos por mujer.

También se obtuvo una correlación positiva elevada entre $v1$ y $v9$:

$$r_{v1,v9} = 0.7962.$$

Esta relación indica que los países con mayores niveles de nacimientos anuales entre mujeres de 15 a 19 años tienden a presentar también un mayor promedio de nacimientos por mujer.

Otra relación importante se presenta entre $v5$ y $v6$:

$$r_{v5,v6} = 0.7763.$$

En este caso, la relación es positiva, por lo que los países con mayores porcentajes de mujeres que reciben atención prenatal tienden a presentar también mayores porcentajes de partos asistidos por personal capacitado.

Por otra parte, se identificó una relación negativa entre $v6$ y $v9$:

$$r_{v6,v9} = -0.7860.$$

Esto indica que una mayor proporción de partos asistidos por personal capacitado se encuentra asociada, en la base analizada, con un menor promedio de nacimientos por mujer.

También destaca la correlación entre $v6$ y $v10$:

$$r_{v6,v10} = -0.7424.$$

Considerando que $v6$ representa el porcentaje de partos asistidos por personal capacitado y $v10$ corresponde a las muertes maternas por cada 100,000 nacimientos, la relación negativa indica que los países con mayores porcentajes de partos asistidos por personal capacitado tienden a presentar menores niveles de muertes maternas.

Asimismo, se observaron relaciones importantes entre $v2$ y $v6$, con una correlación de

$$r_{v2,v6} = 0.7594,$$

y entre $v1$ y $v2$, con una correlación de

$$r_{v1,v2} = -0.7473.$$

En conjunto, la presencia de varias correlaciones de magnitud elevada muestra que existe información compartida entre diferentes variables. Esta característica es importante para la aplicación del Análisis de Componentes Principales, ya que una de las finalidades de esta técnica es sintetizar la información contenida en variables correlacionadas mediante un número reducido de componentes. Es importante señalar que las correlaciones identificadas representan asociaciones lineales entre las variables y no implican necesariamente relaciones de causalidad. Por lo tanto, las interpretaciones realizadas describen el comportamiento conjunto observado en la base de datos.

5.4. Selección de la matriz para el Análisis de Componentes Principales

A partir de los resultados obtenidos mediante las matrices de varianzas y covarianzas S y de correlaciones R , es necesario determinar cuál de las dos matrices resulta más apropiada para realizar el Análisis de Componentes Principales.

Como se observó anteriormente, las variables presentan varianzas de órdenes de magnitud considerablemente diferentes. La variable $v7$ presenta una varianza de aproximadamente 0.4810, mientras que la variable $v10$ presenta una varianza de aproximadamente 104712.9781. Esta diferencia implica que, si se utilizara directamente la matriz S , las variables con mayor variabilidad podrían tener una influencia desproporcionada en la construcción de las componentes principales.

En particular, la variable $v10$, correspondiente a las muertes maternas por cada 100,000 nacimientos, presenta una varianza considerablemente mayor que la de las demás variables. Por lo tanto, utilizar la matriz de varianzas y covarianzas podría provocar que una parte importante de la variabilidad de los componentes estuviera determinada por la escala de esta variable y no necesariamente por la estructura conjunta de los indicadores.

Por esta razón, se decidió realizar el Análisis de Componentes Principales utilizando la matriz de correlaciones R . Esta elección permite estandarizar previamente las variables, de manera que todas tengan media cero y varianza uno. Así, cada indicador participa en el análisis bajo una escala comparable.

El uso de la matriz R también permite que las correlaciones identificadas anteriormente sean utilizadas directamente para estudiar la estructura de relaciones entre las variables. De esta manera, el ACP se enfoca en la asociación existente entre los indicadores y no en las diferencias producidas únicamente por sus unidades de medición.

Por lo tanto, para el desarrollo de las siguientes etapas del análisis se utilizará la matriz de correlaciones R . A partir de esta matriz se calcularán los eigenvalores y eigenvectores, los cuales permitirán construir las componentes principales y determinar la proporción de variabilidad explicada por cada una.

En resumen, la selección de la matriz R se justifica principalmente por las diferencias existentes entre las varianzas de las variables. Al trabajar con la matriz de correlaciones se evita que las variables con mayor escala o variabilidad dominen el análisis y se permite una comparación más adecuada entre los diferentes indicadores.

6. Análisis utilizando la técnica

6.1. Eigenvalores y eigenvectores

Una vez seleccionada la matriz de correlaciones R , se calcularon sus eigenvalores y eigenvectores mediante la función `eigen()` de R. Los eigenvalores obtenidos fueron:

Cuadro 3: Eigenvalores de la matriz de correlaciones

Componente	Eigenvalor
CP_1	6.0386
CP_2	1.3798
CP_3	0.6745
CP_4	0.5112
CP_5	0.3737
CP_6	0.3123
CP_7	0.2879
CP_8	0.2348
CP_9	0.1427
CP_{10}	0.0444

Debido a que el análisis se realizó utilizando la matriz de correlaciones, la suma de los eigenvalores es igual al número de variables consideradas, es decir,

$$\sum_{k=1}^{10} \lambda_k = 10.$$

El mayor eigenvalor corresponde a la primera Componente Principal, con un valor de 6.0386. Debido a que el análisis se realizó a partir de la matriz de correlaciones, este eigenvalor representa la varianza de CP_1 y corresponde al 60.3863 % de la variabilidad total. El segundo eigenvalor es igual a 1.3798, mientras que los eigenvalores restantes son menores que uno.

Los eigenvectores obtenidos contienen los coeficientes que determinan la dirección de cada Componente Principal en el espacio de las variables originales. Debido a que posteriormente se seleccionaron las dos primeras componentes para el análisis, en la Tabla 4 se presentan los eigenvectores correspondientes a CP_1 y CP_2 .

Cuadro 4: Eigenvectores correspondientes a las dos primeras Componentes Principales

Variable	Eigenvector CP_1	Eigenvector CP_2
v_1	0.3471	0.1199
v_2	-0.3704	0.0121
v_3	0.2701	-0.1789
v_4	0.3085	-0.1219
v_5	-0.3379	0.3948
v_6	-0.3534	0.2069
v_7	0.2414	0.5691
v_8	0.1393	0.6453
v_9	0.3794	0.0251
v_{10}	0.3462	-0.0365

Cada eigenvector representa los coeficientes asociados con las variables originales estandarizadas

en la dirección de su respectiva Componente Principal. Por lo tanto, las Componentes Principales se construyen como combinaciones lineales de las diez variables estandarizadas, utilizando los coeficientes proporcionados por los eigenvectores correspondientes.

Es importante distinguir estos coeficientes de las cargas (*loadings*). Los eigenvectores determinan la dirección de las componentes principales, mientras que las cargas representan la relación entre cada variable original y cada componente. Las cargas serán utilizadas posteriormente para facilitar la interpretación de las Componentes Principales.

6.2. Primeras tres Componentes Principales

Considerando las variables estandarizadas $Z_1, \dots, Z_{10}$, las primeras tres Componentes Principales se expresan como combinaciones lineales de las variables originales estandarizadas.

La primera Componente Principal está dada por

$$\begin{aligned} CP_1 = & 0.3477Z_1 - 0.3714Z_2 + 0.2701Z_3 + 0.3085Z_4 - 0.2979Z_5 \\ & - 0.3534Z_6 + 0.2414Z_7 + 0.1932Z_8 + 0.3794Z_9 + 0.3462Z_{10}. \end{aligned}$$

La segunda Componente Principal se expresa como

$$\begin{aligned} CP_2 = & 0.1199Z_1 + 0.0121Z_2 - 0.1789Z_3 - 0.1221Z_4 + 0.3947Z_5 \\ & + 0.2069Z_6 + 0.5691Z_7 + 0.6435Z_8 - 0.0251Z_9 - 0.0366Z_{10}. \end{aligned}$$

Finalmente, la tercera Componente Principal está dada por

$$\begin{aligned} CP_3 = & -0.0153Z_1 + 0.0348Z_2 - 0.7595Z_3 - 0.1065Z_4 - 0.4357Z_5 \\ & - 0.1694Z_6 - 0.1623Z_7 + 0.2484Z_8 - 0.1203Z_9 + 0.2989Z_{10}. \end{aligned}$$

Estas expresiones muestran los coeficientes asociados con cada variable estandarizada en la construcción de las primeras tres Componentes Principales. La magnitud y el signo de estos coeficientes determinan la dirección y participación de cada variable en la combinación lineal correspondiente. La interpretación de las componentes seleccionadas se realizará posteriormente mediante el análisis de sus cargas (*loadings*).

6.3. Gráficas de las Componentes Principales

Con el propósito de analizar la distribución de los países en el espacio definido por las componentes principales, se construyeron las gráficas correspondientes a CP_1 contra CP_2 y CP_2 contra CP_3 . Estas representaciones permiten observar la dispersión de las observaciones y detectar posibles patrones de agrupamiento, así como observaciones que presentan posiciones alejadas del comportamiento general de la base.




Figura 4: Distribución de los países en las componentes $CP1$ y $CP2$.

En la Figura 4 se observa una concentración importante de países en la región correspondiente a valores negativos de $CP1$ y valores cercanos a cero de $CP2$. En esta zona se encuentra una proporción considerable de las observaciones, lo que indica que existe un comportamiento relativamente similar entre estos países respecto a las características representadas por las dos primeras componentes.

En la región correspondiente a valores positivos de $CP1$ se observa una mayor separación entre algunas de las observaciones, particularmente aquellas que presentan posiciones más alejadas del conjunto central. Entre las observaciones que se encuentran más alejadas del conjunto principal destacan Zaire, Congo, República Centroafricana y Zambia, ubicadas en la región superior derecha de la gráfica.

También se identifican observaciones alejadas en la región inferior, entre las que destacan Somalia, Afganistán y Yemen. Estas posiciones indican que dichos países presentan combinaciones de características diferentes respecto al comportamiento predominante en la base.

A pesar de que visualmente pueden identificarse zonas de concentración, estas no deben interpretarse como conglomerados formales, debido a que el Análisis de Componentes Principales tiene como objetivo reducir la dimensionalidad de los datos y representar su estructura de variabilidad, mientras que la formación de conglomerados corresponde a técnicas específicas de clasificación.




Figura 5: Distribución de los países en las componentes CP_2 y CP_3 .

En la Figura 5 se observa nuevamente una concentración importante de observaciones alrededor de la región central de la gráfica. Sin embargo, también se identifican países que presentan posiciones alejadas del conjunto principal, lo que refleja diferencias en las combinaciones de características representadas por la segunda y tercera Componentes Principales.

En la parte superior de la gráfica destacan Bangladesh y Nepal por presentar valores elevados de CP_3 . Ambos países se ubican además en valores negativos de CP_2 . También se observa a Congo en una posición claramente alejada, hacia valores positivos tanto de CP_2 como de CP_3 .

Por otra parte, Zaire y Zambia presentan posiciones alejadas hacia valores positivos de CP_2 . Sin embargo, difieren respecto a la tercera componente, ya que Zambia presenta un valor positivo de CP_3 , mientras que Zaire se ubica en valores negativos de esta componente.

En la región inferior de la gráfica se encuentran países como Tanzania, República Dominicana, Omán y Yemen, entre otros, que presentan valores negativos de CP_3 . Afganistán y Somalia también presentan posiciones alejadas del conjunto central, aunque se ubican en una región diferente, caracterizada por valores negativos de CP_2 y positivos de CP_3 .

En conjunto, la gráfica permite observar que, aunque una proporción importante de los países se concentra alrededor del origen del espacio definido por las componentes, algunas observaciones presentan posiciones considerablemente alejadas. Estas diferencias reflejan comportamientos

particulares respecto a las combinaciones de variables representadas por CP_2 y CP_3 .

En ambas gráficas se observa que una parte importante de los países se concentra en una zona relativamente cercana al centro, mientras que un conjunto de observaciones presenta posiciones más extremas. Estas diferencias permiten identificar países con comportamientos particulares dentro del conjunto de indicadores analizados.

Desde una perspectiva descriptiva, las observaciones más alejadas del centro pueden considerarse posibles valores atípicos dentro del espacio de las componentes. Sin embargo, su identificación como valores atípicos debe entenderse en términos de su posición conjunta en las componentes y no necesariamente como valores atípicos en cada una de las variables originales.

Por lo tanto, las gráficas muestran que las componentes principales permiten representar visualmente diferencias entre los países y facilitan la identificación de observaciones alejadas del comportamiento general. No obstante, para determinar qué variables son responsables de estas diferencias es necesario analizar las cargas (*loadings*) de las componentes principales.

6.4. Varianza explicada por las Componentes Principales

Una vez obtenidos los eigenvalores de la matriz de correlaciones R , se determinó la varianza asociada a cada Componente Principal. En el Análisis de Componentes Principales, cada eigenvalor representa la varianza explicada por la componente correspondiente.

Los resultados obtenidos fueron:

Cuadro 5: Varianza explicada por las Componentes Principales

Componente	Eigenvalor	Varianza (%)	Acumulada (%)
CP_1	6.0386	60.3863	60.3863
CP_2	1.3798	13.7975	74.1839
CP_3	0.6745	6.7452	80.9290
CP_4	0.5112	5.1123	86.0413
CP_5	0.3737	3.7374	89.7787
CP_6	0.3123	3.1233	92.9020
CP_7	0.2879	2.8785	95.7805
CP_8	0.2348	2.3485	98.1290
CP_9	0.1427	1.4266	99.5556
CP_{10}	0.0444	0.4444	100.0000

La varianza total corresponde a la suma de los eigenvalores de la matriz de correlaciones. Debido a que se utilizaron diez variables estandarizadas, dicha suma es igual a diez:

$$\sum_{i=1}^{10} \lambda_i = 10.$$

Por lo tanto, la proporción de varianza explicada por una componente principal puede calcularse mediante:

$$\text{Porcentaje de varianza explicada}_i = \frac{\lambda_i}{\sum_{j=1}^{10} \lambda_j} \times 100.$$

Por ejemplo, para la primera componente se obtiene:

$$\frac{6.0386}{10} \times 100 = 60.3863 \%.$$

De manera análoga, la segunda componente explica:

$$\frac{1.3798}{10} \times 100 = 13.7975 \%.$$

En conjunto, las dos primeras componentes explican:

$$60.3863 \% + 13.7975 \% = 74.1839 \%$$

de la variabilidad total de las diez variables originales.




Figura 6: Gráfico de sedimentación de las Componentes Principales.

El gráfico de sedimentación mostrado en la Figura 6 presenta una disminución pronunciada de los eigenvalores entre las primeras componentes. La caída más importante se observa entre CP_1 y CP_2 , seguida de una disminución adicional entre CP_2 y CP_3 . A partir de CP_3 , la curva presenta un comportamiento más plano y los eigenvalores son considerablemente menores. Este comportamiento sugiere que las primeras componentes concentran la mayor parte de la variabilidad, mientras que las componentes posteriores aportan proporciones relativamente pequeñas.

6.5. Selección del número de Componentes Principales

Para determinar el número de componentes que se conservarán se utilizó el criterio de Kaiser, de acuerdo con el cual se consideran aquellas componentes cuyos eigenvalores sean mayores que uno. En los resultados obtenidos se observa que únicamente las dos primeras componentes cumplen este criterio:

$$\lambda_1 = 6.0386 > 1$$

y

$$\lambda_2 = 1.3798 > 1.$$

A partir de la tercera componente se tiene:

$$\lambda_3 = 0.6745 < 1,$$

y las componentes posteriores presentan también eigenvalores menores que uno.

Por lo anterior, se decidió conservar las dos primeras Componentes Principales. Esta decisión permite reducir las diez variables originales a dos dimensiones, manteniendo aproximadamente el 74.1839 % de la variabilidad total de la información.

La elección de dos componentes también resulta consistente con el gráfico de sedimentación, en el cual se observa una caída muy pronunciada entre CP_1 y CP_2 , seguida de una disminución adicional entre CP_2 y CP_3 . A partir de CP_3 , la curva presenta un comportamiento considerablemente más plano.

En consecuencia, las componentes CP_1 y CP_2 serán las utilizadas para la interpretación de las cargas (*loadings*) y para el análisis de la estructura de los indicadores originales.

6.6. Interpretación de las Componentes Principales

Una vez seleccionadas las dos primeras Componentes Principales, se analizaron sus cargas (*loadings*) con el propósito de identificar las variables que presentan mayor contribución a la construcción de cada componente.

Las cargas representan la asociación entre cada variable estandarizada y la componente principal. Por lo tanto, una carga con valor absoluto elevado indica una mayor contribución de la variable a la componente, mientras que una carga cercana a cero indica una contribución relativamente pequeña.

6.6.1. Interpretación de la primera Componente Principal

La primera Componente Principal presenta cargas tanto positivas como negativas. Las cargas obtenidas para las diez variables originales se presentan en la Tabla 6.

Cuadro 6: Cargas de la primera Componente Principal

Variable	Carga en CP_1
Nacimientos adolescentes	0.8545
Uso de anticoncepción	-0.9127
Políticas de aborto	0.6638
Embarazadas con anemia	0.7581
Atención prenatal	-0.7319
Partos asistidos	-0.8684
Nivel de VIH/SIDA	0.5931
Infertilidad	0.4748
Nacimientos por mujer	0.9323
Muertes maternas	0.8507

Las principales cargas positivas corresponden a v_9 , relacionada con el promedio de nacimientos por mujer, con un valor de 0.9323; v_1 , correspondiente a los nacimientos anuales por cada 100 mujeres de 15 a 19 años, con 0.8545; v_{10} , correspondiente a las muertes maternas por cada 100,000 nacimientos, con 0.8507; y v_4 , relacionada con el porcentaje de embarazadas con anemia, con 0.7581.

También se presentan cargas positivas para v_3 , correspondiente a las políticas de aborto, con un valor de 0.6638; v_7 , relacionada con el nivel de VIH/SIDA, con 0.5931; y v_8 , correspondiente a la infertilidad, con 0.4748.

Por otra parte, las principales cargas negativas corresponden a v_2 , relacionada con el porcentaje de mujeres que utilizan anticoncepción, con un valor de -0.9127; v_6 , correspondiente al porcentaje de partos asistidos por personal capacitado, con -0.8684; y v_5 , relacionada con el porcentaje de mujeres que reciben atención prenatal, con -0.7319.

La estructura de estas cargas permite observar que la primera componente contrapone dos conjuntos de características. Por un lado, presenta cargas positivas elevadas asociadas con el promedio de nacimientos por mujer, los nacimientos en adolescentes, las muertes maternas y el porcentaje de embarazadas con anemia. También presenta cargas positivas en las variables relacionadas con las políticas de aborto, el nivel de VIH/SIDA y la infertilidad.

Por otro lado, el uso de anticoncepción, la atención prenatal y los partos asistidos por personal capacitado presentan cargas negativas de magnitud elevada.

Por lo tanto, los valores positivos de CP_1 se encuentran asociados principalmente con países que presentan mayores niveles en indicadores relacionados con la fecundidad, los nacimientos en adolescentes, la mortalidad materna y algunas condiciones de vulnerabilidad en salud. En contraste,

los valores negativos de la componente se relacionan con mayores niveles de indicadores asociados con el uso de anticoncepción, la atención prenatal y la asistencia profesional durante los partos. Debido a esta estructura, la primera Componente Principal puede interpretarse como una dimensión asociada con la **vulnerabilidad reproductiva y materna**, en la que se contraponen indicadores relacionados con mayores niveles de fecundidad y problemas de salud materna frente a indicadores relacionados con servicios y atención de salud reproductiva.

Es importante señalar que esta interpretación describe la estructura de asociación encontrada en la base de datos y no implica que una variable sea causa de otra. Asimismo, el signo de una componente puede invertirse sin modificar las propiedades estadísticas del ACP; por ello, la interpretación debe centrarse principalmente en la magnitud relativa y en el patrón conjunto de las cargas.

6.6.2. Interpretación de la segunda Componente Principal

La segunda Componente Principal presenta una estructura diferente a la observada en CP_1 . Las cargas obtenidas para las diez variables originales se presentan en la Tabla 7.

Cuadro 7: Cargas de la segunda Componente Principal

Variable	Carga en CP_2
Nacimientos adolescentes	0.1408
Uso de anticoncepción	0.0142
Políticas de aborto	-0.2101
Embarazadas con anemia	-0.1434
Atención prenatal	0.4637
Partos asistidos	0.2430
Nivel de VIH/SIDA	0.6685
Infertilidad	0.7559
Nacimientos por mujer	-0.0295
Muertes maternas	-0.0430

La segunda Componente Principal presenta sus mayores cargas positivas en v_8 , correspondiente a la infertilidad, con un valor de 0.7559, y v_7 , relacionada con el nivel de VIH/SIDA, con 0.6685. También destaca la carga positiva de v_5 , correspondiente a la atención prenatal, con un valor de 0.4637.

Asimismo, v_6 , correspondiente a los partos asistidos por personal capacitado, presenta una carga positiva de 0.2430, mientras que v_1 , relacionada con los nacimientos adolescentes, presenta una carga de 0.1408.

Por otra parte, las cargas negativas de la segunda componente corresponden a v_3 , relacionada con las políticas de aborto, con un valor de -0.2101; v_4 , correspondiente al porcentaje de embarazadas con anemia, con -0.1434; v_9 , relacionada con los nacimientos por mujer, con -0.0295; y v_{10} ,

correspondiente a las muertes maternas, con -0.0430 .

Finalmente, v_2 , correspondiente al uso de anticoncepción, presenta una carga de 0.0142 , cuyo valor se encuentra muy cercano a cero. Esto indica que dicha variable presenta una asociación prácticamente nula con la segunda componente.

La estructura de CP_2 muestra que las variables relacionadas con la infertilidad y el nivel de VIH/SIDA presentan la asociación positiva más fuerte con esta componente. La atención prenatal también presenta una asociación positiva importante, aunque de menor magnitud que las dos variables anteriores.

En contraste, las variables relacionadas con las políticas de aborto, las embarazadas con anemia, los nacimientos por mujer y las muertes maternas presentan cargas negativas de magnitud relativamente pequeña. De manera similar, el uso de anticoncepción presenta una carga prácticamente nula.

Por lo anterior, la segunda Componente Principal puede interpretarse como una dimensión asociada principalmente con ciertas condiciones de salud reproductiva y sanitaria, caracterizada especialmente por su relación positiva con la infertilidad y el nivel de VIH/SIDA, y en menor medida con la atención prenatal.

6.7. Correlación de la primera Componente Principal con la calificación de riesgo

Como parte del análisis se calculó la correlación entre la primera Componente Principal y la variable original correspondiente a la calificación de riesgo, v_{11} . Esta variable no fue utilizada en la construcción del ACP, por lo que se empleó posteriormente para evaluar su relación con la estructura resumida por las componentes principales.

La correlación obtenida entre CP_1 y la calificación de riesgo fue:

$$\text{Cor}(CP_1, v_{11}) = 0.9915.$$

Este resultado muestra una relación positiva y extremadamente fuerte entre la primera Componente Principal y la calificación de riesgo. En términos generales, los países que presentan valores elevados de CP_1 tienden también a presentar valores elevados en la calificación de riesgo.

Para complementar este resultado, se calcularon las correlaciones entre todas las Componentes Principales y la calificación de riesgo.

Cuadro 8: Correlación de las Componentes Principales con la calificación de riesgo

Componente	Correlación con $v11$
CP_1	0.9915
CP_2	0.0234
CP_3	-0.0452
CP_4	-0.0172
CP_5	0.0267
CP_6	0.0371
CP_7	-0.0142
CP_8	0.0417
CP_9	0.0116
CP_{10}	-0.0156

La comparación muestra que la relación de la calificación de riesgo con CP_1 es considerablemente mayor que con cualquiera de las demás componentes. Mientras que la primera componente presenta una correlación de 0.9915, las restantes presentan valores cercanos a cero.

El resultado de la correlación debe analizarse conjuntamente con la varianza explicada por CP_1 . La primera componente explica por sí sola el 60.3863 % de la variabilidad total de las diez variables utilizadas en el ACP y, además, presenta una correlación de 0.9915 con la calificación de riesgo. En conjunto, estos resultados muestran que la principal dimensión de variabilidad de los indicadores analizados se encuentra estrechamente asociada con la calificación de riesgo.

Es importante señalar que esta correlación no implica que $v11$ haya sido utilizada para calcular CP_1 , ya que la calificación de riesgo fue excluida deliberadamente del ACP. El resultado únicamente indica que ambas variables presentan una estructura de comportamiento muy similar dentro de las observaciones analizadas.

6.8. Relación entre las variables originales y la calificación de riesgo

Finalmente, se analizó la relación existente entre la calificación de riesgo ($v11$) y cada una de las diez variables originales utilizadas en el Análisis de Componentes Principales. Este análisis permite identificar cuáles de los indicadores presentan una mayor asociación con la calificación de riesgo. Los resultados obtenidos se presentan en la Tabla 9.

Cuadro 9: Correlación de las variables originales con la calificación de riesgo

Variable	Correlación con v_{11}
Nacimientos por mujer	0.9148
Uso de anticoncepción	-0.8913
Partos asistidos	-0.8594
Nacimientos adolescentes	0.8417
Muertes maternas	0.8213
Embarazadas con anemia	0.7623
Atención prenatal	-0.7141
Políticas de aborto	0.6872
Nivel de VIH/SIDA	0.6264
Infertilidad	0.4811

Los resultados muestran que la calificación de riesgo presenta una relación positiva elevada con variables como los nacimientos por mujer, los nacimientos adolescentes, las muertes maternas y el porcentaje de embarazadas con anemia. Por otro lado, presenta relaciones negativas elevadas con el uso de anticoncepción, los partos asistidos por personal capacitado y la atención prenatal.

La variable con mayor correlación positiva con la calificación de riesgo es v_9 , correspondiente a los nacimientos por mujer, con un coeficiente de 0.9148. En contraste, la mayor correlación negativa corresponde a v_2 , relacionada con el uso de anticoncepción, con un valor de -0.8913.

Este comportamiento presenta una similitud importante con las cargas obtenidas para la primera Componente Principal. En particular, las variables que presentan las mayores correlaciones con la calificación de riesgo también son algunas de las que presentan las mayores cargas, en valor absoluto, en CP_1 .

Por ejemplo, v_9 presenta una carga de 0.9323 en CP_1 y una correlación de 0.9148 con la calificación de riesgo. De manera similar, v_2 presenta una carga de -0.9127 en CP_1 y una correlación de -0.8913 con v_{11} . También se observa este comportamiento en v_6 , v_1 , v_{10} , v_4 y v_5 .

Esta similitud se encuentra respaldada por la correlación calculada anteriormente entre la primera Componente Principal y la calificación de riesgo:

$$\text{Cor}(CP_1, v_{11}) = 0.9915.$$

El valor obtenido indica una relación positiva extremadamente fuerte entre ambas variables. Además, las correlaciones de las restantes componentes con la calificación de riesgo son cercanas a cero, por lo que la relación de v_{11} se encuentra concentrada principalmente en la primera componente. A partir de estos resultados, puede plantearse como hipótesis que la calificación de riesgo está estrechamente relacionada con una combinación de los indicadores incluidos en la base de datos. La evidencia observada muestra que los indicadores con mayores correlaciones con v_{11} presentan patrones de signo y magnitud similares a los observados en las cargas de CP_1 . En particular, los indicadores asociados con mayores niveles de fecundidad, nacimientos adolescentes, mortalidad

materna y algunas condiciones de vulnerabilidad presentan relaciones positivas con la calificación de riesgo, mientras que el uso de anticoncepción, la atención prenatal y los partos asistidos presentan relaciones negativas.

Sin embargo, debido a que la base de datos no proporciona la metodología o fórmula utilizada para construir la variable $v11$, no es posible determinar con certeza la expresión matemática exacta del índice de riesgo. Por lo tanto, la interpretación anterior debe considerarse como una hipótesis basada en las correlaciones observadas y en la estructura obtenida mediante el Análisis de Componentes Principales.

En conclusión, los resultados permiten observar que la primera Componente Principal presenta una estructura estadística muy similar a la de la calificación de riesgo. La correlación de 0.9915 sugiere que CP_1 constituye una representación estadística muy próxima al patrón de variabilidad asociado con la calificación de riesgo de los países incluidos en la base de datos. Sin embargo, este resultado no permite afirmar que ambas variables hayan sido construidas mediante la misma expresión matemática.

7. Conclusiones

El desarrollo del Análisis de Componentes Principales permitió sintetizar la información contenida en diez indicadores relacionados con la salud reproductiva y materna de 118 países. Previo a la aplicación del ACP, se identificaron cuatro valores faltantes, dos en $v5$ y dos en $v6$, los cuales fueron tratados mediante imputación con la mediana correspondiente. Este procedimiento permitió conservar la totalidad de las observaciones disponibles y obtener una base completa para el análisis. El análisis descriptivo y de las varianzas mostró que las variables presentaban diferencias importantes en sus órdenes de magnitud. En particular, la variable correspondiente a las muertes maternas presentó una variabilidad considerablemente mayor que el resto de los indicadores. Debido a estas diferencias de escala, se decidió utilizar la matriz de correlaciones R en lugar de la matriz de varianzas y covarianzas S , trabajando así con las variables estandarizadas y evitando que las diferencias en las unidades de medición determinaran de manera desproporcionada la construcción de las componentes.

A partir de la matriz de correlaciones se obtuvieron los eigenvalores y eigenvectores necesarios para construir las Componentes Principales. La primera componente presentó un eigenvalor de 6.0386 y explicó el 60.3863 % de la variabilidad total, mientras que la segunda presentó un eigenvalor de 1.3798 y explicó un 13.7975 % adicional. De acuerdo con el criterio de Kaiser, únicamente estas dos componentes presentaron eigenvalores mayores que uno. Esta selección también fue consistente con el comportamiento observado en el gráfico de sedimentación. En conjunto, CP_1 y CP_2 permitieron representar aproximadamente el 74.1839 % de la variabilidad total de las diez variables originales. La interpretación de las cargas permitió identificar las principales características asociadas con cada componente. La primera Componente Principal presentó cargas positivas elevadas en variables

relacionadas con los nacimientos por mujer, los nacimientos adolescentes, las muertes maternas y la anemia, mientras que presentó cargas negativas importantes en el uso de anticoncepción, la atención prenatal y los partos asistidos por personal capacitado. Por esta estructura, CP_1 puede interpretarse como una dimensión asociada con la vulnerabilidad reproductiva y materna, en la que se contraponen indicadores relacionados con mayores niveles de fecundidad y condiciones de vulnerabilidad frente a indicadores asociados con servicios de atención y prevención.

Por su parte, la segunda Componente Principal presentó sus mayores cargas positivas en las variables relacionadas con la infertilidad y el nivel de VIH/SIDA, acompañadas por una contribución positiva de la atención prenatal. En consecuencia, CP_2 puede interpretarse como una dimensión relacionada principalmente con determinadas condiciones de salud reproductiva y sanitaria que presentan una menor representación en la primera componente.

Uno de los resultados más relevantes del análisis fue la correlación obtenida entre la primera Componente Principal y la calificación de riesgo, con un valor de

$$\text{Cor}(CP_1, v11) = 0.9915.$$

Esta relación positiva y extremadamente fuerte indica que la dimensión representada por CP_1 presenta un comportamiento muy similar al de la calificación de riesgo incluida en la base de datos. Asimismo, las restantes componentes presentaron correlaciones cercanas a cero con dicha variable, por lo que la asociación de la calificación de riesgo con la estructura resumida mediante las componentes se encuentra concentrada principalmente en CP_1 .

En conjunto, los resultados muestran que la reducción de diez variables a dos componentes permitió conservar una proporción considerable de la variabilidad de la información original, facilitando la representación e interpretación de las principales dimensiones presentes en los datos. Las gráficas de las componentes también permitieron identificar diferencias en la posición de los países y observaciones alejadas del comportamiento central.

Finalmente, debe señalarse que la elevada correlación entre CP_1 y la calificación de riesgo no implica una relación causal ni permite determinar la fórmula utilizada para construir dicha calificación. Debido a que la base de datos no proporciona la metodología mediante la cual fue calculada la variable $v11$, los resultados únicamente permiten identificar una fuerte asociación entre ambas variables. Por lo tanto, las conclusiones obtenidas deben entenderse dentro del contexto de la estructura estadística de la base de datos analizada.

Referencias

- [1] Sala, A. (s.f.). *Análisis de Componentes Principales: teoría*. Universitat Politècnica de València. Disponible en: <https://personales.upv.es/asala/DocenciaOnline/Video/pca1>.

html

- [2] Universitat de València. (s.f.). *Análisis de Componentes Principales*. Proyecto CEACES. Disponible en: <https://www.uv.es/ceaces/multivari/factorial/factorial.htm>
- [3] Fallas, J. J. y Chavarría, J. (2014). *Implementación del Análisis en Componentes Principales con el software estadístico R*. Revista Digital: Matemática, Educación e Internet, 11(2). Instituto Tecnológico de Costa Rica. Disponible en: <https://revistas.tec.ac.cr/index.php/matematica/article/view/1958>
- [4] Minitab. (s.f.). *Interpretar los resultados clave para Análisis de los componentes principales*. Minitab. Disponible en: <https://support.minitab.com/es-mx/minitab/help-and-how-to/statistical-modeling/multivariate/how-to/principal-components/interpret-the-results/key-results/>
- [5] Harvey, D. (s.f.). *Uso de R para un análisis de componentes principales*. LibreTexts Español. Disponible en: [https://espanol.libretexts.org/Bookshelves/Quimica/Química_Analítica/Quimiometría_usando_R_\(Harvey\)/11:_Encontrar_estructura_en_datos/11.06:_Uso_de_R_para_un_análisis_de_componentes_principales](https://espanol.libretexts.org/Bookshelves/Quimica/Química_Analítica/Quimiometría_usando_R_(Harvey)/11:_Encontrar_estructura_en_datos/11.06:_Uso_de_R_para_un_análisis_de_componentes_principales)

8. Anexos

8.1. Trabajo realizado sobre la base de datos

Para realizar el análisis estadístico se utilizó la base de datos denominada “riesgo”, proporcionada para el desarrollo de la práctica. La información se encontraba almacenada en un archivo de Excel con extensión `.xls`, organizado en diferentes hojas de trabajo.

La primera hoja del archivo contenía la base de datos principal. Es importante señalar que la primera fila de esta hoja correspondía directamente a la primera observación y no a los nombres de las variables. Por esta razón, al importar la información a R se indicó que el archivo no contenía nombres de columnas y posteriormente se asignaron manualmente los nombres correspondientes a las variables.

La segunda hoja contenía la descripción de las variables y la codificación de algunos de los indicadores utilizados en el análisis. Esta información permitió identificar el significado de cada variable y establecer la correspondencia entre los códigos utilizados en la base y los indicadores que representan.

La tercera hoja del archivo no contenía información adicional, por lo que no fue utilizada durante el procesamiento de los datos.

La base de datos fue importada a R mediante la función `read_excel()` del paquete `readxl`. Debido a que la primera fila correspondía a una observación, se utilizó la opción `col_names = FALSE` durante la lectura del archivo. Posteriormente, se asignaron los nombres a las doce columnas de la base.

La primera columna corresponde al país, mientras que las siguientes once columnas fueron identificadas como `v1` a `v11`. La estructura de la base fue revisada mediante las funciones `head()`, `str()`, `dim()`, `names()` y `summary()`, con el propósito de comprobar que la información hubiera sido importada correctamente.

Como resultado de esta revisión se identificaron 118 observaciones y 12 variables. Para la aplicación del Análisis de Componentes Principales se seleccionaron las variables `v1` a `v10`. La variable correspondiente al país se mantuvo únicamente como identificador de las observaciones y no fue incorporada al análisis numérico.

La variable `v11`, correspondiente a la “calificación de riesgo”, tampoco fue utilizada para construir las componentes principales. Esta variable se conservó de manera independiente para analizar posteriormente su relación con los componentes obtenidos.

Posteriormente, se realizó una revisión de los datos faltantes presentes en las diez variables seleccionadas para el ACP. Mediante la función `is.na()` se identificaron cuatro valores faltantes en total: dos correspondieron a la variable `v5` y dos a la variable `v6`.

Las observaciones que presentaban información faltante fueron identificadas para conocer los países afectados. Los valores faltantes de `v5` se encontraron en las observaciones correspondientes a Suiza

y Laos, mientras que los valores faltantes de $v6$ correspondieron a Congo y Zaire.

Debido a que se buscó conservar la totalidad de las observaciones disponibles, no se eliminaron los registros que presentaban valores faltantes. En su lugar, se realizó un proceso de imputación mediante la mediana de cada variable.

Para llevar a cabo este procedimiento, se calculó la mediana de cada una de las variables utilizando los valores disponibles. Posteriormente, los valores faltantes fueron sustituidos por la mediana correspondiente.

Las medianas utilizadas para realizar la imputación fueron:

Cuadro 10: Medianas utilizadas para la imputación de datos faltantes

Variable	Mediana
$v5$	79.50
$v6$	71.50

Por lo tanto, los dos valores faltantes de la variable $v5$ fueron sustituidos por 79.50, mientras que los dos valores faltantes de la variable $v6$ fueron sustituidos por 71.50.

Una vez realizada la imputación, se verificó nuevamente la presencia de valores faltantes. El resultado mostró que ninguna de las diez variables utilizadas en el Análisis de Componentes Principales presentaba valores faltantes después del tratamiento.

De esta manera, se conservaron las 118 observaciones originales y se obtuvo una base completa para continuar con el análisis estadístico.

Una vez preparada la base de datos, se procedió a aplicar el Análisis de Componentes Principales sobre las diez variables seleccionadas. Debido a que las variables presentaban diferentes escalas de medición y órdenes de magnitud, se decidió trabajar con la matriz de correlaciones R . Esto equivale a estandarizar previamente las variables, de manera que cada una tenga media cero y varianza uno, evitando que las diferencias de escala provoquen que alguna variable tenga una influencia desproporcionada en la construcción de las componentes.

En primer lugar, se calculó la matriz de varianzas y covarianzas S , con el propósito de analizar la variabilidad de las variables originales. Posteriormente, se obtuvo la matriz de correlaciones R , a partir de la cual se evaluó la relación lineal existente entre los diferentes indicadores.

Una vez seleccionada la matriz R , se calcularon sus eigenvalores y eigenvectores. Los eigenvalores permitieron determinar la varianza explicada por cada Componente Principal, mientras que los eigenvectores proporcionaron los coeficientes necesarios para construir las componentes como combinaciones lineales de las variables estandarizadas.

A partir de los eigenvalores obtenidos se calculó la proporción de varianza explicada por cada componente y su porcentaje acumulado. También se elaboró el gráfico de sedimentación con el propósito de observar el comportamiento de los eigenvalores y apoyar la selección del número de componentes.

Posteriormente, se analizaron las primeras tres Componentes Principales mediante sus expresiones como combinaciones lineales de las variables estandarizadas. También se construyeron las gráficas correspondientes a CP_1 contra CP_2 y CP_2 contra CP_3 , con el objetivo de observar la distribución de los países en el espacio reducido de las componentes e identificar posibles zonas de concentración y observaciones alejadas.

Para determinar el número de componentes a conservar se consideró el criterio de Kaiser, de acuerdo con el cual se conservan aquellas componentes cuyos eigenvalores son mayores que uno. En este caso, únicamente CP_1 y CP_2 cumplieron dicho criterio. Además, ambas componentes acumularon el 74.1839 % de la variabilidad total, resultado que también fue considerado junto con el gráfico de sedimentación para seleccionar las dos primeras componentes.

Una vez seleccionadas CP_1 y CP_2 , se calcularon y analizaron sus cargas (*loadings*), considerando las diez variables originales. Esto permitió identificar el sentido y la magnitud de la contribución de cada variable a las componentes y establecer una interpretación de las dimensiones obtenidas. Finalmente, se analizó la relación de las componentes principales con la variable v_{11} , correspondiente a la calificación de riesgo. En particular, se calculó la correlación entre CP_1 y dicha variable, obteniéndose un valor de 0.9915. También se calcularon las correlaciones entre la calificación de riesgo y las diez variables originales, con el propósito de analizar el patrón de asociación existente y plantear una posible explicación sobre la construcción del índice de riesgo.

8.2. Código utilizado

```

1 # PRACTICA: ANALISIS DE COMPONENTES PRINCIPALES
2 # Base de datos: riesgo.xls
3
4 # CARGAR PAQUETES
5 library(readxl)
6 library(ggplot2)
7 library(corrplot)
8 library(factoextra)
9
10 # LEER EL ARCHIVO DE EXCEL
11 ruta <- "C:/Users/Garc a/Downloads/riesgo.xls"
12
13 # col_names = FALSE porque la primera fila es una observaci0n
14 riesgo <- read_excel(
15   ruta,
16   sheet = 1,
17   col_names = FALSE)
18
19 # ASIGNAR NOMBRES A LAS COLUMNAS
20 names(riesgo) <- c("pais", "v1", "v2", "v3", "v4", "v5", "v6", "v7", "v8", "v9", "v10", "v11")
21
22 # Revisar la base
23 View(riesgo)
24
25 # Ver primeras observaciones
26 head(riesgo)

```



```
27
28 # Revisar estructura
29 str(riesgo)
30
31 # REVISAR LA INFORMACION DE LA BASE
32
33 # Numero de observaciones y variables
34 dim(riesgo)
35
36 # Nombres de las variables
37 names(riesgo)
38
39 # Resumen estadístico
40 summary(riesgo)
41
42
43 # SEPARAR LAS VARIABLES PARA EL ACP
44 # La columna "pais" NO entra al análisis. v1 a v10 entran al ACP
45
46 datos <- riesgo[, c("v1", "v2", "v3", "v4", "v5", "v6", "v7", "v8", "v9", "v10")]
47
48 # v11 = calificación de riesgo NO participa en el ACP
49 calificacion_riesgo <- riesgo$v11
50
51 # REVISAR DATOS FALTANTES
52 # Numero de datos faltantes por variable
53
54 faltantes <- colSums(is.na(datos))
55 faltantes
56
57 # Porcentaje de datos faltantes
58 porcentaje_faltantes <- colMeans(is.na(datos)) * 100
59 porcentaje_faltantes
60
61 # Mostrar las observaciones que tienen algún dato faltante
62 datos[!complete.cases(datos), ]
63
64 # Mostrar los países que tienen algún dato faltante
65
66 riesgo[!complete.cases(datos), ]
67
68 # Guardar los números de fila que originalmente tenían algún dato faltante
69
70 filas_faltantes <- which(!complete.cases(datos))
71 filas_faltantes
72
73 # TRATAMIENTO DE DATOS FALTANTES
74
75 # NO se eliminan las observaciones. Los valores faltantes se imputan utilizando la MEDIANA de la
    variable correspondiente.
76
77 # Crear una copia de los datos originales
78 datos_imputados <- datos
79
80 # Imputar los valores faltantes
81
82 for(i in 1:ncol(datos_imputados)){
```

```
83
84 # Calcular la mediana de la variable ignorando los valores faltantes
85 mediana <- median(datos_imputados[[i]], na.rm = TRUE)
86
87 # Sustituir los valores NA por la mediana
88 datos_imputados[[i]][is.na(datos_imputados[[i]])] <- mediana}
89
90 # COMPROBAR LA IMPUTACION
91
92 # Verificar que no queden valores faltantes
93 colSums(is.na(datos_imputados))
94
95 # Mostrar las observaciones que originalmente tenían datos faltantes, después de la imputación
96 datos_imputados[filas_faltantes, ]
97
98 # VER LAS MEDIANAS UTILIZADAS
99 medianas <- sapply(
100   datos,
101   median,
102   na.rm = TRUE)
103
104 medianas
105
106 # MATRIZ S: VARIANZAS Y COVARIANZAS
107
108 S <- cov(datos_imputados)
109
110 # Mostrar matriz S
111 S
112
113 # Mostrar matriz S redondeada
114 round(S, 4)
115
116 # VARIANZAS DE LAS VARIABLES
117
118 varianzas <- diag(S)
119 varianzas
120
121 # Tabla de varianzas
122 tabla_varianzas <- data.frame(
123   Variable = names(datos_imputados),
124   Varianza = varianzas)
125
126 tabla_varianzas
127
128 # MATRIZ R: CORRELACIONES
129
130 R <- cor(datos_imputados)
131
132 # Mostrar matriz R
133 R
134
135 # Mostrar matriz R redondeada
136 round(R, 4)
137
138 # IDENTIFICAR CORRELACIONES ALTAS
139
```

```
140 # Crear una copia de la matriz de correlaciones
141 R_aux <- R
142
143 # Eliminar la diagonal
144 diag(R_aux) <- NA
145
146 # Buscar correlaciones altas. Usaremos |r| >= 0.70
147
148 correlaciones_altas <- which(
149   abs(R_aux) >= 0.70,
150   arr.ind = TRUE)
151
152 # Mostrar las correlaciones sin repetir pares
153
154 for(i in 1:nrow(correlaciones_altas)){
155
156   fila <- correlaciones_altas[i, 1]
157   columna <- correlaciones_altas[i, 2]
158
159   if(fila < columna){
160
161     cat(
162       names(datos_imputados)[fila],
163       " con ",
164       names(datos_imputados)[columna],
165       ": ",
166       round(R[fila, columna], 4),
167       "\n")}}
168
169 # MAPA DE CORRELACIONES
170
171 corrplot(
172   R,
173   method = "color",
174   type = "upper",
175   addCoef.col = "black",
176   tl.col = "black",
177   tl.srt = 45)
178
179
180 # GRAFICAS DEL ANALISIS DESCRIPTIVO
181
182 # Nombres descriptivos de las variables
183 nombres_variables <- c(
184   "Nacimientos adolescentes",
185   "Uso de anticoncepcion",
186   "Políticas de aborto",
187   "Embarazadas con anemia",
188   "Atencion prenatal",
189   "Partos asistidos",
190   "Nivel de VIH/SIDA",
191   "Infertilidad",
192   "Nacimientos por mujer",
193   "Muertes maternas")
194
195 # MEDIAS DE LOS INDICADORES
196
```

```
197 medias <- sapply(  
198   datos_imputados,  
199   mean,  
200   na.rm = TRUE)  
201  
202 tabla_medias <- data.frame(  
203   Variable = nombres_variabls,  
204   Media = medias)  
205  
206 # Ordenar de mayor a menor  
207 tabla_medias <- tabla_medias[  
208   order(tabla_medias$Media, decreasing = TRUE),]  
209  
210 # Convertir variable en factor para conservar el orden  
211 tabla_medias$Variable <- factor(  
212   tabla_medias$Variable,  
213   levels = tabla_medias$Variable)  
214  
215 grafica_medias <- ggplot(  
216   tabla_medias,  
217   aes(x = Variable, y = Media)) +  
218   geom_col(  
219     width = 0.7) +  
220   coord_flip() +  
221   geom_text(  
222     aes(label = round(Media, 2)),  
223     hjust = -0.15,  
224     size = 3.5) +  
225   labs(  
226     title = "Nivel promedio de los indicadores",  
227     subtitle = "Media de las variables utilizadas en el analisis",  
228     x = NULL,  
229     y = "Media") +  
230   theme_minimal(base_size = 12) +  
231   theme(  
232     plot.title = element_text(  
233       face = "bold",  
234       size = 16),  
235     plot.subtitle = element_text(  
236       size = 11),  
237     axis.text.y = element_text(  
238       size = 10),  
239     panel.grid.minor = element_blank(),  
240     plot.margin = margin(  
241       15, 30, 15, 15))  
242  
243 grafica_medias  
244  
245 ggsave(  
246   filename = "medias_indicadores.png",  
247   plot = grafica_medias,  
248   width = 11,  
249   height = 7,  
250   units = "in",  
251   dpi = 300,  
252   bg = "white")  
253
```

```

254 # DISPERSION DE LOS INDICADORES
255
256 desviaciones <- sapply(
257   datos_imputados,
258   sd,
259   na.rm = TRUE)
260
261 tabla_sd <- data.frame(
262   Variable = nombres_variaciones,
263   Desviacion = desviaciones)
264
265 tabla_sd <- tabla_sd[
266   order(tabla_sd$Desviacion, decreasing = TRUE),]
267
268 tabla_sd$Variable <- factor(
269   tabla_sd$Variable,
270   levels = tabla_sd$Variable)
271
272 grafica_sd <- ggplot(
273   tabla_sd,
274   aes(x = Variable, y = Desviacion)) +
275   geom_col(
276     width = 0.7) +
277   coord_flip() +
278   geom_text(
279     aes(label = round(Desviacion, 2)),
280     hjust = -0.15,
281     size = 3.5) +
282   labs(
283     title = "Dispersion de los indicadores",
284     subtitle = "Desviacion estandar de las variables analizadas",
285     x = NULL,
286     y = "Desviacion estandar") +
287   theme_minimal(base_size = 12) +
288   theme(
289     plot.title = element_text(
290       face = "bold",
291       size = 16),
292     plot.subtitle = element_text(
293       size = 11),
294     panel.grid.minor = element_blank(),
295     plot.margin = margin(
296       15, 30, 15, 15))
297
298 grafica_sd
299
300 ggsave(
301   filename = "dispersion_indicadores.png",
302   plot = grafica_sd,
303   width = 11,
304   height = 7,
305   units = "in",
306   dpi = 300,
307   bg = "white")
308
309 # BOXPLOT DE VARIABLES ESTANDARIZADAS
310

```

```

311 datos_estandarizados <- as.data.frame(
312   scale(datos_imputados))
313
314 datos_estandarizados$pais <- riesgo$pais
315
316 datos_largo <- reshape2::melt(
317   datos_estandarizados,
318   id.vars = "pais",
319   variable.name = "Variable",
320   value.name = "Valor")
321
322 datos_largo$Variable <- factor(
323   datos_largo$Variable,
324   levels = paste0("v", 1:10),
325   labels = nombres_variabales)
326
327 grafica_boxplot <- ggplot(
328   datos_largo,
329   aes(x = Variable, y = Valor) +
330   geom_boxplot(
331     width = 0.65,
332     outlier.size = 1.5) +
333   geom_hline(
334     yintercept = 0,
335     linetype = "dashed",
336     linewidth = 0.4) +
337   coord_flip() +
338   labs(
339     title = "Distribucion estandarizada de los indicadores",
340     subtitle = "Comparacion de la distribucion de las variables",
341     x = NULL,
342     y = "Valor estandarizado") +
343   theme_minimal(base_size = 12) +
344   theme(
345     plot.title = element_text(
346       face = "bold",
347       size = 16),
348     plot.subtitle = element_text(
349       size = 11),
350     axis.text.y = element_text(
351       size = 10),
352     panel.grid.minor = element_blank(),
353     plot.margin = margin(
354       15, 25, 15, 15))
355
356 grafica_boxplot
357
358 ggsave(
359   filename = "boxplot_indicadores.png",
360   plot = grafica_boxplot,
361   width = 11,
362   height = 8,
363   units = "in",
364   dpi = 300,
365   bg = "white")
366
367 # ANALISIS DE COMPONENTES PRINCIPALES

```

```
368
369 # Se realiza el ACP utilizando las variables estandarizadas, equivalente a trabajar con la matriz
    de correlaciones R.
370
371 ACP <- prcomp(
372   datos_imputados,
373   center = TRUE,
374   scale. = TRUE)
375
376 # Resumen de los componentes principales
377 summary(ACP)
378
379 # EIGENVALORES Y EIGENVECTORES
380
381 # Eigenvalores de la matriz de correlaciones
382 eigen_R <- eigen(R)
383
384 # Eigenvalores
385 eigen_R$values
386
387 # Eigenvectores
388 eigen_R$vectors
389
390 # Mostrar eigenvalores redondeados
391 round(eigen_R$values, 4)
392
393 # Mostrar eigenvectores redondeados
394 round(eigen_R$vectors, 4)
395
396 # GRAFICAS DE LOS COMPONENTES PRINCIPALES
397
398 library(ggplot2)
399
400 # Obtener las coordenadas de cada pais en los componentes
401 scores <- as.data.frame(ACP$x)
402
403 # Agregar el nombre del pais
404 scores$pais <- riesgo$pais
405
406 # GRAFICA CP1 VS CP2
407
408 grafica_CP1_CP2 <- ggplot(
409   scores,
410   aes(x = PC1, y = PC2)) +
411
412   # Lineas de referencia en los ejes
413   geom_hline(
414     yintercept = 0,
415     linetype = "dashed",
416     linewidth = 0.4) +
417
418   geom_vline(
419     xintercept = 0,
420     linetype = "dashed",
421     linewidth = 0.4) +
422
423   # Puntos
```

```

424 geom_point(
425   size = 2.8,
426   alpha = 0.75) +
427
428 # Etiquetas sin encimarse
429 geom_text_repel(
430   aes(label = pais),
431   size = 3,
432   box.padding = 0.45,
433   point.padding = 0.25,
434   max.overlaps = Inf,
435   segment.linewidth = 0.3,
436   min.segment.length = 0) +
437
438 labs(
439   title = "Análisis de Componentes Principales",
440   subtitle = "Distribucion de los paises en las dos primeras componentes",
441   x = "Primera componente principal (CP1)",
442   y = "Segunda componente principal (CP2)") +
443
444 theme_minimal(base_size = 12) +
445
446 theme(
447   plot.title = element_text(
448     face = "bold",
449     size = 16),
450   plot.subtitle = element_text(
451     size = 11),
452   axis.title = element_text(
453     face = "bold"),
454   panel.grid.minor = element_blank(),
455   plot.margin = margin(
456     15, 20, 15, 15))
457
458 # Mostrar grafica
459 grafica_CP1_CP2
460
461 # Guardar grafica
462 ggsave(
463   filename = "CP1_CP2.png",
464   plot = grafica_CP1_CP2,
465   width = 12,
466   height = 8,
467   units = "in",
468   dpi = 300,
469   bg = "white")
470
471 # GRAFICA CP2 VS CP3
472
473 grafica_CP2_CP3 <- ggplot(
474   scores,
475   aes(x = PC2, y = PC3)) +
476
477 # Lineas de referencia en los ejes
478 geom_hline(
479   yintercept = 0,
480   linetype = "dashed",

```



```

481     linewidth = 0.4) +
482
483 geom_vline(
484     xintercept = 0,
485     linetype = "dashed",
486     linewidth = 0.4) +
487
488 # Puntos
489 geom_point(
490     size = 2.8,
491     alpha = 0.75) +
492
493 # Etiquetas sin encimarse
494 geom_text_repel(
495     aes(label = pais),
496     size = 3,
497     box.padding = 0.45,
498     point.padding = 0.25,
499     max.overlaps = Inf,
500     segment.linewidth = 0.3,
501     min.segment.length = 0) +
502
503 labs(
504     title = "Análisis de Componentes Principales",
505     subtitle = "Distribucion de los paises en la segunda y tercera componente",
506     x = "Segunda componente principal (CP2)",
507     y = "Tercera componente principal (CP3)") +
508
509 theme_minimal(base_size = 12) +
510
511 theme(
512     plot.title = element_text(
513         face = "bold",
514         size = 16),
515     plot.subtitle = element_text(
516         size = 11),
517     axis.title = element_text(
518         face = "bold"),
519     panel.grid.minor = element_blank(),
520     plot.margin = margin(
521         15, 20, 15, 15))
522
523 # Mostrar grafica
524 grafica_CP2_CP3
525
526 # Guardar grafica
527 ggsave(
528     filename = "CP2_CP3.png",
529     plot = grafica_CP2_CP3,
530     width = 12,
531     height = 8,
532     units = "in",
533     dpi = 300,
534     bg = "white")
535
536 # VARIANZA DE CADA COMPONENTE Y VARIANZA TOTAL
537

```

```

538 # Los eigenvalores representan la varianza de cada componente principal
539 varianzas_componentes <- eigen_R$values
540
541 # Mostrar las varianzas
542 round(varianzas_componentes, 4)
543
544 # Varianza total
545 varianza_total <- sum(varianzas_componentes)
546 varianza_total
547
548 # Porcentaje de varianza explicado por cada componente
549 porcentaje_varianza <- (varianzas_componentes / varianza_total) * 100
550 round(porcentaje_varianza, 4)
551
552 # Porcentaje acumulado
553 porcentaje_acumulado <- cumsum(porcentaje_varianza)
554 round(porcentaje_acumulado, 4)
555
556 # TABLA DE VARIANZAS
557 tabla_componentes <- data.frame(
558
559   Componente = paste0(
560     "CP",
561     1:length(varianzas_componentes)),
562   Eigenvalor = varianzas_componentes,
563   Porcentaje = porcentaje_varianza,
564   Acumulado = porcentaje_acumulado)
565
566 tabla_componentes[, 2:4] <- round(tabla_componentes[, 2:4],4)
567
568 tabla_componentes
569
570
571 # GRAFICO DE SEDIMENTACION
572
573 grafica_sedimentacion <- ggplot(
574   tabla_componentes,
575   aes(
576     x = 1:10,
577     y = Eigenvalor)) +
578
579   geom_line(
580     linewidth = 0.8) +
581
582   geom_point(
583     size = 3) +
584
585   geom_hline(
586     yintercept = 1,
587     linetype = "dashed",
588     linewidth = 0.5) +
589
590   scale_x_continuous(
591     breaks = 1:10,
592     labels = paste0("CP", 1:10)) +
593
594   labs(

```

```

595     title = "Grafico de sedimentacion",
596     subtitle = "Eigenvalores de las componentes principales",
597     x = "Componente principal",
598     y = "Eigenvalor") +
599
600 theme_minimal(base_size = 12) +
601
602 theme(
603     plot.title = element_text(
604         face = "bold",
605         size = 16),
606     plot.subtitle = element_text(
607         size = 11),
608     axis.title = element_text(
609         face = "bold"),
610     panel.grid.minor = element_blank())
611
612 grafica_sedimentacion
613
614 # Guardar grafica
615 ggsave(
616     filename = "scree_plot.png",
617     plot = grafica_sedimentacion,
618     width = 10,
619     height = 7,
620     units = "in",
621     dpi = 300,
622     bg = "white")
623
624 # CARGAS (LOADINGS) DE LAS COMPONENTES
625
626 # Obtener las cargas de las componentes
627 loadings <- ACP$rotation %*% diag(ACP$sdev)
628
629 # Mostrar las cargas de las dos primeras componentes
630 loadings_CP12 <- loadings[, 1:2]
631 round(loadings_CP12, 4)
632
633 # NOMBRES DE LAS VARIABLES
634 nombres_variables <- c(
635     "Nacimientos adolescentes",
636     "Uso de anticoncepcion",
637     "Políticas de aborto",
638     "Embarazadas con anemia",
639     "Atencion prenatal",
640     "Partos asistidos",
641     "Nivel de VIH/SIDA",
642     "Infertilidad",
643     "Nacimientos por mujer",
644     "Muertes maternas")
645
646 # Tabla de loadings
647 tabla_loadings <- data.frame(
648     Variable = nombres_variables,
649     CP1 = loadings[, 1],
650     CP2 = loadings[, 2])
651

```

```
652 tabla_loadings[, 2:3] <- round(tabla_loadings[, 2:3],4)
653 tabla_loadings
654
655
656 # MAGNITUD DE LAS CARGAS
657 tabla_loadings_magnitud <- data.frame(
658   Variable = nombres_variabes,
659   CP1 = loadings[, 1],
660   CP2 = loadings[, 2])
661
662 tabla_loadings_magnitud$Abs_CP1 <- abs(tabla_loadings_magnitud$CP1)
663 tabla_loadings_magnitud$Abs_CP2 <- abs(tabla_loadings_magnitud$CP2)
664
665 # Ordenar por magnitud en CP1
666 tabla_loadings_magnitud[order(-tabla_loadings_magnitud$Abs_CP1),]
667
668 # Ordenar por magnitud en CP2
669 tabla_loadings_magnitud[order(-tabla_loadings_magnitud$Abs_CP2),]
670
671 # CORRELACION DE CP1 CON LA CALIFICACION DE RIESGO
672
673 # Extraer los valores de la primera componente
674 CP1 <- ACP$x[, 1]
675
676 # Calificacion de riesgo original
677 calificacion_riesgo <- riesgo$v11
678
679 # Calcular la correlacion
680 cor_CP1_riesgo <- cor(
681   CP1,
682   calificacion_riesgo,
683   use = "complete.obs")
684
685 # Mostrar resultado
686 cor_CP1_riesgo
687
688 # Correlacion de todas las componentes con la calificacion de riesgo
689 correlaciones_riesgo <- sapply(
690   1:ncol(ACP$x),
691   function(i) {
692     cor(
693       ACP$x[, i],
694       calificacion_riesgo,
695       use = "complete.obs"))
696
697 # Mostrar resultados
698 round(correlaciones_riesgo, 4)
699
700 # Tabla de correlaciones
701 tabla_cor_riesgo <- data.frame(
702   Componente = paste0(
703     "CP", 1:length(correlaciones_riesgo)),
704   Correlacion = round(correlaciones_riesgo,4))
705
706 tabla_cor_riesgo
707
708 # RELACION DE LA CALIFICACION DE RIESGO CON LAS VARIABLES ORIGINALES
```

```
709
710 correlaciones_variables_riesgo <- sapply(
711   datos_imputados,
712   function(x) {
713     cor(
714       x,
715       calificacion_riesgo,
716       use = "complete.obs"))
717
718 round(correlaciones_variables_riesgo, 4)
719
720 tabla_variables_riesgo <- data.frame(
721   Variable = names(datos_imputados),
722   Correlacion = correlaciones_variables_riesgo)
723
724 tabla_variables_riesgo <- tabla_variables_riesgo[order(-abs(tabla_variables_riesgo$Correlacion)),]
725 tabla_variables_riesgo$Correlacion <- round(tabla_variables_riesgo$Correlacion, 4)
726 tabla_variables_riesgo
```

Elaborado por:

Noé Antonio García Martínez

